

GARUDA: *Gated Adaptive Retrieval-Augmented Unsupervised Distillation Architecture* untuk Klasifikasi Sentimen Teks Ekonomi Indonesia

Muhammad Aufer Rizqi Kusuma - 13524061
Program Studi Teknik Informatika
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Bandung 40132
E-mail: 13524061@std.stei.itb.ac.id

Kurt Mikhael Purba - 13524065
Program Studi Teknik Informatika
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Bandung 40132
E-mail: 13524065@std.stei.itb.ac.id

Mochamad Fachri Alfaridzi - 13525128
Program Studi Teknik Informatika
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Bandung 40132
E-mail: 13525128@std.stei.itb.ac.id

Abstract— Analisis sentimen teks ekonomi berbahasa Indonesia memerlukan pemahaman konteks karena entitas, angka, dan istilah yang sama dapat membawa sentimen berbeda. Dataset penelitian terdiri atas 1.526 kalimat latih dan 654 kalimat uji dengan kelas **NEGATIF**, **NETRAL**, dan **POSITIF**. Penelitian ini mengusulkan GARUDA (*Gated Adaptive Retrieval-Augmented Unsupervised Distillation Architecture*), sebuah ensemble yang memadukan SVC berbasis TF-IDF kata dan karakter dengan empat encoder prelatih. Tiga encoder membentuk *teacher*; teks tanpa label dipakai sebagai data semu hanya ketika keyakinan *teacher* sedikitnya 0,95 dan kelasnya disetujui oleh SVC. *Student* dilatih dari bobot prelatih awal menggunakan data resmi dan data semu terpilih dengan *R-Drop* serta *token masking*. Pada 306 sampel validasi internal, ensemble mencapai *Macro F1* 0,8670, dibandingkan 0,8603 pada anggota tunggal terbaik. Pelatihan penuh menyeleksi 386 dari 654 kalimat uji sebagai data semu. Hasil tersebut menunjukkan bahwa representasi leksikal dan kontekstual memberikan sinyal yang saling melengkapi, sedangkan seleksi berbasis keyakinan dan kesepakatan membatasi penggunaan prediksi semu yang meragukan.

Kata kunci: analisis sentimen, teks ekonomi Indonesia, ensemble, distilasi tanpa supervisi, pseudo-label, IndoBERT, XLM-R

I. PENDAHULUAN

Informasi ekonomi, keuangan, dan bisnis hadir dalam bentuk yang padat, cepat berubah, serta sarat konteks. Sebuah kenaikan suku bunga, misalnya, dapat dipandang positif bagi pemberi pinjaman, tetapi negatif bagi pelaku usaha yang menanggung biaya modal lebih tinggi. Kalimat berita juga kerap memuat lebih dari satu sinyal sekaligus: capaian laba dapat disertai penurunan pertumbuhan, peningkatan harga dapat diikuti pelemahan permintaan, dan pernyataan yang tampak positif dapat dibalik maknanya oleh satu kata negasi. Kondisi tersebut membuat analisis sentimen ekonomi tidak cukup diselesaikan melalui pencarian kata positif dan negatif secara terpisah. Model perlu menilai hubungan antarkata, aktor yang terdampak, besaran numerik, serta konteks keseluruhan kalimat.

Permasalahan pada penelitian ini diformulasikan sebagai

klasifikasi tiga kelas atas kalimat ekonomi berbahasa Indonesia, yaitu **NEGATIF**, **NETRAL**, dan **POSITIF**. Kinerja model dinilai menggunakan *Macro F1*, sehingga ketepatan pada setiap kelas memperoleh bobot yang sama. Penggunaan metrik tersebut menuntut model yang tidak hanya mengikuti kelas yang lebih sering muncul, tetapi juga mampu membedakan sinyal sentimen yang berdekatan pada seluruh kelas.

Latar Belakang. Dataset penelitian terdiri atas 1.526 kalimat latih dan 654 kalimat uji. Kelas **NETRAL** berjumlah 610, sedangkan kelas **NEGATIF** dan **POSITIF** masing-masing berjumlah 458, sehingga rasio kelas terbesar terhadap kelas terkecil mencapai 1,33:1. Seluruh baris memiliki identitas unik, tidak mengandung nilai hilang, dan tidak memiliki teks kosong. Panjang teks relatif seragam, dengan median 63 karakter atau 10 kata serta maksimum 121 karakter atau 16 kata. Meskipun ringkas, 734 kalimat atau 48,1% data latih memuat angka. Angka tersebut dapat menyatakan nominal, persentase, tahun, atau perubahan kuantitatif yang berperan langsung dalam penentuan sentimen sehingga perlu dipertahankan selama prapemrosesan.

Eksplorasi leksikal juga memperlihatkan bahwa entitas populer bukan penentu kelas yang andal. Kata “BRI” muncul 337 kali pada kelas **NEGATIF**, 93 kali pada kelas **NETRAL**, dan 388 kali pada kelas **POSITIF**. Sebaliknya, frasa seperti “ATM”, “nasabah”, dan “uang” lebih sering menyertai kelas negatif; “saham”, “IHSG”, “OJK”, dan “rekomendasi” dominan pada kelas **netral**; sementara “triliun” dan “UMKM” lebih sering muncul pada kelas **positif**. Pola ini menunjukkan dua kebutuhan yang berlawanan tetapi sama penting. Model perlu mempertahankan pola kata dan karakter yang diskriminatif, namun pada saat yang sama harus mencegah penghafalan entitas serta menafsirkan kata tersebut di dalam konteks kalimat.

Ukuran data latih yang terbatas menambah kesulitan. Encoder bahasa berukuran besar dapat memahami konteks dengan lebih baik daripada model leksikal, tetapi hasil *fine-tuning* pada data kecil sensitif terhadap inisialisasi, pembagian data, dan bias domain prelatih. Di sisi lain, model TF-

IDF lebih stabil dalam menangkap frasa, variasi ejaan, dan pola angka, tetapi tidak memodelkan urutan makna secara mendalam. Pemanfaatan teks uji tanpa label melalui *pseudo-labeling* dapat memperluas data pelatihan, tetapi prediksi semu yang salah berpotensi memperkuat kesalahan *teacher*. Selain itu, terdapat dua kalimat latih duplikat setelah normalisasi dan tiga kalimat uji yang juga muncul pada data latih, sehingga protokol validasi harus mengendalikan kemiripan teks untuk mencegah estimasi performa yang terlalu optimistik.

Penelitian ini mengusulkan GARUDA untuk menjawab rangkaian tantangan tersebut. GARUDA menggabungkan satu jalur leksikal berbasis TF-IDF kata dan karakter dengan empat jalur encoder yang memiliki sumber representasi berbeda. Tiga encoder membentuk *teacher* untuk menghasilkan kandidat label semu, sedangkan SVC leksikal bertindak sebagai gerbang persetujuan yang independen. Sebuah kandidat hanya diterima apabila keyakinan *teacher* tinggi dan prediksi leksikal menyatakan kelas yang sama. Lima anggota kemudian digabung melalui rata-rata probabilitas berbobot sama agar keputusan akhir tidak bergantung pada satu jenis representasi.

Tujuan, Manfaat, dan Kontribusi. Penelitian ini bertujuan mengembangkan dan mengevaluasi sistem klasifikasi sentimen teks ekonomi Indonesia dengan menggabungkan representasi leksikal dan kontekstual. Kontribusi teknis penelitian ini meliputi:

- ensemble lima anggota yang memadukan SVC berbasis TF-IDF kata dan karakter dengan empat encoder dari sumber pelatihan yang berbeda;
- mekanisme seleksi label semu berdasarkan ambang keyakinan *teacher* dan kesepakatan dengan model leksikal; dan
- prosedur eksperimen yang mencatat konfigurasi model, pembagian data, jumlah label semu terpilih, serta sidik jari keluaran untuk membantu pemeriksaan ulang hasil.

Manfaat penelitian ini adalah menyediakan rancangan awal yang dapat digunakan sebagai acuan eksperimen untuk klasifikasi sentimen ekonomi Indonesia pada data berukuran terbatas. Penggabungan model leksikal dan kontekstual diharapkan membantu mengidentifikasi kondisi ketika kedua jenis representasi saling melengkapi, sedangkan mekanisme seleksi label semu memberikan cara yang lebih konservatif untuk memanfaatkan teks tanpa label. Hasil penelitian tetap perlu diuji lebih lanjut sebelum digunakan pada konteks operasional di luar dataset yang diteliti.

Batasan Masalah. Penelitian ini dibatasi pada dataset yang terdiri atas 1.526 data latih dan 654 data uji. Fitur klasifikasi hanya berasal dari kolom *kalimat*, sedangkan kolom *id* digunakan untuk menjaga urutan keluaran. Sistem menggunakan empat checkpoint publik yang dinyatakan dalam notebook dan tidak menggunakan dataset berlabel tambahan, pembacaan label uji, atau koreksi label secara manual. Data uji dimanfaatkan secara transduktif hanya melalui label semu yang dihasilkan pada proses berjalan. Nilai validasi berasal dari 306 sampel pada lipatan pertama pembagian terstratifikasi lima lipatan dengan *seed* 42. Karena

lipatan tersebut digunakan selama pengembangan, nilainya diperlakukan sebagai diagnostik internal dan bukan estimasi pada *holdout* baru yang sepenuhnya belum tersentuh. Penelitian ini berfokus pada *Macro F1* dan belum mencakup evaluasi lintas dataset, interpretasi kausal terhadap kondisi ekonomi, pemeriksaan kebenaran faktual isi berita, maupun optimasi latensi untuk penggunaan produksi.

II. LANDASAN TEORI

Klasifikasi Sentimen dan Macro F1. Analisis sentimen memetakan teks ke dalam kategori yang merepresentasikan polaritas opini. Pada penelitian ini, ruang label dinyatakan sebagai $\mathcal{C} = \{\text{NEGATIF}, \text{NETRAL}, \text{POSITIF}\}$. Karena kontribusi setiap kelas perlu dinilai secara setara, metrik utama yang digunakan adalah *Macro F1*. Untuk kelas c , presisi P_c dan *recall* R_c dihitung dari *true positive* (TP_c), *false positive* (FP_c), dan *false negative* (FN_c). Nilai akhirnya dirumuskan sebagai

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \quad (1)$$

$$F1_{\text{macro}} = \frac{1}{|\mathcal{C}|} \sum_{c \in \mathcal{C}} \frac{2P_c R_c}{P_c + R_c}.$$

Perataan antarkelas membuat peningkatan pada kelas yang lebih sering muncul tidak dapat sepenuhnya menutupi kinerja yang rendah pada kelas lain.

Representasi Leksikal TF-IDF. TF-IDF merepresentasikan dokumen melalui kepentingan relatif sebuah term terhadap seluruh korpus [1]. Untuk term t , dokumen d , dan korpus berukuran N , bobot dasarnya dinyatakan sebagai

$$\text{tfidf}(t, d) = \text{tf}(t, d) \log \left(\frac{N}{\text{df}(t)} \right), \quad (2)$$

dengan $\text{tf}(t, d)$ sebagai frekuensi term pada dokumen dan $\text{df}(t)$ sebagai jumlah dokumen yang memuat term tersebut. N-gram kata menangkap frasa pendek, sedangkan n-gram karakter mempertahankan informasi subkata, variasi ejaan, dan sebagian pola angka. Kedua representasi menghasilkan vektor jarang yang sesuai untuk teks singkat.

Support Vector Classification. Support Vector Machine mencari bidang pemisah dengan margin besar dan memperbolehkan pelanggaran margin melalui variabel slack [2]. Untuk kasus biner, optimasi *soft margin* dapat ditulis sebagai

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i, \quad y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i. \quad (3)$$

Pemetaan $\phi(\cdot)$ tidak perlu dihitung secara eksplisit apabila digunakan fungsi kernel. Kernel radial basis function mengukur kedekatan dua vektor melalui

$$K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2). \quad (4)$$

Untuk klasifikasi multikelas, beberapa pemisah biner digabungkan dan kelas dengan skor keputusan tertinggi dipilih sebagai prediksi.

Transformer dan Encoder Bahasa Pralatih. Transformer membentuk representasi kontekstual dengan

mekanisme *self-attention* [3]. Untuk matriks *query* Q , *key* K , dan *value* V berdimensi d_k , operasi perhatian dirumuskan sebagai

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V. \quad (5)$$

Setiap token memperoleh representasi berdasarkan hubungannya dengan token lain dalam kalimat. Representasi keluaran kemudian diproyeksikan menjadi logit $\mathbf{z}$ dan diubah menjadi probabilitas kelas melalui $p_c = \exp(z_c) / \sum_j \exp(z_j)$.

IndoBERT menyediakan representasi yang dipelajari khusus untuk bahasa Indonesia melalui korpus dan tugas pada IndoNLU [4]. XLM-R mempelajari representasi lintas bahasa dari korpus multibahasa berskala besar [5], sedangkan XLM-T melanjutkan prapenelitian pada data Twitter multibahasa agar lebih sesuai dengan bahasa media sosial dan tugas sentimen [6]. Perbedaan sumber pelatihan tersebut dapat menghasilkan pola kesalahan yang berbeda ketika model diadaptasi pada teks ekonomi Indonesia.

Ensemble Probabilistik. Ensemble menggabungkan beberapa model untuk mengurangi ketergantungan keputusan pada satu jenis representasi. Jika M model menghasilkan distribusi probabilitas $\mathbf{p}^{(m)}(x)$, rata-rata berbobot sama diberikan oleh

$$\bar{\mathbf{p}}(x) = \frac{1}{M} \sum_{m=1}^M \mathbf{p}^{(m)}(x), \quad \hat{y} = \arg \max_{c \in \mathcal{C}} \bar{p}_c(x). \quad (6)$$

Perataan bermanfaat ketika anggota ensemble membawa informasi yang saling melengkapi, tetapi tidak menjamin peningkatan apabila seluruh model menghasilkan kesalahan yang sama.

Pseudo-labeling dan Gerbang Keyakinan. *Pseudo-labeling* menggunakan prediksi model pada data tanpa label sebagai target tambahan. Seleksi berbasis ambang keyakinan merupakan cara umum untuk mengurangi pemakaian target semu yang tidak pasti [7]. Untuk probabilitas *teacher* $\mathbf{p}_T(x)$, label dan keyakinan semu dinyatakan sebagai

$$\hat{y}(x) = \arg \max_c p_{T,c}(x), \quad q(x) = \max_c p_{T,c}(x). \quad (7)$$

Sampel dapat dipakai apabila $q(x) \geq \tau$, dengan τ sebagai ambang yang ditetapkan. Gerbang tambahan berupa kesepakan dengan model dari keluarga representasi berbeda dapat memperketat seleksi, tetapi kualitas label semu tetap bergantung pada kesalahan kedua model. Oleh karena itu, skor dari proses ini perlu dinilai sebagai mekanisme penyaringan, bukan bukti bahwa label semu selalu benar.

R-Drop dan Token Masking. Dropout menghasilkan submodel yang berbeda pada setiap lintasan maju. R-Drop mendorong dua distribusi keluaran dari masukan yang sama agar konsisten dengan menambahkan divergensi Kullback–Leibler dua arah [8]. Untuk dua keluaran $\mathbf{p}_1$ dan $\mathbf{p}_2$, fungsi kerugiannya ditulis sebagai

$$\mathcal{L}_{\text{RDrop}} = \frac{1}{2} [\mathcal{L}_{\text{CE}}(\mathbf{p}_1, y) + \mathcal{L}_{\text{CE}}(\mathbf{p}_2, y)] + \frac{\alpha}{2} [D_{\text{KL}}(\mathbf{p}_1 \parallel \mathbf{p}_2) + D_{\text{KL}}(\mathbf{p}_2 \parallel \mathbf{p}_1)]. \quad (8)$$

Token masking melengkapi regularisasi tersebut dengan mengganti sebagian token nonspesial menggunakan token mask selama pelatihan. Perturbasi ini mencegah model bergantung penuh pada satu token, sementara teks asli tetap digunakan pada validasi dan inferensi.

III. METODOLOGI

IV. EKSPERIMEN DAN HASIL

V. KESIMPULAN

REFERENCES

- [1] G. Salton and C. Buckley, “Term-weighting approaches in automatic text retrieval,” *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988, doi: 10.1016/0306-4573(88)90021-0.
- [2] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995, doi: 10.1007/BF00994018.
- [3] A. Vaswani et al., “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017. [Online]. Available: <https://arxiv.org/abs/1706.03762>
- [4] B. Wilie et al., “IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding,” in *Proc. 1st AACL-IJCNLP*, Suzhou, China, 2020, pp. 843–857, doi: 10.18653/v1/2020.aacl-main.85.
- [5] A. Conneau et al., “Unsupervised cross-lingual representation learning at scale,” in *Proc. 58th Annual Meeting of the Association for Computational Linguistics*, 2020, pp. 8440–8451, doi: 10.18653/v1/2020.acl-main.747.
- [6] F. Barbieri, L. Espinosa Anke, and J. Camacho-Collados, “XLM-T: Multilingual language models in Twitter for sentiment analysis and beyond,” in *Proc. 13th Language Resources and Evaluation Conference*, Marseille, France, 2022, pp. 258–266.
- [7] K. Sohn et al., “FixMatch: Simplifying semi-supervised learning with consistency and confidence,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020. [Online]. Available: <https://arxiv.org/abs/2001.07685>
- [8] X. Liang et al., “R-Drop: Regularized dropout for neural networks,” in *Advances in Neural Information Processing Systems*, 2021. [Online]. Available: <https://arxiv.org/abs/2106.14448>