

HIDRA (Headline Incongruity Detection with Rival-paired Monotonic Alignment): Ensemble Fitur Penyelarasan Monoton dan Perbandingan Rival Berpasangan untuk Klasifikasi Kesesuaian Judul dan Isi Berita Indonesia

Muhammad Aufar Rizqi Kusuma - 13524061

Program Studi Teknik Informatika
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Bandung 40132
E-mail: 13524061@std.stei.itb.ac.id

Kurt Mikhael Purba - 13524065

Program Studi Teknik Informatika
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Bandung 40132
E-mail: 13524065@std.stei.itb.ac.id

Mochamad Fachri Alfaridzi - 13525128

Program Studi Teknik Informatika
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Bandung 40132
E-mail: 13525128@std.stei.itb.ac.id

Abstract—*Headline Incongruity Detection (HID)* adalah tugas mengidentifikasi ketidaksesuaian antara judul berita dan isi teksnya. Tugas ini menjadi kritis karena pembaca daring cenderung hanya memindai judul sehingga informasi yang keliru dapat menyebar luas, terutama pada isu sensitif. Tantangan utama pada dataset berita Indonesia adalah distribusi kelas yang sangat tidak seimbang (rasio 9:1), kemiripan leksikal tinggi di kedua kelas (rerata *overlap* 0,796 versus 0,749), serta larangan penggunaan model *pretrained*. Penelitian ini mengusulkan *HIDRA (Headline Incongruity Detection with Rival-paired Monotonic Alignment)*, suatu *pipeline* yang menggabungkan rekayasa fitur multiblok dengan pemodelan paralel. Rekayasa fitur mencakup penyelarasan monoton berbasis *longest increasing subsequence*, pemeringkatan rival berbasis indeks TF-IDF, serta perbandingan berpasangan terhadap tetangga terdekat. Pemodelan paralel terdiri dari *ensemble* pohon bergradien beranggotakan enam model untuk menangkap interaksi struktural, serta *cross encoder BiGRU* dengan mekanisme atensi yang dilatih pada data sintesis tujuh skema korupsi untuk menangkap interaksi kontekstual. Seluruh komponen dilatih dari awal tanpa bobot *pretrained* dan divalidasi menggunakan *StratifiedGroupKFold* lima lipatan. Evaluasi terhadap data validasi menghasilkan *Macro F1* sebesar 0,8728, dengan skor kelas minoritas (*Tidak Sesuai*) mencapai 0,7690. Kontribusi utama meliputi fitur penyelarasan monoton dan perbandingan rival yang mengubah pertanyaan absolut menjadi komparatif, serta generator korupsi sintesis yang mengarahkan *cross encoder* pada tipologi kesalahan nyata. Pengembangan lebih lanjut meliputi eksplorasi *cross-lingual transfer* dan optimasi inferensi untuk penerapan waktu nyata. **Kata Kunci:** *Headline Incongruity Detection*, penyelarasan monoton, perbandingan rival, *gradient boosted decision tree*, *cross encoder*, deteksi ketidaksesuaian berita

I. PENDAHULUAN

Judul adalah ringkasan berita dan menjadi dasar pertama bagi pembaca untuk memutuskan membaca isi dan memercayai pemberitaan. Interaksi pembaca daring kini bertumpu pada pemindaian cepat sehingga judul dibaca tanpa

isi dibaca sampai tuntas. Ketika judul tidak mencerminkan peristiwa yang diberitakan, pembaca memperoleh gambaran yang salah. Risiko salah paham membesar ketika rentang perhatian menyusut dan semakin membesar ketika kebiasaan verifikasi masih lemah. Pada isu sensitif seperti SARA, salah paham yang kecil terhadap suatu berita yang demikian dapat berubah menjadi kegaduhan di masyarakat.

Persoalan ini terlihat sepele tetapi sulit diselesaikan secara otomatis. Di dunia akademik, permasalahan ini lebih dikenal sebagai *Headline Incongruity Detection (HID)*. Metode paling sederhana dari HID adalah dengan memeriksa apakah kata pada judul muncul di dalam isi. Akan tetapi, cara tersebut gagal ketika judul dan isi memakai kata yang sama untuk peristiwa yang bertolak belakang [1]. Penghitungan skor kemiripan kata juga gagal pada parafrasa dan pada perbedaan kecil nama atau angka yang mengubah makna [5], [6]. Kegagalan serupa pun juga terdokumentasi pada data berita yang berbahasa Indonesia [7], [8]. Penentuan kesesuaian antara judul berita dan teks isi menuntut analisis semantik yang mendalam. Penilaian tidak bisa hanya berdasarkan frekuensi kata, melainkan memerlukan analisis konteks dari judul dengan isi berita. Maka dari itu, diperlukan Sistem *HID* yang *robust* terhadap keragaman teks yang tersebar pada media digital yang dapat menangkap makna semantik dari judul berita dengan isinya, lalu membandingkannya sebagai dasar keputusan untuk dapat menentukan kesesuaian judul berita dengan isinya.

Latar Belakang. Tantangan HID pada penelitian ini dapat dirangkum ke dalam beberapa poin: (1) Distribusi label sangat tidak seimbang. Data latih memuat 14397 pasangan dengan 12960 berlabel *Sesuai* dan 1437 berlabel *Tidak Sesuai*. (2) Panjang judul dan isi timpang. Judul rata-rata 10 kata. Isi rata-rata 310 kata dengan terdapat pencilan yang memiliki kata sangat panjang. (3) Kemiripan kata tinggi di

kedua kelas. (4) Topik Covid yang mendominasi judul pada dataset dan aturan lomba yang mewajibkan model harus dilatih *from scratch* tanpa bobot pra latih.

Pendekatan awal mengandalkan fitur artifisial dan TF-IDF. Riedel *et al.* membangun baseline FNC-1 yang sulit dikalahkan dengan TF-IDF dan SVD serta XGBoost [9]. Yoon *et al.* kemudian mengembangkan encoder hierarkis ganda berbasis perhatian untuk memodelkan paragraf isi yang panjang [10]. Selain itu, Mishra *et al.* mengusulkan pencocokan semantik dengan perhatian timbal balik antara judul asli dan judul sintetis [11]. Sayangnya, seluruh pendekatan tersebut menunjukkan degradasi pada kondisi dataset ini. Baseline leksikal gagal membedakan tukar nama dan angka yang mempertahankan kata sama, sedangkan di satu sisi, model hierarkis dan semantik membutuhkan data besar dan representasi pra latih sehingga tidak dapat dipakai karena *constraint* dari penelitian ini.

Tujuan, Manfaat, dan Kontribusi. Penelitian ini bertujuan membangun sistem HID yang robust terhadap variasi panjang teks dan kemiripan judul isi yang tinggi melalui ensemble GBDT, dilengkapi dengan fitur penyalarsan dan perbandingan rival yang dikombinasikan dengan cross encoder BiGRU. Kontribusi teknis penelitian ini meliputi tiga hal berikut.

- Monotonic alignment (ALG) dan aligned window (ALI) yang menangkap pertukaran peran dan urutan kata antara judul dan isi.
- Paired rival comparison (DUP dan NDP) yang mengubah pertanyaan menjadi judul mana yang lebih berhak atas suatu isi. Fitur ini didukung rival ranking (RET) berbasis indeks TF-IDF.
- Cross encoder BiGRU dengan synthetic corruption generator tujuh resep yang melatih model peka terhadap permutasi dan negasi yang lolos dari handcrafted features.

Terdapat dua manfaat dari penelitian ini. Pertama, bagi komunitas riset dan redaksi, sistem ini diharapkan menjadi acuan terbuka pengembangan deteksi Headline Incongruity berbahasa Indonesia sekaligus alat bantu kurasi judul sebelum diterbitkan. Kedua, bagi masyarakat, sistem ini menjadi pelindung dari salah paham akibat judul yang menyesatkan.

Batasan Masalah. Penelitian ini dibatasi pada empat ruang lingkup berikut. Pertama, evaluasi dilakukan secara eksklusif pada dataset kompetisi DAC IFEST 2026 tanpa pengujian lintas dataset. Kedua, tugas dibatasi pada klasifikasi biner Sesuai dan Tidak Sesuai untuk berita berbahasa Indonesia dan tidak mencakup jenis misinformasi lain di luar ketidaksesuaian judul dan isi. Ketiga, seluruh parameter diinisialisasi acak dan dioptimasi pada korpus latih tanpa memanfaatkan bobot pra latih apapun dan data uji hanya dipakai pada tahap inferensi. Keempat, sistem dioptimasi untuk Macro F1 kompetisi dan belum dioptimasi untuk inferensi real-time.

II. LANDASAN TEORI

Headline Incongruity Detection (HID). HID didefinisikan sebagai persoalan menilai apakah informasi utama pada judul berita secara faktual didukung oleh isi berita yang menyertainya. Persoalan ini berbeda dari deteksi *clickbait*, yang berfokus pada judul provokatif atau sensasional terlepas dari kebenarannya [1], karena HID menuntut penilaian terhadap hubungan referensial antara dua unit teks, mendekati kerangka *textual entailment* dan identifikasi parafrasa. Riset awal memperlakukan HID sebagai persoalan klasifikasi berbasis fitur buatan tangan, sementara riset lanjutan bergeser ke representasi semantik yang dipelajari dari data [5], [6]. Pada konteks bahasa Indonesia, kajian menunjukkan pola kegagalan yang serupa dengan bahasa Inggris, bahkan dengan tantangan tambahan berupa morfologi aglutinatif dan keterbatasan sumber daya berlabel [7], [8]. Kesamaan lintas bahasa ini menegaskan bahwa akar persoalan HID bukan pada bahasa tertentu, melainkan pada keterbatasan mendasar ukuran kemiripan permukaan dalam menangkap perubahan makna.

Vector Space Model & Lexical Similarity. Model ruang vektor dengan pembobotan TF-IDF [13] dan ukuran himpunan seperti Jaccard mengasumsikan teks yang berbagi kosakata membicarakan hal yang sama, dan terbukti menjadi *baseline* kuat pada deteksi sikap berita [9], tetapi rapuh terhadap pertukaran entitas atau angka yang mempertahankan kata yang sama. Hipotesis distribusional, bahwa kata pada konteks serupa memiliki makna berdekatan [14], mendasari *Word2Vec* yang mempelajari vektor kata dari korpus tanpa label eksternal [15], sementara *pointwise mutual information* mengukur kekuatan asosiasi dua kata dari statistik kemunculan bersama [16]. Kedua kerangka ini memungkinkan estimasi kedekatan makna sepenuhnya dari data latih tanpa bobot pra latih.

Penyalarsan Urutan dan Pemeringkatan Relatif. Selain kosakata, urutan informasi membawa makna struktural. Penyalarsan rangkaian yang berakar pada pencocokan biologi komputasional [17] dan korelasi peringkat Kendall tau [18] menyediakan kerangka untuk mengukur konsistensi urutan, relevan karena berita konvensional mengikuti gaya piramida terbalik sehingga penyimpangan pola monoton menjadi sinyal struktural. Teori *learning to rank* [19], yang berakar pada hukum penilaian komparatif Thurstone [20], menunjukkan bahwa perbandingan relatif antar kandidat sering lebih diskriminatif daripada penilaian mutlak satu kandidat secara terisolasi.

Encoder Neural, Atensi, dan Augmentasi Data. *Gated recurrent unit* memodelkan ketergantungan sekuensial secara hemat parameter [21], sedangkan mekanisme atensi membentuk penyalarsan lunak dinamis antar-elemen dua rangkaian [22]. *Enhanced Sequential Inference Model* menggabungkan keduanya melalui atensi silang sebelum komposisi [23], merepresentasikan paradigma *cross-encoder* yang menangkap interaksi berbutir halus, berbeda dari *bi-encoder* yang mengorbankan kedalaman interaksi demi efisiensi. Untuk memperkaya data latih pada kelas minoritas, pembangk-

itan contoh negatif melalui perturbasi terkendali [24] dapat diarahkan pada tipologi kesalahan nyata seperti pertukaran entitas, negasi, dan permutasi urutan, tanpa bergantung pada model generatif pralatih.

III. METODOLOGI

A. Gambaran Umum Pipeline

HIDRA (*Headline Incongruity Detection with Rival-paired Monotonic Alignment*) menilai kesesuaian judul-isi secara komparatif antarjudul yang berasosiasi dengan isi yang sama, karena ketidaksesuaian umumnya mempertahankan kemiripan leksikal tinggi. Penilaian tersebut diwujudkan melalui pengujian konsistensi penyelarasan monoton, perbandingan berpasangan berbasis pemeringkatan, serta pengodean lintas sekuens.

Secara garis besar, *pipeline* dari program terdiri atas tujuh tahap berurutan, yaitu eksplorasi data untuk pemetaan karakteristik dan himpunan sulit, prapemrosesan berupa normalisasi teks dan pembentukan grup untuk validasi, rekayasa fitur multiblok yang mencakup fitur semantik dasar, penyelarasan monoton, pemeringkatan berbasis temu kembali, perbandingan berpasangan, dan leksikon eksternal, pemodelan paralel melalui *ensemble* pohon bergradien dan pengodean lintas sekuens berbasis BiGRU dengan mekanisme atensi, kalibrasi untuk penyamaan ruang skor, serta penentuan ambang keputusan dan inferensi. *Ensemble* pohon bergradien berperan menangkap sinyal struktural dan leksikal, sedangkan pengodean lintas sekuens menangkap interaksi kontekstual berbutir halus; keduanya bersifat komplementer.

Strategi pelatihan menggunakan validasi silang berkelompok terstratifikasi agar baris yang berbagi judul atau isi tidak terpisah antarlipatan, penanganan ketidakseimbangan kelas melalui pembobotan dan penentuan ambang berbasis validasi, serta pengayaan data kelas minoritas melalui beberapa skema perturbasi sintesis terkendali. Seluruh sumber daya korpus dan fitur dibentuk hanya dari data latih, sedangkan data uji digunakan hanya pada tahap inferensi. Seluruh model diinisialisasi secara acak dan dilatih dari awal tanpa bobot pralatih. Ambang keputusan dan bobot penggabungan ditentukan dari prediksi luar lipatan yang memaksimalkan *Macro F1*, kemudian diterapkan tanpa perubahan pada skor data uji yang dihasilkan rata-rata prediksi model tiap lipatan. Gambar 1 menunjukkan diagram *pipeline* pemrosesan data secara lengkap.

B. Text Preprocessing & Strategi Validasi

Prapemrosesan pada penelitian ini tidak dimaksudkan untuk mengubah isi informasi teks, melainkan untuk menjamin konsistensi representasi sebelum masuk ke tahap rekayasa fitur, serta membentuk struktur pengelompokan yang menjadi dasar skema validasi yang jujur terhadap kebocoran data.

Normalisasi Teks. Setiap teks judul dan isi dinormalisasi melalui fungsi

$$\text{norm}(s) = \text{lower}(\text{collapse}_{\setminus s}(\text{trim}(s)))$$

dengan $\text{trim}(\cdot)$ menghapus spasi di awal dan akhir string, $\text{collapse}_{\setminus s}(\cdot)$ menyederhanakan seluruh rangkaian karakter *whitespace* menjadi satu spasi tunggal, dan $\text{lower}(\cdot)$




Fig. 1: Diagram *pipeline* HIDRA. Data latih dipetakan menjadi matriks fitur lima blok, dipelajari oleh dua jalur model yang komplementer, lalu digabung melalui kalibrasi dan ambang keputusan yang ditentukan dari prediksi luar lipatan (*out-of-fold*).

mengubah seluruh karakter menjadi huruf kecil. Hasil $\text{norm}(s)$ pada judul dan isi masing-masing dinotasikan $t_i = \text{norm}(\text{judul}_i)$ dan $c_i = \text{norm}(\text{isi}_i)$ untuk baris ke- i . Normalisasi ini bersifat minimal dan disengaja, karena tanda baca pada dataset sudah bersih, sehingga langkah tambahan seperti penghapusan stopword atau *stemming* sengaja tidak diterapkan pada tahap ini agar tidak menghilangkan sinyal yang justru dibutuhkan pada tahap rekayasa fitur selanjutnya.

Pembentukan Grup melalui Union-Find. Pemeriksaan integritas data menemukan sejumlah kecil baris pada data latih yang memiliki pasangan judul dan isi yang identik persis secara tekstual. Kondisi ini secara umum menandakan risiko kebocoran validasi apabila baris-baris yang saling berbagi teks yang identik atau saling terhubung ditempatkan pada *fold* latih dan *fold* validasi yang berbeda, karena model dapat menghafal langsung kemunculan pasangan tersebut alih-alih mempelajari relasi kesesuaian secara umum [25].

Untuk mencegah hal ini, didefinisikan relasi $i \sim j$ apabila $t_i = t_j$ atau $c_i = c_j$. Relasi $\sim$ pada dasarnya tidak bersifat transitif secara langsung, sehingga dibentuk relasi ekivalensi $\approx$ sebagai penutupan transitif (*transitive closure*) dari $\sim$, yaitu $i \approx j$ jika dan hanya jika terdapat rangkaian indeks $i = k_0, k_1, \dots, k_m = j$ sedemikian sehingga $k_l \sim k_{l+1}$ untuk setiap l . Relasi ekivalensi ini mempartisi seluruh baris data latih ke dalam himpunan grup saling lepas

$$\mathcal{G} = \{G_1, G_2, \dots, G_M\}, \quad \bigcup_{m=1}^M G_m = \{1, \dots, N_{\text{tr}}\}, \\ G_m \cap G_{m'} = \emptyset \quad (m \neq m')$$

dengan fungsi keanggotaan grup $g(i) = m$ jika $i \in G_m$. Partisi ini dihitung secara efisien menggunakan struktur data *union-find* dengan pemadatan lintasan (*path compression*), yang memberikan kompleksitas waktu amortisasi mendekati $O(N_{\text{tr}} \alpha(N_{\text{tr}}))$ dengan α adalah fungsi invers Ackermann yang tumbuh sangat lambat, sehingga tetap efisien meskipun diterapkan pada seluruh baris data latih. Baris pada data uji tidak diikutsertakan dalam pembentukan grup ini dan diberi indeks grup yang unik satu sama lain, sehingga struktur korpus data uji tidak memengaruhi proses pengelompokan yang hanya dibentuk dari data latih.

Skema Validasi StratifiedGroupKFold. Validasi silang standar berasumsi setiap baris adalah unit observasi yang

independen, sebuah asumsi yang dilanggar oleh keberadaan grup $\mathcal{G}$ pada bagian sebelumnya. Penelitian ini menggunakan *StratifiedGroupKFold* dengan $K = 5$ fold, yaitu skema yang membagi data berdasarkan grup $g(i)$, bukan berdasarkan baris satu per satu, sehingga seluruh anggota satu grup (baris yang berbagi judul atau isi yang identik) selalu jatuh pada fold yang sama dan tidak pernah terbelah antara data latih dan data validasi. Di dalam batasan tersebut, algoritma tetap berusaha menjaga proporsi kelas Sesuai dan Tidak Sesuai pada tiap fold semirip mungkin dengan proporsi keseluruhan, mengingat rasio ketidakseimbangan kelas yang mendekati sembilan berbanding satu berisiko membuat proporsi kelas antar-fold timpang jika hanya mengandalkan pembagian acak [26].

C. Feature Engineering

Rekayasa fitur dibentuk karena kemiripan leksikal mentah tidak diskriminatif pada himpunan sulit. Rerata *overlap* kelas Sesuai 0,796 berbanding Tidak Sesuai 0,749 dengan 954 baris negatif *ber-overlap* di atas 0,7. Seluruh fitur dihitung dari awal tanpa bobot pralatih dan difit hanya pada data latih. Total sekitar 264 fitur tabular dikelompokkan menjadi lima blok yang saling melengkapi, yang meliputi semantik dasar (SEM, 69 fitur), penyesuaian monoton (ALG, 19 fitur), temu kembali (RET, 90 fitur), perbandingan berpasangan (DUP 6 dan NDP 56 fitur), serta leksikon eksternal (EXT, 24 fitur).

Dua besaran statistik dipakai berulang lintas blok fitur dan karena itu didefinisikan lebih dahulu. Bobot *inverse document frequency* suatu kata w dihitung sebagai

$$\text{idf}(w) = \ln \left(\frac{N}{1 + \text{df}(w)} \right),$$

dengan N jumlah dokumen isi pada data latih dan $\text{df}(w)$ jumlah dokumen yang memuat w , dipakai untuk memberi bobot lebih besar pada kata yang jarang muncul ketika mengukur seberapa penting suatu kata yang hilang atau tertangkap. Kekuatan asosiasi dua kata a dan b dihitung melalui *pointwise mutual information* empiris dari ko-okurensi dalam jendela isi yang sama,

$$\text{pmi}(a, b) = \ln \left(\frac{c(a, b)/N}{(\text{df}(a)/N)(\text{df}(b)/N)} \right),$$

dengan $c(a, b)$ jumlah dokumen yang memuat a dan b bersamaan. Kemiripan semantik dua kata $\text{sim}(a, b)$ diperoleh dari *cosine similarity* vektor *Word2Vec* yang dilatih sendiri pada gabungan judul dan isi data latih. Ketiga fungsi ini menjadi komponen dasar bagi fitur cloze dan fitur rival pada blok-blok berikutnya.

Blok SEM: Fitur Semantik Dasar. Konsep dari Blok SEM adalah ia memperluas *coverage* sederhana menjadi dukungan berlapis (melalui eksak, singkatan, bentuk dasar kata, kemiripan trigram karakter, dll), sehingga parafrasa yang sah tetap terdeteksi meski kata permukaannya berbeda. *Coverage* tertimbang IDF dihitung sebagai

$$\text{cov_idf} = \frac{\sum_{w \in T} \text{idf}(w) \cdot \mathbb{I}[w \in C]}{\sum_{w \in T} \text{idf}(w)}.$$

Entitas dideteksi tanpa kamus eksternal melalui *cap rate* $\text{caprate}(w) \geq 0,6$. Fitur paling diskriminatif adalah *cloze slot filling*, dimana untuk entitas judul yang tak terdukung isi, dicari kata tetangganya lalu ditelusuri entitas apa yang sebenarnya mengisi posisi tersebut di isi, kemudian dihitung sim dan pmi antara entitas judul dan entitas pengisi. Fitur ini langsung menyasar pola pertukaran entitas yang mendominasi *hard negative*. Fitur pelengkap lain mencakup n-gram verbatim, rasio inversi urutan kemunculan (setara Kendall tau), serta ketidakcocokan negasi dan angka.

Blok ALG: Penyesuaian Monoton Berbasis LIS. Konsep dari ALG adalah token judul yang sah umumnya tersusun monoton terhadap posisi kemunculannya di isi, sehingga pelanggaran urutan menandakan pertukaran peran. Diterapkan melalui *longest increasing subsequence* atas pasangan posisi (judul, isi) yang dinyatakan oleh

$$\text{aln_frac} = \frac{|\text{aligned}|}{|T_{\text{core}}|}.$$

Untuk token yang gagal selaras, posisi yang diharapkan diinterpolasi dari jangkar terdekat, lalu jendela di sekitarnya diperiksa keberadaan entitas atau negasi lain. Blok ini menangkap substitusi dari sudut urutan, melengkapi cloze pada Blok SEM yang menilai dari sudut kata tetangga.

Blok RET: Pemeringkatan Rival Berbasis Temu Kembali. Konsep dari blok RET adalah ia mengubah pertanyaan menjadi pemeringkatan, yaitu, apakah isi yang dipasangkan benar-benar kandidat terbaik untuk judul tersebut dibanding seluruh judul lain di korpus. Dengan TF-IDF (kata dan karakter) yang di-fit train-only, dihitung margin skor terhadap kandidat terbaik selain grup sendiri dengan menggunakan

$$\text{marg}_i = s(t_i, c_i) - \max_{j \notin G_i} s(t_i, c_j).$$

Margin yang bernilai negatif berarti ada isi lain yang lebih cocok dengan judul tersebut, sinyal kuat ketidaksesuaian. Dihitung dua arah kueri dan dua representasi teks agar saling melengkapi.

Blok DUP dan NDP: Perbandingan Berpasangan. Konsep dari Blok DUP dan NDP adalah ia akan menilai sebuah pasangan secara relatif terhadap rival/tetangga terdekatnya. Duplikasi eksak diperiksa lebih dulu (Blok DUP), lalu *near-duplicate* ditentukan lewat ambang *cosine* isi 0,85 dan judul 0,93 (Blok NDP). Fitur permukaan sejenis Blok SEM dihitung ulang pada rival, lalu diambil selisihnya lewat

$$\Delta_{\text{cov}} = \text{cov}(T_i, C_i) - \text{cov}(T_{\text{rival}}, C_i).$$

Δ yang bernilai negatif berarti rival lebih didukung isi yang sama, berguna khusus pada kasus satu isi dipakai lebih dari satu judul kandidat.

Blok EXT: Leksikon Dalam Perbandingan. Konsep dari blok EXT adalah ia akan melengkapi fitur statistik dengan *gazetteer* wilayah berjenjang, leksikon nama orang, kamus normalisasi KBBA, dan tesaurus sinonim, yang dibatasi pada kosakata train saja. Singkatan wilayah (seperti *jabar*, *dki*) dikenali lewat pencocokan subsekuensi karakter. Fraksi token

lokasi yang tak terdukung isi dapat dihitung lewat

$$e_geo_miss_frac = \frac{|\{w \in T \cap geo : w \notin C\}|}{|\{w \in T : w \in geo\}|},$$

yang dilengkapi dengan indikator ketidakcocokan provinsi. Sama seperti Blok DUP/NDP, fitur ini juga dihitung selisihnya terhadap rival, menangkap ketidakcocokan lokasi/tokoh pada level kategori yang lebih kasar.

Seluruh kolom dari kelima blok digabung menjadi satu matriks fitur untuk jalur pohon keputusan, sementara teks mentah judul dan isi tetap dipertahankan terpisah sebagai input jalur *encoder* neural.

D. Arsitektur Model

Persoalan klasifikasi kesesuaian judul dan isi dapat dirumuskan sebagai pencarian fungsi diskriminatif f yang memetakan sepasang teks, yaitu judul T dan isi C , ke suatu peluang

$$f(T, C) = \hat{p} \approx P(y = 1 | T, C), \quad \hat{p} \in [0, 1],$$

dengan $y = 1$ menyatakan kelas *Sesuai*. Penelitian ini menggabungkan dua golongan model yang berbeda secara mendasar dalam cara mempelajari f . Golongan pertama adalah *ensemble* pohon keputusan berpenguatan gradien (*gradient boosted decision tree*) yang beroperasi atas matriks fitur tabular hasil rekayasa fitur pada bagian sebelumnya, sehingga interaksi antar-variabel bersifat eksplisit karena telah dirumuskan terlebih dahulu dalam bentuk fitur. Golongan kedua adalah *encoder* neural sekuensial yang beroperasi langsung atas rangkaian token mentah judul dan isi, sehingga interaksi antar-kata dipelajari secara implisit melalui parameter yang dioptimasi dengan penurunan gradien. Gambar 2 memperlihatkan arsitektur lengkap kedua jalur beserta alur datanya.

Ensemble Gradient Boosting Model. Setiap anggota *ensemble* mengikuti kerangka penguatan gradien, yaitu model aditif bertahap

$$F_m(x) = F_{m-1}(x) + \eta h_m(x),$$

$$h_m = \arg \min_h \sum_i \left[-\frac{\partial L(y_i, F_{m-1}(x_i))}{\partial F_{m-1}(x_i)} - h(x_i) \right]^2.$$

dengan h_m pohon regresi dangkal yang dilatih untuk mendekati turunan negatif fungsi kerugian (*pseudo-residual*) pada tahap sebelumnya, dan η laju pembelajaran yang mengendalikan kontribusi tiap tahap. Peluang akhir suatu anggota model diperoleh melalui fungsi sigmoid $\hat{p}(x) = \sigma(F_M(x))$ terhadap fungsi kerugian log-likelihood biner.

Tiga implementasi penguatan gradien dipakai sekaligus, yaitu LightGBM, XGBoost, dan CatBoost, yang berbeda pada strategi pertumbuhan pohon, skema regularisasi, dan penanganan pembelahan fitur, masing-masing dilatih dengan dua nilai *seed* acak berbeda dan lima lipatan validasi silang berkelompok. Peluang akhir golongan ini merupakan rerata atas seluruh anggota,

$$\hat{p}_{GBDT}(x) = \frac{1}{|\mathcal{K}|} \sum_{k \in \mathcal{K}} \left(\frac{1}{5} \sum_{l=1}^5 \hat{p}_{k,l}(x) \right),$$

dengan $\mathcal{K}$ himpunan enam kombinasi implementasi dan *seed*. Keragaman implementasi menjadikan galat antar-anggota cenderung tidak berkorelasi sempurna, karena tiap implementasi memiliki kecenderungan galat yang berbeda akibat perbedaan mekanisme pembelahan pohon, sementara pengulangan atas beberapa *seed* menekan variansi yang timbul murni akibat keacakan pembagian data latih. Kombinasi kedua sumber keragaman ini menjadi dasar kekukuhan golongan model pertama terhadap fluktuasi data latih.

Cross-Encoder BiGRU dengan Atensi Silang. Golongan kedua adalah *cross encoder* sekuensial bergaya ESIM [23] yang membaca pasangan judul-isi secara bersamaan. Judul dipotong maksimum 24 token dan isi 200 token. Lapisan *embedding* berdimensi 200 diinisialisasi acak dari $\mathcal{N}(0, 0, 1)$ dan dilatih sepenuhnya dari awal. Enkoder judul menerima pasangan $(emb(w), f_w)$ dengan $f_w \in \{0, 1\}$ penanda apakah token judul ditemukan dalam isi, yaitu sinyal leksikal murah yang mempercepat konvergensi, sedangkan enkoder isi hanya menerima *embedding*. Keduanya memakai GRU dua arah dengan 160 unit tersembunyi, menghasilkan matriks representasi $H_t \in \mathbb{R}^{|T| \times 2h}$ dan $H_c \in \mathbb{R}^{|C| \times 2h}$. Atensi silang menghitung kesesuaian antar posisi judul terhadap seluruh posisi isi,

$$\alpha_{ij} = \frac{\exp(h_i^t \cdot h_j^c)}{\sum_{j'=1}^{|C|} \exp(h_i^t \cdot h_{j'}^c)}, \quad a_i = \sum_{j=1}^{|C|} \alpha_{ij} h_j^c,$$

lalu tiap posisi judul dikomposisikan menjadi $[h_i^t; a_i; h_i^t - a_i; h_i^t \odot a_i]$, diproyeksikan ke $2h$ melalui lapisan linear-ReLU dengan *dropout* 0,2, dan diencode ulang oleh GRU lokal dua arah. Vektor pasangan dibentuk dari *pooling* rata-rata dan maksimum *ter-mask* atas judul ditambah rata-rata atas isi, kemudian kepala MLP dua lapis mengeluarkan peluang kelas melalui fungsi sigmoid. Karena model membaca kedua teks sekaligus dan peka terhadap urutan, ia menangkap negasi, permutasi, dan pertukaran entitas yang lolos dari fitur tabular, sehingga komplementer terhadap golongan GBDT.

E. Generator Korupsi Sintetis

Cross encoder memerlukan contoh negatif yang meniru tipologi kesalahan nyata, sementara data latih hanya menyediakan 1437 baris negatif asli. Generator korupsi mengubah pasangan *Sesuai* menjadi *Tidak Sesuai* melalui tujuh resep yang diturunkan dari observasi himpunan sulit. Langkah-langkah dilakukan dengan cara : (1) substitusi entitas (SUB_ENT, proporsi 0,574), (2) penggantian judul oleh judul artikel lain terdekat (PAIR, 0,167), (3) penghapusan kata negasi (NEG_DEL, 0,106), (4) permutasi dua entitas (PERM, 0,061), (5) substitusi bigram entitas berurutan (SUB_MULTII, 0,061), (6) penyisipan negasi sebelum kata modal (NEG_INS, 0,015), (7) dan substitusi angka sebesar 5–60% (SUB_NUM, 0,015).

Resep SUB_ENT mengganti satu entitas judul dengan tetangga terdekatnya dalam ruang *Word2Vec* yang dilatih sendiri, dengan kandidat dibatasi pada entitas berfrekuensi minimal empat pada korpus judul. Dengan peluang 0,45 kandidat yang dipilih justru kata yang *tidak* muncul dalam isi, meniru pola pertukaran tokoh pada *hard negative*. Seleksi




Fig. 2: Arsitektur lengkap sistem HIDRA: matriks fitur lima blok menyalurkan jalur *ensemble* GBDT, pasangan teks mentah menyalurkan jalur *cross encoder* BiGRU, dan keluaran keduanya digabung melalui kalibrasi serta ambang keputusan yang ditentukan dari prediksi luar lipatan.

kandidat diberi bobot $\text{tf}(x)/(1 + |\text{idf}(x) - \text{idf}(w)|)$ agar entitas pengganti mempertahankan profil frekuensi-dokumen yang serupa dengan kata aslinya. Resep PAIR mengambil judul dari artikel lain dengan kemiripan kosinus TF-IDF tertinggi terhadap isi yang sama (dua kandidat teratas di luar grup sendiri), menghasilkan pasangan yang sulit secara konstruksi karena membahas topik serupa. Untuk setiap baris, resep diurutkan secara acak tanpa pengembalian sesuai proporsinya, lalu resep pertama yang berhasil mengubah judul dipakai. Generator ini hanya dipakai untuk melatih *cross encoder*, tidak sebagai baris latih GBDT.

F. Strategi Pelatihan dan Inferensi

Determinisme dan Reprodusibilitas. Seluruh sumber keacakan dikunci pada *seed* 42 untuk pembangkit acak Python, NumPy, dan PyTorch, variabel lingkungan PYTHONHASHSEED, serta konfigurasi deterministik CUBLAS. Tiap komponen sub-acak (pembagian lipatan, generator korupsi, inisialisasi bobot) menerima *seed* turunan yang tetap sehingga hasil run dapat direplikasi. Hasil akhir divalidasi formatnya terhadap `sample_submission.csv` sebelum dikumpulkan.

Pelatihan Cross Encoder. Pada tiap lipatan, 15% grup dari data latih lipatan disisihkan sebagai validasi internal untuk seleksi *checkpoint* terbaik berdasarkan AUC. Kelas minoritas diperkaya lewat dua cara, yaitu baris negatif asli direplikasi tiga kali dan 1,5 kali jumlah baris kelas mayoritas dikorupsi menjadi negatif sintesis oleh generator pada bagian sebelumnya. Model dioptimasi dengan AdamW (ℓ_2 10^{-4}), penjadwal laju *OneCycle*, delapan *epoch*, ukuran batch 128, dan pemotongan gradien norm 2, dengan fungsi kerugian entropi silang biner atas logit.

Data Eksternal Single-Pass (NN-EXT). Dataset publik CLICK-ID sebanyak 37.389 artikel (setelah deduplikasi) dipakai sebagai tambahan data latih. Skema *pretrain* lalu *fine-tune* digantikan pelatihan satu tahap. Pasangan natural CLICK-ID dilabeli *Sesuai*, pasangan terkorupsi generator dilabeli *Tidak Sesuai*, lalu keduanya digabung dengan baris latih lipatan lomba dalam satu pelatihan yang sama se-

TABLE I: Konfigurasi hyperparameter utama.

Komponen	Hyperparameter	Nilai
LightGBM	laju / daun / iterasi	0,02 / 63 / 6000
XGBoost	laju / kedalaman / iterasi	0,02 / 7 / 6000
CatBoost	laju / kedalaman / iterasi	0,03 / 7 / 6000
GBDT (bersama)	colsample / subsample / λ	0,6 / 0,85 / 2,0
BiGRU	emb / tersembunyi	200 / 160
BiGRU	potong judul / isi	24 / 200 token
BiGRU	epoch / batch / lr	8 / 128 / 2×10^{-3}
NN-EXT	lr	8×10^{-4}
Word2Vec	dimensi / jendela / epoch	150 / 6 / 6

hingga tidak ada bobot yang berpindah antar tahap. Kosakata dibentuk dari gabungan data latih lomba dan data eksternal tanpa menyentuh data uji.

Pelatihan Ensemble GBDT. Golongan pertama dilatih per anggota dengan lima lipatan *StratifiedGroupKFold* dan *early stopping* 250 iterasi pada metrik AUC lipatan validasi. Tabel I merangkum konfigurasi tiap anggota; keenam anggota dibentuk dari tiga implementasi dan dua *seed* model berbeda.

Penentuan Ambang dan Penggabungan Skor. Prediksi luar lipatan (OOF) kedua golongan menjadi dasar seluruh keputusan akhir. Ambang keputusan dicari dari 900 kandidat kuantil skor OOF pada rentang $[0,0005, 0,75]$ yang memaksimalkan *Macro F1*. Sebelum digabung, tiap sumber skor, baik dari ensemble GBDT, cross encoder dengan data eksternal (NN-EXT), maupun dari cross encoder tanpa data eksternal, dikalibrasi ke ruang probabilitas yang sama melalui *Platt scaling*, yaitu regresi logistik satu dimensi yang dipaskan pada OOF [27]. Bobot penggabungan $w = (0,70; 0,20; 0,10)$ diperoleh dari pencarian *coordinate descent* atas OOF terkalibrasi, kemudian ambang final ditentukan ulang pada gabungan OOF terkalibrasi dengan prosedur yang sama.

Inferensi. Skor data uji dihasilkan dari rata-rata prediksi model tiap lipatan untuk setiap anggota, lalu dirata-ratakan antar anggota, dikalibrasi, dan digabung dengan bobot serta

ambang yang telah ditetapkan, tanpa penyetelan tambahan apa pun terhadap data uji. Baris berlabel *Tidak Sesuai* adalah baris dengan skor gabungan di bawah ambang. Hasil prediksi ditulis ke `submission.csv` dengan format identifier string `teXXXXXX` dan dua kolom `id,label` yang sesuai `sample_submission.csv`.

IV. EKSPERIMEN DAN HASIL

A. Rancangan Eksperimen

Seluruh evaluasi dilakukan pada data latih melalui prediksi luar lipatan (OOF) dari lima lipatan *StratifiedGroupKFold* dengan *seed* 42, sehingga setiap angka yang dilaporkan berasal dari baris yang tidak pernah dilihat model saat pelatihan. Metrik utama adalah *Macro F1* sesuai ketentuan kompetisi, dengan AUC sebagai metrik sekunder yang tidak bergantung pada ambang keputusan. Sebagai acuan bawah, baseline naif yang selalu memprediksi *Sesuai* hanya mencapai *Macro F1* 0,4737, sehingga setiap perbaikan di atas nilai tersebut harus berasal dari kemampuan model mengenali kelas minoritas, bukan sekadar mengikuti distribusi kelas.

Eksperimen berjalan pada Python 3.11 dengan scikit-learn 1.7, LightGBM 4.6, XGBoost 3.2, CatBoost 1.2, gensim 4.4, dan PyTorch 2.9 (CUDA) pada GPU NVIDIA RTX 3050 dan CPU delapan utas. Pembangunan sumber daya korpus memakan 267 detik, keseluruhan lima blok fitur untuk 18.000 baris selesai dalam total 573 detik, pelatihan cross encoder tanpa data eksternal memakan sekitar 366 detik untuk lima lipatan, dan varian NN-EXT dengan 74.778 pasangan latih tambahan memakan sekitar 2.056 detik. Ini menegaskan bahwa seluruh sistem tetap moderat secara komputasi.

B. Karakteristik Data dan Implikasinya

Analisis eksplorasi mengonfirmasi tiga karakteristik yang membentuk rancangan pada Bagian IV. Pertama, distribusi kelas timpang 9,02 banding satu (12.960 berlabel *Sesuai*, 1.437 *Tidak Sesuai*) sehingga akurasi tidak lagi informatif dan optimasi harus langsung menarget *Macro F1*. Kedua, seperti ditunjukkan Gambar 3, rerata *overlap* leksikal kelas *Sesuai* (0,796) dan *Tidak Sesuai* (0,749) nyaris tidak terpisahkan; 954 baris negatif (66,4%) justru memiliki *overlap* di atas 0,7. Hal ini membuktikan bahwa pendekatan kemiripan kata sederhana akan gagal pada mayoritas kasus sulit dan menjadi justifikasi utama bagi fitur penyelarasan, pemerinkatan rival, dan *cross encoder*. Ketiga, sebanyak 44,5% isi dipakai oleh lebih dari satu judul dan hanya terdapat 3 pasangan duplikat persis, kondisi yang menjadi dasar kuat perbandingan berpasangan. Dengan demikian, keputusan kesesuaian sebaiknya tidak diambil secara mutlak, melainkan dibandingkan terhadap judul-judul rival yang memperebutkan isi yang sama.

C. Hasil Komponen Model

Tabel II merangkum kinerja tiap komponen pada OOF. Jalur neural dilaporkan hanya pada AUC karena perannya bukan pengambil keputusan mandiri, melainkan penyumbang fitur skor (`nn_gru400` dan `nn2_c`) bagi ensemble GBDT.

Tiga pola terbaca dari hasil tersebut. Pertama, rata-rata keenam anggota GBDT (AUC 0,9504) stabil melam-




Fig. 3: Distribusi *overlap* leksikal judul terhadap isi per kelas. Garis putus-putus menandai rerata tiap kelas (0,796 vs 0,749). Dua distribusi saling tumpang-tindih pada daerah 0,7–0,9 tempat mayoritas negatif sulit berada, sehingga kemiripan kata saja tidak memadai sebagai pembeda kelas.

TABLE II: Hasil evaluasi OOF tiap komponen dan gabungan final. Ambang dilaporkan untuk komponen yang menjadi pengambil keputusan.

Komponen	AUC	<i>Macro F1</i>	Ambang
LightGBM <i>seed</i> 0	0,9475	0,8682	0,5882
LightGBM <i>seed</i> 1	0,9437	0,8693	0,6397
XGBoost <i>seed</i> 0	0,9446	0,8666	0,6391
XGBoost <i>seed</i> 1	0,9422	0,8690	0,7266
CatBoost <i>seed</i> 0	0,9487	0,8671	0,6793
CatBoost <i>seed</i> 1	0,9502	0,8753	0,6474
Cross encoder BiGRU	0,7164	–	–
NN-EXT (+CLICK-ID)	0,7398	–	–
Rerata ensemble GBDT	0,9504	0,8728	0,6372
Blend final terkalibrasi	–	–	0,7675

paui hampir seluruh anggota individualnya. Ia hanya dapat dikalahkan secara tipis oleh CatBoost *seed* 1 pada *Macro F1* (0,8753) namun unggul pada AUC. Ini konsisten dengan premis keragaman pada Bagian IV bahwa galat antar-anggota tidak berkorelasi sempurna sehingga perataan menekan variansi. Kedua, ambang optimal tiap anggota berpecah antara 0,59 hingga 0,73, jauh di bawah proporsi kelas mayoritas 0,90. Tanpa penurunan ambang, model akan hampir selalu memprediksi kelas mayoritas dan *F1* kelas minoritas runtuh seperti pada baseline naif. Ketiga, proporsi prediksi negatif pada data uji adalah 7,72% (278 dari 3.603 baris) terhadap proporsi kelas minoritas sebenarnya 9,98%, indikator bahwa ambang blend final berhasil memulihkan sensitivitas kelas minoritas tanpa menenggelamkan presisi.

Dua jalur neural juga saling melengkapi secara terukur. Perhatikan bahwa penambahan data eksternal CLICK-ID menaikkan AUC cross encoder dari 0,7164 menjadi 0,7398. Skor AUC kedua jalur tampak moderat secara mutlak, namun keduanya dikonsumsi sebagai fitur oleh GBDT sehingga yang dibutuhkan bukan kinerja tertinggi melainkan sinyal yang berbeda dari fitur tabular.

Pemisahan audit *bebas vs berkembaran* memberikan bukti langsung peran blok DUP/NDP. Dapat terlihat bahwa skor AUC pada 9.120 baris yang isinya tidak dipakai judul lain adalah 0,8469, sementara pada baris berkembaran mencapai 0,9920. Selisih yang besar ini menunjukkan bahwa ketika struktur korpus memungkinkan perbandingan antar-judul rival. Sistem secara praktis dapat mengenali ketidaksesuaian secara hampir sempurna dan sebagian besar kekukuhan sistem justru berasal dari mekanisme perbandingan berpasangan.

D. Analisis Komponen dan Ablasi

Pada konfigurasi final, presisi kelas Tidak Sesuai mencapai 0,7602 dengan recall 0,7543, sementara kelas Sesuai mencapai presisi 0,9728 dan recall 0,9736 dengan akurasi keseluruhan 0,9517. Dari 1.437 negatif asli, 1.083 berhasil dideteksi. Analisis per subset memperlihatkan letak kesulitan yang tersisa. Pada 954 negatif ber-*overlap* tinggi, *Macro F1* subset hanya mendapatkan skor 0,4267 dan pada 278 positif ber-*overlap* rendah, model hanya mendapatkan skor 0,4674. Dengan kata lain, kesalahan terkonsentrasi hampir seluruhnya pada segmen yang distribusi leksikalnya melawan labelnya, persis seperti batas atas kemampuan sistem jika tanpa menggunakan bobot pralatih.

Beberapa keputusan desain terkonfirmasi penting melalui pengamatan selama pengembangan. Potongan isi 200 token konsisten antara pelatihan dan inferensi terbukti krusial. Varian yang memakai 400 token pada pelatihan menurunkan kualitas OOF, sehingga konsistensi ruang input lebih bernilai daripada cakupan konteks yang lebih panjang. Generator korupsi sintesis berperan ganda, yaitu untuk memperkaya kelas minoritas dan menanamkan sensitivitas terhadap tipologi kesalahan nyata (seperti pertukaran entitas, negasi, permutasi) yang tidak cukup terwakili 1.437 contoh asli. Kalibrasi Platt sebelum *blending* juga diperlukan karena tiga sumber skor berada pada ruang berbeda yang berasal dari probabilitas terkalibrasi GBDT, sigmoid cross encoder tanpa data eksternal, dan sigmoid NN-EXT. Tanpa penyamaan skala, bobot w dapat kehilangan makna sehingga perlu untuk disetarakan.

Dari sisi kesalahan, contoh Tidak Sesuai yang melompat topik relatif mudah dikenali karena margin temu kembali dan fitur dukungan langsung bernilai negatif. Kesalahan yang tersisa terkonsentrasi pada negatif sulit yang hanya berbeda pada satu tokoh, satu angka, atau satu konteks peristiwa. Segmen yang ditarget adalah blok ALG, fitur *cloze*, dan *cross encoder*, namun kedepannya perluasan dari segmen-segmen ini bisa menjadi ruang terbuka bagi pengembangan berikutnya.

V. KESIMPULAN

Penelitian ini membangun HIDRA, sistem deteksi ketidaksesuaian judul dan isi berita Indonesia yang sepenuhnya dilatih dari awal tanpa bobot pralatih, sesuai ketentuan kompetisi. Sistem menggabungkan 264 fitur tabular lima blok terdiri dari semantik dasar, penyelarasan monoton, temu kembali, perbandingan rival berpasangan, dan leksikon eksternal dengan dua jalur *cross encoder* BiGRU yang diperkaya generator korupsi sintesis tujuh resep, lalu

dipersatukan melalui kalibrasi Platt, pembobotan *blend*, dan ambang keputusan yang seluruhnya ditentukan dari prediksi luar lipatan. Pada validasi OOF, sistem mencapai *Macro F1* 0,8728 dan AUC 0,9504 yang merupakan peningkatan besar dari baseline naif dengan skor 0,4737 dengan presisi dan recall kelas minoritas yang berimbang (0,7602 dan 0,7543) serta proporsi prediksi negatif pada data uji (7,72%) yang mendekati distribusi sebenarnya (9,98%).

Empat temuan utama dapat ditarik. Pertama, pada dataset dengan rerata *overlap* kedua kelas yang nyaris identik (0,796 vs 0,749), keputusan kesesuaian lebih efektif diambil secara *komparatif*, yaitu dengan menimbang judul terhadap rival-rival yang memperebutkan isi yang sama. Buktinya, AUC pada baris berkembaran mencapai 0,9920. Kedua, korupsi sintesis terkendali yang meniru tipologi kesalahan nyata terbukti menjadi pengganti yang efektif bagi data kelas minoritas yang langka sekaligus bagi representasi pralatih yang dilarang, terlihat dari kontribusi positif kedua jalur neural sebagai fitur skor. Ketiga, validasi berkelompok wajib pada korpus berita yang 44,5% isinya dipakai lintas judul. Tanpa pembatasan grup, skor validasi mengukur kemampuan menghafal alih-alih menggeneralisasi. Keempat, dua golongan model terbukti komplementer. GBDT menangkap sinyal struktural eksplisit hasil rekayasa fitur, sedangkan *cross encoder* menangkap interaksi urutan dan negasi yang lolos dari fitur tabular.

A. Rekomendasi Strategis

Temuan di atas diterjemahkan ke dalam tiga rekomendasi aplikatif. Bagi redaksi media, sistem ini layak ditempatkan sebagai penyaring pra-publikasi. Artikel dengan skor gabungan di bawah ambang, misal secara kasar sekitar 8% dari total artikel, itu ditandai untuk peninjauan manusia sebelum judul diterbitkan, menjadikan proses kurasi lebih efisien daripada pemeriksaan menyeluruh tanpa memindahkan keputusan editorial dari manusia. Bagi platform dan regulator, skor ketidaksesuaian dapat menjadi sinyal pemeringkat prioritas moderasi konten, khususnya pada isu sensitif seperti SARA dan kesehatan publik yang didominasi dataset ini, agar kapasitas verifikasi terbatas tercurah pada konten berisiko tertinggi. Bagi pengembang, seluruh pipeline selesai dalam hitungan puluhan menit pada GPU kelas laptop dengan pembuatan fitur di bawah sepuluh menit, sehingga biaya integrasi rendah. Akan tetapi, perlu diingat bahwa model dilatih pada korpus berita Indonesia yang didominasi topik pandemi, belum diuji lintas domain, dan secara desain hanya menilai kesesuaian judul dengan isi, bukan kebenaran faktual isi itu sendiri.

Pengembangan lebih lanjut dari penelitian ini mencakup perluasan tipologi korupsi sintesis dari data kesalahan dunia nyata, evaluasi lintas dataset untuk mengukur generalisasi lintas domain, serta *distillasi ensemble* menjadi model tunggal yang lebih ringan untuk inferensi waktu-nyata. Dengan tetap berpatok pada aturan latihan dari awal, arah tersebut dapat ditempuh tanpa bergantung pada bobot pralatih apapun.

REFERENCES

- [1] S. Chesney, M. Liakata, M. Poesio, and M. Purver, "Incongruent headlines: Yet another way to mislead your readers," in *Proc. Workshop on Natural Language Processing meets Journalism*, Copenhagen, Denmark, 2017, pp. 56–61. [Online]. Available: <https://doi.org/10.18653/v1/W17-4210>
- [2] Asosiasi Penyelenggara Jasa Internet Indonesia, "Survei penetrasi internet Indonesia 2024," APJII, Jakarta, Indonesia, Jan. 2024. [Online]. Available: <https://apjii.or.id/berita/d/apjii-jumlah-pengguna-internet-indonesia-tembus-221-juta-orang>
- [3] M. Gabielkov, A. Ramachandran, A. Chaintreau, and A. Legout, "Social clicks: What and who gets read on Twitter?" in *Proc. ACM SIGMETRICS Int. Conf. Meas. Model. Comput. Syst.*, Antibes Juan-les-Pins, France, 2016, pp. 179–192. [Online]. Available: <https://doi.org/10.1145/2964791.2901462>
- [4] N. A. Prathama, M. J. R. Hasani, and M. I. Akbar, "SARA hoax: Phenomena, meaning, and conflict management," *Jurnal ASPIKOM*, vol. 7, no. 2, 2022. [Online]. Available: <http://dx.doi.org/10.24329/aspikom.v7i2.1117>
- [5] S. Yoon, K. Park, M. Lee, T. Kim, M. Cha, and K. Jung, "Learning to detect incongruence in news headline and body text via a graph neural network," *IEEE Access*, vol. 9, pp. 36195–36206, 2021. [Online]. Available: <https://doi.org/10.1109/ACCESS.2021.3062029>
- [6] P. Bourgonje, J. M. Schneider, and G. Rehm, "From clickbait to fake news detection: An approach based on detecting the stance of headlines to articles," in *Proc. Workshop on Natural Language Processing meets Journalism*, Copenhagen, Denmark, 2017, pp. 87–92. [Online]. Available: <https://aclanthology.org/W17-4215/>
- [7] A. William and Y. Sari, "CLICK-ID: A novel dataset for Indonesian clickbait headlines," *Data in Brief*, vol. 32, Art. no. 106231, Oct. 2020. [Online]. Available: <https://doi.org/10.1016/j.dib.2020.106231>
- [8] D. F. Suriyanto and D. A. Adnas, "Ensemble-based clickbait detection in Indonesian online news," *J. Embedded Syst. Secur. Intell. Syst.*, vol. 6, no. 4, pp. 690–704, Jan. 2026. [Online]. Available: <https://doi.org/10.59562/jessi.v6i4.11251>
- [9] B. Riedel, I. Augenstein, G. Spithourakis, and S. Riedel, "A simple but tough-to-beat baseline for the Fake News Challenge stance detection task," *arXiv preprint arXiv:1707.03264*, Jul. 2017. [Online]. Available: <https://doi.org/10.48550/arXiv.1707.03264>
- [10] S. Yoon, K. Park, J. Shin, H. Lim, S. Won, M. Cha, and K. Jung, "Detecting incongruity between news headline and body text via a deep hierarchical encoder," in *Proc. AAAI Conf. Artif. Intell.*, Honolulu, HI, USA, 2019, pp. 7917–7924. [Online]. Available: <https://doi.org/10.1609/aaai.v33i01.33017917>
- [11] R. Mishra, P. Yadav, R. Calizzano, and M. Leippold, "MuSeM: Detecting incongruent news headlines using mutual attentive semantic matching," in *Proc. IEEE Int. Conf. Mach. Learn. Appl. (ICMLA)*, Miami, FL, USA, 2020, pp. 687–692. [Online]. Available: <https://doi.org/10.1109/ICMLA51294.2020.00116>
- [12] M. A. Afif, M. Ula, L. Rosnita, and Rizal, "Applying TF-IDF and K-NN for clickbait detection in Indonesian online news headlines," *J. Adv. Comput. Knowl. Algorithms*, vol. 1, no. 2, pp. 38–41, Apr. 2024. [Online]. Available: <https://doi.org/10.29103/jacka.v1i2.15810>
- [13] Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *IPM*, 24(5), 513-523.
- [14] Harris, Z.S. (1954). Distributional structure. *Word*, 10(2-3), 146-162.
- [15] Mikolov et al. (2013). Efficient estimation of word representations in vector space. *arXiv:1301.3781*.
- [16] Church, K.W., & Hanks, P. (1990). Word association norms, mutual information, and lexicography. *Comp. Ling.*, 16(1), 22-29.
- [17] Needleman & Wunsch (1970). A general method applicable to similarities in amino acid sequence. *JMB*, 48(3), 443-453.
- [18] Kendall, M.G. (1938). A new measure of rank correlation. *Biometrika*, 30(1/2), 81-93.
- [19] Liu, T.Y. (2009). Learning to rank for information retrieval. *FnTIR*, 3(3), 225-331.
- [20] Thurstone, L.L. (1927). A law of comparative judgment. *Psych. Review*, 34(4), 273-286.
- [21] Cho et al. (2014). Learning phrase representations using RNN encoder-decoder. *EMNLP*.
- [22] Bahdanau, Cho, & Bengio (2014). Neural machine translation by jointly learning to align and translate. *arXiv:1409.0473*.
- [23] Chen et al. (2017). Enhanced LSTM for natural language inference. *ACL*.
- [24] Vincent et al. (2008). Extracting and composing robust features with denoising autoencoders. *ICML*.
- [25] Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM TKDD*, 6(4), 1-21.
- [26] Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *IJCAI*.
- [27] J. C. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," in *Advances in Large Margin Classifiers*, Cambridge, MA, USA: MIT Press, 2000.