

Prediksi Kategori Kualitas Udara Jakarta Menggunakan *Ensemble Learning* dengan Integrasi Pengetahuan Domain

Tim NeedNamaTim - Kompetisi Datavidia 10.0

Zaky Muhammad Fauzi
School of Computing
Telkom University
Bandung, Indonesia
zakyfarhan1326@gmail.com

Syauqi Gathan Setyapratama
School of Computing
Telkom University
Bandung, Indonesia
gathan.sp@gmail.com

Ghifary Wibisono
School of Computing
Telkom University
Bandung, Indonesia
ghifarywibisono1@gmail.com

Ringkasan—Polusi udara di DKI Jakarta telah menjadi permasalahan kritis yang berdampak pada kesehatan masyarakat dan keberlanjutan lingkungan. Penelitian ini mengembangkan sistem prediksi kategori Indeks Standar Pencemar Udara (ISPU) menggunakan pendekatan *ensemble learning* yang mengintegrasikan tiga algoritma *gradient boosting*: XGBoost, LightGBM, dan CatBoost. Model dikembangkan dengan pembobotan berbasis performa *cross-validation*, di mana CatBoost memperoleh bobot tertinggi (50%) berdasarkan *Mean Absolute Error* terendah karena keunggulannya dalam *robustness* terhadap *overfitting* dan penanganan fitur kategorikal. Sistem ini menggabungkan 11 fitur per polutan yang mencakup aspek temporal, meteorologis, serta statistik *time series*, ditambah dengan heuristik berbasis pengetahuan domain yang menangkap dinamika temporal dan anomali musiman. Evaluasi menggunakan *5-fold cross-validation* menunjukkan performa model yang konsisten dengan rata-rata MAE 6.51 untuk CatBoost. Pada *public leaderboard* kompetisi dengan 30% data uji, sistem mencapai *Macro F1-Score* sebesar 0.92951.

Index Terms—kualitas udara, ISPU, *ensemble learning*, XGBoost, LightGBM, CatBoost, prediksi polusi, Jakarta, *time series*

I. PENDAHULUAN

A. Latar Belakang

Penurunan kualitas udara di wilayah metropolitan DKI Jakarta telah menjadi isu lingkungan yang mendesak untuk ditangani. Laporan secara konsisten menempatkan Jakarta sebagai salah satu kota dengan tingkat polusi udara tertinggi di dunia [1], di mana konsentrasi berbagai polutan seperti PM_{2.5}, PM₁₀, SO₂, CO, O₃, dan NO₂ seringkali melampaui ambang batas aman yang ditetapkan oleh Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) serta pedoman Organisasi Kesehatan Dunia (WHO).

Dampak dari polusi udara ini tidak hanya terbatas pada gangguan kesehatan pernapasan masyarakat, tetapi juga mencakup berbagai efek sistemik yang mempengaruhi produktivitas ekonomi dan kualitas hidup secara keseluruhan. Studi epidemiologis menunjukkan bahwa paparan jangka panjang terhadap polutan udara berkontribusi signifikan terhadap peningkatan kasus penyakit kardiovaskular (risiko relatif 1.11 per

10 $\mu\text{g}/\text{m}^3$ peningkatan PM_{2.5}), gangguan perkembangan anak termasuk penurunan fungsi paru hingga 20% pada paparan kronis, dan penurunan fungsi kognitif terutama pada populasi rentan seperti anak-anak dan lansia [13]. Estimasi biaya ekonomi dari polusi udara Jakarta mencapai lebih dari 5.2 triliun rupiah per tahun akibat hilangnya hari kerja produktif, biaya pengobatan, dan kematian prematur.

Kompleksitas dinamika kualitas udara di Jakarta dipengaruhi oleh berbagai faktor multidimensi yang saling berinteraksi secara non-linear. Kontributor utama meliputi: (1) **Emisi kendaraan bermotor** yang merupakan sumber terbesar dengan estimasi 75% dari total polusi udara, dengan 20+ juta kendaraan beroperasi setiap hari dan volume lalu lintas mencapai puncak pada jam sibuk pagi (07:00-09:00) dan sore (17:00-19:00), (2) **Aktivitas industri** di kawasan sekitar Jakarta yang berkontribusi 15% terutama untuk SO₂ dan emisi partikulat dari proses pembakaran dan manufaktur, (3) **Kondisi meteorologis** seperti curah hujan yang dapat menurunkan konsentrasi PM_{2.5} hingga 38% melalui efek *wet deposition* dan kecepatan angin yang memfasilitasi dispersi polutan dengan efek maksimal pada kecepatan > 15 km/h, (4) **Pola aktivitas manusia** yang berbeda antara hari kerja (aktivitas tinggi) dan akhir pekan (reduksi lalu lintas hingga 22%), serta (5) **Karakteristik geografis** termasuk topografi cekungan Jakarta yang membatasi dispersi polutan vertikal terutama pada kondisi inversi termal, serta variasi iklim mikro antar wilayah seperti efek *urban heat island* yang mengintensifikasi akumulasi polutan di pusat kota.

Variabilitas temporal menunjukkan pola yang konsisten: musim kemarau (Juni-Oktober) dicirikan oleh konsentrasi polutan 40-50% lebih tinggi dibandingkan musim hujan (November-Maret), dengan puncak tertinggi terjadi pada September-Oktober ketika curah hujan minimal dan kelembaban rendah. Variabilitas spasial juga signifikan, dengan stasiun pemantau di kawasan padat lalu lintas (Kebon Jeruk, Jagakarsa) menunjukkan konsentrasi PM_{2.5} rata-rata 45-49 $\mu\text{g}/\text{m}^3$, sementara stasiun di kawasan terbuka (Bundaran HI)

atau dekat pantai (Kelapa Gading) menunjukkan nilai lebih rendah 33-37 $\mu\text{g}/\text{m}^3$.

B. Permasalahan

Prediksi kategori Indeks Standar Pencemar Udara (ISPU) menghadapi beberapa tantangan teknis yang signifikan:

Pertama, distribusi data yang tidak seimbang (*imbalanced dataset*) menjadi kendala utama, di mana kategori ekstrem seperti "TIDAK SEHAT" muncul dengan frekuensi yang jauh lebih rendah dibandingkan kategori "BAIK" atau "SEDANG". Dalam *dataset training*, distribusi kategori menunjukkan proporsi sekitar 42% BAIK, 45% SEDANG, dan hanya 13% TIDAK SEHAT, namun deteksi akurat terhadap kategori ekstrem ini sangat krusial untuk sistem peringatan dini.

Kedua, hubungan non-linear yang kompleks antara berbagai polutan dan faktor meteorologis memerlukan pendekatan pemodelan yang mampu menangkap interaksi multivariat secara efektif. Korelasi antar polutan bervariasi dari 0.35 hingga 0.87, mengindikasikan *dependencies* yang perlu dimodelkan dengan tepat.

Ketiga, variabilitas temporal yang tinggi, termasuk pola musiman yang konsisten pada periode September-November dengan perbedaan konsentrasi mencapai 60% antara puncak kemarau dan awal musim hujan, menambah kompleksitas dalam pengembangan model prediktif yang *robust*.

Keempat, perbedaan karakteristik antar stasiun pemantau (SPKU) memerlukan strategi pemodelan yang dapat mengakomodasi variasi spasial dalam konsentrasi polutan. Variasi antar stasiun dapat mencapai 40% untuk polutan yang sama.

Kelima, integrasi data dari berbagai sumber dengan kualitas dan kelengkapan yang bervariasi menuntut teknik *preprocessing* dan imputasi yang tepat. Proporsi *missing values* berkisar antara 2% hingga 15% tergantung polutan dan periode.

C. Tujuan dan Kontribusi

Penelitian ini bertujuan untuk mengembangkan sistem prediksi kategori ISPU yang akurat dan dapat diandalkan melalui pendekatan *ensemble learning* yang mengintegrasikan pengetahuan domain. Kontribusi utama penelitian ini meliputi:

- Pengembangan arsitektur *ensemble* berbasis tiga algoritma *gradient boosting* (XGBoost, LightGBM, CatBoost) dengan pembobotan adaptif (0.3:0.2:0.5) berdasarkan evaluasi *cross-validation*
- Rekayasa fitur komprehensif yang menggabungkan aspek temporal, meteorologis, dan statistik *time series* dengan total 11 fitur per polutan
- Integrasi heuristik berbasis pengetahuan domain yang menangkap dinamika temporal dan anomali musiman
- Evaluasi sistematis menggunakan *5-fold cross-validation* untuk memastikan generalisasi model
- Pendekatan pemodelan spesifik-stasiun yang mengakomodasi variasi spasial kualitas udara

Hasil penelitian ini diharapkan dapat berkontribusi pada pengembangan sistem peringatan dini yang lebih efektif serta mendukung pengambilan keputusan dalam tata kelola kualitas udara di DKI Jakarta.

II. LANDASAN TEORI

A. Indeks Standar Pencemar Udara (ISPU)

ISPU merupakan indeks yang digunakan untuk mengkomunikasikan tingkat pencemaran udara kepada masyarakat. Sistem kategori ISPU terbagi menjadi beberapa tingkatan berdasarkan konsentrasi polutan, dengan ambang batas yang telah ditetapkan oleh regulasi nasional. Untuk keperluan penelitian ini, kategori disederhanakan menjadi tiga kelas utama: BAIK ($\text{ISPU} \leq 50$), SEDANG ($50 < \text{ISPU} \leq 100$), dan TIDAK SEHAT ($\text{ISPU} > 100$).

Penghitungan ISPU menggunakan formula konversi yang memetakan konsentrasi polutan (C_p) ke nilai indeks (I) melalui interpolasi linear:

$$I = \frac{I_{hi} - I_{lo}}{C_{hi} - C_{lo}} (C_p - C_{lo}) + I_{lo} \quad (1)$$

di mana I_{hi} dan I_{lo} adalah batas atas dan bawah indeks untuk kategori tertentu, sementara C_{hi} dan C_{lo} adalah batas konsentrasi yang bersesuaian.

B. Algoritma Gradient Boosting

Gradient boosting merupakan teknik *ensemble learning* yang membangun model prediktif secara sekuensial, di mana setiap model baru berupaya memperbaiki kesalahan model sebelumnya [3]. Prinsip dasar *gradient boosting* dapat diformulasikan sebagai optimisasi *additive model*:

$$F_m(x) = F_{m-1}(x) + \nu h_m(x) \quad (2)$$

di mana F_m adalah model *ensemble* pada iterasi ke- m , h_m adalah *base learner* baru, dan ν adalah *learning rate*.

Penelitian ini mengimplementasikan tiga varian *gradient boosting* yang telah terbukti efektif dalam berbagai aplikasi:

1) **XGBoost: Extreme Gradient Boosting** (XGBoost) [5] merupakan implementasi efisien dari *gradient boosting* yang menggunakan regularisasi untuk mencegah *overfitting*. Fungsi obyektif XGBoost menggabungkan *loss function* dengan *regularization term*:

$$\mathcal{L} = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k) \quad (3)$$

di mana $\Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$, dengan T adalah jumlah *leaves*, w adalah *leaf weights*, γ dan λ adalah *hyperparameter* regularisasi.

2) **LightGBM: Light Gradient Boosting Machine** (LightGBM) [6] menggunakan dua teknik inovatif untuk meningkatkan efisiensi: *Gradient-based One-Side Sampling* (GOSS) yang mempertahankan *instances* dengan *gradient* besar sambil melakukan *random sampling* pada *instances* dengan *gradient* kecil, dan *Exclusive Feature Bundling* (EFB) yang menggabungkan fitur-fitur yang *mutually exclusive* untuk mengurangi dimensionalitas *feature space*.

3) *CatBoost*: CatBoost [7] mengimplementasikan teknik *ordered boosting* yang mengatasi *prediction shift problem* pada *categorical feature encoding*. Algoritma ini menggunakan *ordered target statistics* untuk *encoding* fitur kategorikal:

$$\hat{x}_k^i = \frac{\sum_{j=1}^{p-1} [x_j^k = x_p^k] \cdot y_j + a \cdot P}{\sum_{j=1}^{p-1} [x_j^k = x_p^k] + a} \quad (4)$$

Keunggulan utama CatBoost terletak pada *robustness* terhadap *overfitting* dan kemampuan superior dalam menangani fitur kategorikal tanpa memerlukan *preprocessing* ekstensif.

C. Ensemble Learning

Ensemble learning menggabungkan prediksi dari beberapa model untuk meningkatkan performa keseluruhan [9]. Penelitian ini menggunakan pendekatan *weighted averaging* di mana bobot setiap model ditentukan berdasarkan performanya pada *validation set*. Untuk K model dasar, prediksi *ensemble* dihitung sebagai:

$$\hat{y}_{ensemble} = \sum_{k=1}^K w_k \hat{y}_k, \quad \text{dengan} \quad \sum_{k=1}^K w_k = 1 \quad (5)$$

D. Cross-Validation

K-fold cross-validation merupakan teknik evaluasi model yang membagi *dataset* menjadi K bagian (*folds*), di mana model dilatih pada $K - 1$ bagian dan dievaluasi pada satu bagian sisanya [9]. Estimator error rata-rata adalah:

$$E_{CV} = \frac{1}{K} \sum_{i=1}^K E_i \quad (6)$$

di mana E_i adalah error pada *fold* ke- i .

III. METODE ANALISIS

A. Dataset dan Preprocessing

1) *Sumber Data*: *Dataset* penelitian ini terdiri dari dua sumber utama dengan total lebih dari 45.000 rekaman:

- **Data ISPU**: *Dataset* historis Indeks Standar Pencemar Udara dari 5 stasiun pemantau (SPKU) di DKI Jakarta (DKI1-DKI5) yang mencakup konsentrasi 6 polutan utama: PM2.5, PM10, SO₂, CO, O₃, dan NO₂ dari tahun 2010 hingga 2025 [1]
- **Data Cuaca**: *Dataset* meteorologis harian yang mencakup curah hujan dalam mm dan kecepatan angin maksimal dalam km/h untuk setiap stasiun dari tahun 2010-2025

2) *Standardisasi dan Pembersihan Data*: Proses standarisasi mengatasi inkonsistensi penamaan stasiun (DKI1-DKI5 vs nama lengkap) dengan pemetaan manual tervalidasi koordinat geografis, format tanggal heterogen (DD/MM/YYYY, YYYY-MM-DD) dengan *pandas.to_datetime*, duplikasi 127 rekaman (0.28%), dan *outliers* 0.5% yang dipertahankan setelah validasi dengan kejadian polusi ekstrem historis (misalnya kebakaran hutan September 2019).

3) *Imputasi Missing Values*: *Missing values* bervariasi per polutan: PM2.5 (2.3%), PM10 (3.1%), SO₂ (8.7%), CO (5.4%), O₃ (12.6%), NO₂ (6.8%). Pola temporal menunjukkan tingkat lebih tinggi pada 2010-2012 (15-20%) karena keterbatasan infrastruktur awal. Strategi bertingkat diimplementasikan:

- 1) **Interpolasi Linear** (3 hari, 87% kasus): MAE interpolasi vs aktual 4.2 $\mu\text{g}/\text{m}^3$
- 2) **Forward Fill** (4-7 hari, 9%): Memanfaatkan autokorelasi lag-1 rata-rata 0.65
- 3) **Backward Fill**: Kasus khusus *missing* awal periode
- 4) **Median Stasiun-Bulan** (>7 hari, 4%): *Robust* terhadap *outliers*


Validasi Kolmogorov-Smirnov: semua polutan $p > 0.05$, mengonfirmasi distribusi terimputasi tidak berbeda signifikan dari observasi.

B. Analisis Eksploratif Data


Analisis eksploratif dilakukan untuk memahami karakteristik dan pola dalam data, mengidentifikasi hubungan antar variabel, dan menginformasikan strategi pemodelan.

1) *Distribusi Polutan*: Distribusi konsentrasi menunjukkan karakteristik yang berbeda untuk masing-masing polutan:


- **PM2.5**: Distribusi condong kanan (*right-skewed*) dengan median 35.2 $\mu\text{g}/\text{m}^3$ dan rata-rata 42.8 $\mu\text{g}/\text{m}^3$
- **PM10**: Pola serupa PM2.5 dengan kemiringan (*skewness*) lebih tinggi, median 52.1 $\mu\text{g}/\text{m}^3$
- **SO₂**: Distribusi paling terkonsentrasi dengan 85% nilai < 20 $\mu\text{g}/\text{m}^3$
- **CO**: Distribusi bimodal dengan puncak pada 3-5 mg/m^3 dan 8-10 mg/m^3
- **O₃**: Distribusi mendekati normal terpusat di sekitar 40 $\mu\text{g}/\text{m}^3$
- **NO₂**: Kemiringan moderat dengan median 28.5 $\mu\text{g}/\text{m}^3$




Gambar 1. Distribusi konsentrasi PM2.5 menunjukkan pola *right-skewed* dengan beberapa *outliers* ekstrem.




Gambar 2. Distribusi konsentrasi PM10 dengan karakteristik serupa PM2.5 namun variabilitas lebih tinggi.




Gambar 3. Distribusi SO₂ terkonsentrasi pada nilai rendah, mengindikasikan kontrol industri.



Gambar 4. Distribusi CO menunjukkan pola bimodal mencerminkan kondisi lalu lintas tinggi vs rendah.




Gambar 5. Distribusi O₃ mendekati normal, konsisten dengan karakteristik polutan sekunder.



Gambar 6. Distribusi NO₂ dengan kemiringan moderat, mencerminkan dominansi emisi kendaraan.

2) *Pola Musiman*: Pola musiman yang konsisten dan signifikan secara statistik (ANOVA $p < 0.001$) terobservasi:

- **September-Oktober**: Konsentrasi PM2.5 mencapai rata-rata $58.3 \mu\text{g}/\text{m}^3 (\pm 21.2)$, 47% lebih tinggi dari rata-rata tahunan. Periode ini bertepatan dengan musim kemarau panjang dan curah hujan minimal.
- **November**: Penurunan drastis dengan rata-rata PM2.5 turun ke $25.7 \mu\text{g}/\text{m}^3 (\pm 8.4)$, penurunan 56% dibandingkan Oktober. Ini berkorelasi kuat dengan awal musim hujan (korelasi $r = -0.73$, $p < 0.001$).
- **Desember-Februari**: Mempertahankan level rendah ($28-32 \mu\text{g}/\text{m}^3$) selama puncak musim hujan.
- **Maret-Mei**: Peningkatan bertahap dengan rata-rata $38-42 \mu\text{g}/\text{m}^3$.




Gambar 7. Pola konsentrasi PM2.5 bulanan menunjukkan peningkatan signifikan September-Oktober dan penurunan drastis November dengan *error bars* mewakili ± 1 standar deviasi.

3) *Variasi Harian*: Gambar 8 mendemonstrasikan perbedaan signifikan hari kerja vs akhir pekan:

- **Senin-Jumat**: Rata-rata PM2.5 $40.2-43.5 \mu\text{g}/\text{m}^3$
- **Sabtu**: Transisi dengan $37.8 \mu\text{g}/\text{m}^3$
- **Minggu**: Terendah dengan $34.1 \mu\text{g}/\text{m}^3$, pengurangan 22% vs rata-rata hari kerja

T-test menunjukkan perbedaan Minggu vs hari kerja signifikan ($p < 0.001$), membenarkan faktor penyesuaian akhir pekan dalam aturan domain.


4) *Perbedaan Antar Stasiun*: Gambar 9 mengungkapkan variasi spasial yang substansial:



Gambar 8. Pola hari dalam seminggu mendemonstrasikan pengurangan terkait lalu lintas pada akhir pekan, terutama Minggu.

- **DKI5 (Kebon Jeruk):** Rata-rata tertinggi $48.7 \mu\text{g}/\text{m}^3$, kemungkinan karena kedekatan dengan jalan raya utama
- **DKI3 (Jagakarsa):** $45.2 \mu\text{g}/\text{m}^3$
- **DKI4 (Lubang Buaya):** $42.1 \mu\text{g}/\text{m}^3$
- **DKI1 (Bundaran HI):** $36.8 \mu\text{g}/\text{m}^3$, mendapat manfaat dari ruang terbuka dan ventilasi lebih baik
- **DKI2 (Kelapa Gading):** Terendah $33.5 \mu\text{g}/\text{m}^3$, kedekatan pantai faktor potensial

ANOVA mengonfirmasi perbedaan antar-stasiun yang signifikan ($F=428.3$, $p < 0.001$), mendukung pendekatan pemo-
delan spesifik-stasiun.




Gambar 9. Perbandingan rata-rata PM2.5 antar stasiun dengan error bars. DKI5 konsisten tertinggi, DKI2 konsisten terendah.

5) *Korelasi Polutan:* Gambar 10 mengungkapkan struktur ketergantungan:

- **PM2.5-PM10:** $r = 0.87$, korelasi positif sangat kuat, mengindikasikan sumber umum (lalu lintas, debu)
- **CO-NO₂:** $r = 0.64$, positif kuat, keduanya terutama dari emisi kendaraan
- **PM2.5-NO₂:** $r = 0.58$, positif moderat
- **O₃-NO₂:** $r = -0.42$, korelasi negatif mencerminkan konsumsi fotokimia NO₂ dalam pembentukan O₃
- **O₃-CO:** $r = -0.35$, mekanisme serupa

- **SO₂-Lainnya:** $r = 0.35 - 0.45$, korelasi lebih lemah menunjukkan sumber primer berbeda (industri vs lalu lintas)




Gambar 10. Matriks korelasi mengungkapkan hubungan PM2.5-PM10 yang kuat dan korelasi O₃ negatif dengan polutan primer.

6) *Dampak Cuaca:* Gambar 11 mendemonstrasikan efek curah hujan yang dramatis:

- **Tanpa Hujan:** Rata-rata PM2.5 $45.7 \mu\text{g}/\text{m}^3$
- **Hujan Ringan (0-5mm):** $38.2 \mu\text{g}/\text{m}^3$ (-16%)
- **Hujan Sedang (5-15mm):** $32.1 \mu\text{g}/\text{m}^3$ (-30%)
- **Hujan Lebat (>15mm):** $28.4 \mu\text{g}/\text{m}^3$ (-38%)

Analisis regresi: $\text{PM}_{2.5} = 46.2 - 1.18 \times \text{Hujan}$ ($R^2 = 0.61$, $p < 0.001$). Ambang batas hujan lebat (>15mm) dipilih berdasarkan titik infleksi dalam kurva regresi non-linear.



Gambar 11. Dampak kategorisasi curah hujan pada PM2.5 menunjukkan efek pembersihan yang semakin kuat dengan meningkatnya curah hujan.

C. Rekayasa Fitur

Penelitian ini mengembangkan 11 fitur untuk setiap polutan, yang dikelompokkan menjadi tiga kategori:

1) Fitur Temporal:

- **Month:** Bulan (1-12) untuk menangkap pola musiman, di-encode sebagai ordinal. *Cyclic encoding* (transformasi sin/cos) dipertimbangkan namun menunjukkan peningkatan minimal dalam eksperimen awal ($< 1\%$ reduksi MAE), sehingga *encoding ordinal* sederhana dipertahankan untuk kemudahan interpretasi.
- **Day of Week:** Hari dalam seminggu (0-6) untuk menangkap pola aktivitas mingguan yang signifikan berbeda antara hari kerja dan akhir pekan, sebagaimana divalidasi oleh analisis *t-test* ($p < 0.001$).

2) Fitur Meteorologis:

- **Rain:** Curah hujan harian (mm), variabel kontinu. Menunjukkan korelasi negatif kuat dengan PM2.5 ($r = -0.68$, $p < 0.001$).
- **Wind:** Kecepatan angin maksimal (km/h), variabel kontinu. Efek dispersi polutan dengan korelasi moderat ($r = -0.42$).
- **Rain Lag1, Wind Lag1:** Nilai cuaca hari sebelumnya untuk menangkap efek atmosferik tertunda. *Lag* orde lebih tinggi (*lag2, lag3*) diuji namun dieksklusi untuk menghindari multikolinearitas ($VIF > 5$).

3) *Fitur Time Series:* Untuk setiap polutan P, dihitung per stasiun:

- **P_lag1:** Konsentrasi hari sebelumnya, menangkap persistensi jangka pendek. Autokorelasi tipikal 0.6-0.8 mengindikasikan *dependency* kuat satu hari.
- **P_lag7:** Konsentrasi 7 hari sebelumnya untuk pola mingguan. Autokorelasi 0.3-0.5 menunjukkan periodisitas mingguan moderat.
- **P_roll_mean_7:** Rata-rata bergerak sederhana 7 hari, menghaluskan fluktuasi jangka pendek dan menangkap tren lokal.
- **P_roll_std_7:** Standar deviasi bergerak 7 hari, menangkap volatilitas terkini. Nilai tinggi mengindikasikan periode transisi atau anomali.
- **P_ewm_7:** *Exponentially weighted moving average* ($span=7$), memberikan bobot lebih besar pada nilai terkini ($\alpha = 2/(7 + 1) \approx 0.25$). Lebih responsif terhadap perubahan terkini dibanding rata-rata sederhana.

Total fitur per model: 11 fitur $\times$ 1 polutan target = ruang fitur 11-dimensi, menjadikan model efisien secara komputasi sambil kaya informasi. Analisis VIF mengonfirmasi multikolinearitas rendah (semua $VIF < 3.2$), memvalidasi pemilihan fitur.

D. Arsitektur Model

1) *Strategi Pemodelan Spesifik-Stasiun:* Model dikembangkan secara terpisah untuk setiap stasiun pemantau (DKI1-DKI5). Total model yang dilatih: 5 stasiun $\times$ 6 polutan $\times$ 3 algoritma = 90 model dasar + logika *ensemble*.

2) *Konfigurasi Hyperparameter:* *Hyperparameter* dipilih melalui *grid search* dengan 3-fold CV pada sampel 20%:

Konfigurasi XGBoost:

- **n_estimators:** 500 (dibandingkan dengan alternatif 300/700). Nilai 500 memberikan keseimbangan optimal antara waktu komputasi dan konvergensi model.
- **learning_rate:** 0.05 (dibandingkan dengan 0.01/0.1). *Learning rate* moderat memungkinkan konvergensi stabil tanpa *overfitting*.
- **max_depth:** 5 (dibandingkan dengan 3/7). Kedalaman 5 mencegah model terlalu kompleks sambil menangkap interaksi non-linear penting.
- **subsample:** 0.8 (*row sampling*). Sampling 80% mencegah *overfitting* melalui randomisasi, analogous dengan *bagging*.
- **colsample_bytree:** 0.8 (*column sampling*). Analog dengan *feature bagging* dalam *random forest*.
- **reg_alpha:** 0 (regularisasi L1). Tidak diperlukan untuk *feature space* berukuran moderat.
- **reg_lambda:** 1 (regularisasi L2, nilai *default*). Regularisasi L2 cukup untuk mencegah *overfitting*.

Konfigurasi LightGBM:

- **n_estimators:** 500
- **learning_rate:** 0.05
- **num_leaves:** 31 (nilai *default*, $2^5 - 1$). Jumlah daun dikontrol ketat untuk mencegah pertumbuhan pohon berlebihan.
- **min_child_samples:** 20. Minimal 20 sampel per daun untuk mencegah *overfitting* pada *outliers*.
- **feature_fraction:** 1.0. Menggunakan seluruh fitur karena *feature space* relatif kecil (11 fitur).
- **bagging_fraction:** 1.0. Tidak menggunakan *row sampling* karena *GOSS* sudah menangani sampling instance.

Konfigurasi CatBoost:

- **iterations:** 500
- **learning_rate:** 0.05
- **depth:** 5. Kedalaman pohon dikontrol konsisten dengan XGBoost untuk perbandingan adil.
- **l2_leaf_reg:** 3 (nilai *default*). Regularisasi L2 pada nilai daun.
- **border_count:** 254. Jumlah *split* untuk fitur numerik.
- **grow_policy:** *SymmetricTree*. Pertumbuhan pohon simetris untuk efisiensi komputasi.

Semua model menggunakan *early stopping* berdasarkan *validation loss*, meskipun jumlah iterasi tetap digunakan untuk konsistensi antar *folds*. *Random state* ditetapkan 42 untuk reproduktibilitas.

3) *Strategi Weighted Ensemble:* Prediksi final untuk setiap polutan adalah *weighted average*:

$$\hat{y}_p = 0.3 \cdot \hat{y}_{XGB} + 0.2 \cdot \hat{y}_{LGB} + 0.5 \cdot \hat{y}_{CB} \quad (7)$$

Bobot (0.3:0.2:0.5) ditentukan berdasarkan performa *cross-validation*, di mana CatBoost memperoleh bobot tertinggi karena MAE terendah secara konsisten.

E. Integrasi Pengetahuan Domain

Sistem menerapkan lebih dari 20 heuristik berbasis pengetahuan domain yang diturunkan dari analisis eksploratif dan validasi empiris. Aturan dikelompokkan dalam lima kategori:

1) *Aturan Musiman Spesifik*: Berdasarkan analisis pola bulanan (Gambar 7), aturan musiman diterapkan untuk mengoreksi bias sistematis:

- **Puncak Kemarau (September-Oktober)**: Jika prediksi ISPU < 40 pada bulan 9-10, tingkatkan 15% untuk mengoreksi underprediksi model pada periode polusi tinggi. Validasi: reduksi underprediksi dari 18.3% menjadi 4.2%.
- **Transisi Musim Hujan (November)**: Jika prediksi ISPU > 55 pada November dan curah hujan $> 5\text{mm}$, turunkan 20% untuk merefleksikan pembersihan atmosferik dramatis. Korelasi November: $r = -0.73$ antara rain dan PM2.5.
- **Musim Hujan Puncak (Desember-Februari)**: Terapkan *ceiling* ISPU maksimal 50 jika curah hujan bulanan $> 200\text{mm}$, konsisten dengan observasi historis periode basah.

2) *Aturan Meteorologis*: Efek cuaca dimodelkan eksplisit untuk menangkap proses atmosferik:

- **Hujan Lebat**: Jika curah hujan $> 15\text{mm}$, terapkan *ceiling* ISPU ≤ 45 . Threshold 15mm dipilih dari analisis regresi inflection point ($R^2 = 0.61$).
- **Hujan Sedang**: Untuk $5\text{mm} < \text{rain} \leq 15\text{mm}$, turunkan prediksi ISPU 10% untuk PM2.5 dan PM10 (efek *wet deposition*).
- **Angin Kuat**: Jika kecepatan angin $> 20\text{ km/h}$, turunkan prediksi 8% untuk semua polutan kecuali O_3 (dispersi mekanis).
- **Kondisi Stagnasi**: Jika $\text{rain} < 1\text{mm}$ DAN $\text{wind} < 5\text{ km/h}$, tingkatkan prediksi 12% (akumulasi polutan).
- **Efek Lag Cuaca**: Prediksi hari t dipengaruhi cuaca $t-1$. Jika hujan $> 10\text{mm}$ pada $t-1$, turunkan prediksi t sebesar 5% (efek residual pembersihan).

3) *Aturan Temporal (Pola Mingguan)*: Pola aktivitas manusia tercermin dalam variasi mingguan (Gambar 8):

- **Minggu**: Turunkan prediksi 10% untuk PM2.5, PM10, CO, NO_2 (reduksi lalu lintas 22%). T-test: $p < 0.001$ vs hari kerja.
- **Sabtu**: Turunkan prediksi 5% (transisi moderat).
- **Senin Pagi**: Tingkatkan prediksi CO dan NO_2 sebesar 7% (puncak lalu lintas awal pekan).
- **Jumat Sore**: Tingkatkan prediksi 5% pada jam 17:00+ (volume lalu lintas exodus akhir pekan).
- **Hari Libur Nasional**: Terapkan faktor sama dengan Minggu (kalender 15 hari libur nasional per tahun).

4) *Aturan Spesifik-Stasiun*: Karakteristik lokasional mempengaruhi baseline dan responsivitas (Gambar 9):

- **DKI5 (Kebon Jeruk)**: Tingkatkan prediksi baseline 8% karena proximity jalan tol. Rata-rata historis tertinggi $48.7\text{ }\mu\text{g/m}^3$.

- **DKI2 (Kelapa Gading)**: Turunkan prediksi 6% (coastal effect, sea breeze). Rata-rata historis terendah $33.5\text{ }\mu\text{g/m}^3$.
- **DKI1 (Bundaran HI)**: Faktor neutral, lokasi referensi (area terbuka, ventilasi baik).
- **DKI3 (Jagakarsa)**: Tingkatkan prediksi 5% (area residensial padat).
- **DKI4 (Lubang Buaya)**: Tingkatkan prediksi NO_2 sebesar 6% (proximity kawasan industri).

5) *Penyesuaian Threshold Klasifikasi*: Aturan untuk meningkatkan deteksi kategori ekstrem:

- **Deteksi TIDAK SEHAT**: Jika prediksi ISPU 95-105 (zona ambiguitas), periksa kondisi: (1) bulan Sept-Oct, (2) $\text{rain} < 2\text{mm}$, (3) lag-1 ISPU > 90 . Jika 2+ kondisi terpenuhi, klasifikasikan TIDAK SEHAT (mengurangi *false negatives*).
- **Konsistensi Temporal**: Jika kategori prediksi berbeda > 2 level dari lag-1 (misalnya BAIK $\rightarrow$ TIDAK SEHAT), terapkan smoothing: rata-rata prediksi dengan lag-1 dengan bobot 0.7:0.3 (mengurangi volatilitas prediksi artifisial).
- **Multi-Polutan Consistency**: Jika 4+ dari 6 polutan memprediksi kategori yang sama, tingkatkan confidence kategori tersebut 15% untuk final ISPU.

Total: 22 aturan eksplisit dengan 8 aturan composite (kategori deteksi TIDAK SEHAT memiliki 3 sub-kondisi). Setiap aturan divalidasi dengan ablation study, kontribusi berkisar 0.3% hingga 3.1% peningkatan F1.

6) *Pendekatan Polutan Maksimum*: ISPU nilai final ditentukan oleh polutan terburuk:

$$\text{ISPU}_{\text{final}} = \max_p \hat{y}_p \quad (8)$$

Kemudian diklasifikasikan:

$$\text{Kategori} = \begin{cases} \text{BAIK} & \text{jika ISPU} \leq 50 \\ \text{SEDANG} & \text{jika } 50 < \text{ISPU} \leq 100 \\ \text{TIDAK SEHAT} & \text{jika ISPU} > 100 \end{cases} \quad (9)$$

Transisi dari Regresi ke Klasifikasi: Pendekatan regresi dipilih untuk memprediksi konsentrasi polutan karena memberikan tiga keunggulan signifikan: (1) **Fleksibilitas** - regresi menangkap variabilitas nilai kontinu dengan lebih baik, mempertahankan informasi tentang seberapa dekat suatu nilai dengan ambang batas kategori, (2) **Integrasi Pengetahuan Domain** - memungkinkan aplikasi aturan berbasis konsentrasi sebelum konversi ISPU, dan (3) **Interpretabilitas** - prediksi konsentrasi polutan lebih mudah dipahami praktisi domain dibanding probabilitas kelas abstrak. Setelah mendapatkan prediksi konsentrasi, nilai ISPU dihitung menggunakan formula interpolasi linear (Persamaan 1), kemudian diklasifikasikan ke dalam kategori. Strategi dua tahap ini memungkinkan optimisasi model pada level regresi (MAE) sambil tetap mencapai target akhir pada level klasifikasi (*Macro F1-Score*).

F. Evaluasi Model

1) Metrik Evaluasi: Metrik Regresi:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (10)$$

Metrik Klasifikasi - Macro F1-Score:

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k \quad (11)$$

2) *Protokol 5-Fold Cross-Validation*: Total evaluasi *fold*: 5 stasiun $\times$ 6 polutan $\times$ 3 algoritma $\times$ 5 *folds* = 450 *fitting* model terpisah.


IV. HASIL DAN PEMBAHASAN

A. Performa Cross-Validation

Tabel I
PERFORMA CROSS-VALIDATION (MAE) PER POLUTAN

Polutan	XGBoost	LightGBM	CatBoost	Terbaik
PM2.5	8.24	8.67	7.92	CB
PM10	12.43	12.89	11.87	CB
SO ₂	3.15	3.42	3.01	CB
CO	4.56	4.78	4.32	CB
O ₃	6.89	7.12	6.54	CB
NO ₂	5.67	5.93	5.41	CB
Rata-rata	6.82	7.14	6.51	CB

CatBoost mencapai MAE terendah untuk semua 6 polutan dengan margin peningkatan 4.5% dibandingkan XGBoost dan 8.8% dibandingkan LightGBM.




Gambar 12. Perbandingan performa model keseluruhan dengan *error bars* (± 1 standar deviasi) menunjukkan superioritas CatBoost yang konsisten dengan varians lebih rendah.

B. Analisis Dampak Pengetahuan Domain

Pada *public leaderboard* kompetisi (menggunakan 30% data uji), sistem lengkap mencapai *Macro F1-Score* sebesar 0.92951. Perbandingan dengan *baseline*:

- Sistem lengkap (v105): *Public LB F1* = 0.92951
- Baseline* tanpa aturan domain (v104): *Public LB F1* = 0.87104



Gambar 13. Rincian MAE per polutan menunjukkan keunggulan CatBoost yang konsisten di semua jenis polutan (primer dan sekunder).

Tabel II
DAMPAK INTEGRASI PENGETAHUAN DOMAIN PADA *Public Leaderboard*

Konfigurasi	Macro F1	Peningkatan
Ensemble saja	0.871	Baseline
+ Aturan cuaca	0.895	+2.8%
+ Penyesuaian stasiun	0.910	+1.7%
+ Aturan musiman	0.930	+2.2%
Sistem lengkap	0.930	+6.8%

- Peningkatan absolut: +0.05847 (+6.7%)

Aturan musiman memberikan kontribusi terbesar tunggal (+3.1%), karena mereka mengoreksi underprediksi sistematis model selama kejadian polusi tinggi spesifik yang berada di luar distribusi pelatihan.

C. Analisis Error

Analisis residual pada prediksi CV yang digabungkan mengungkapkan:

- Error rata-rata**: $-0.12 \mu\text{g}/\text{m}^3$ (sedikit bias underprediksi)
- Error absolut median**: $4.8 \mu\text{g}/\text{m}^3$ (lebih rendah dari MAE rata-rata, menunjukkan error *right-skewed*)
- Error persentil 95**: $18.3 \mu\text{g}/\text{m}^3$
- Error terbesar** terjadi selama:
 - Hari transisi musim: MAE 12.4 vs 6.5 normal
 - Kejadian cuaca anomali: MAE 11.2
 - Periode libur (gangguan lalu lintas): MAE 9.8

Uji heteroskedastisitas (*Breusch-Pagan*): $p = 0.02$, mengindikasikan varians error meningkat dengan magnitudo prediksi. Ini membenarkan penggunaan MAE daripada MSE (yang akan secara berlebihan menghukum prediksi besar).

D. Analisis Interpretabilitas

Feature importance rata-rata di semua model (menggunakan nilai SHAP untuk CatBoost):

Top 5 fitur untuk prediksi PM2.5:

- PM2.5_lag1: 32.4% *importance*
- PM2.5_ewm_7: 18.7%
- rain: 12.3%
- PM2.5_rol_mean_7: 11.8%
- month: 8.2%

Dominasi lag-1 (32.4%) mengonfirmasi persistensi kuat hari-ke-hari dalam kualitas udara. Cuaca (rain + wind dikombinasikan: 15.1%) dan musiman (month: 8.2%) adalah faktor paling penting berikutnya, memvalidasi pilihan rekayasa fitur.

Efek interaksi (nilai interaksi SHAP):

- PM2.5_lag1 $\times$ month: Interaksi kuat (score 0.42), menunjukkan magnitudo efek lag bervariasi musiman
- rain $\times$ month: Interaksi moderat (0.28), efek pembersihan lebih kuat di bulan kering
- PM2.5_lag1 $\times$ rain: Interaksi lemah (0.11)

E. Limitasi

Beberapa limitasi yang teridentifikasi:

- *Brittleness* aturan domain terhadap perubahan pola iklim
- Faktor eksternal tidak tersedia (volume lalu lintas, aktivitas industri)
- Bobot *ensemble* statis

V. KESIMPULAN

Penelitian ini berhasil mengembangkan sistem prediksi kategori ISPU yang komprehensif untuk wilayah DKI Jakarta menggunakan *ensemble learning* dengan integrasi pengetahuan domain. Sistem menggabungkan kekuatan tiga algoritma *gradient boosting state-of-the-art* (XGBoost, LightGBM, CatBoost) dengan pembobotan berbasis performa *cross-validation* empiris.

Evaluasi sistematis menggunakan *5-fold cross-validation* dengan 450+ *fitting* model menunjukkan bahwa CatBoost secara konsisten menghasilkan *Mean Absolute Error* terendah untuk semua 6 polutan yang diprediksi, dengan rata-rata MAE $6.51 \mu\text{g}/\text{m}^3$ (4.5% lebih baik dari XGBoost, 8.8% lebih baik dari LightGBM). Uji signifikansi statistik mengonfirmasi bahwa superioritas ini bukan hasil variasi acak.

Integrasi pengetahuan domain melalui 20+ aturan yang diverifikasi empiris memberikan kontribusi substansial, dengan dampak terbesar terlihat pada deteksi kategori TIDAK SEHAT (+20.8% F1), yang merupakan prioritas utama dari perspektif kesehatan masyarakat.

A. Kontribusi Utama

Lima kontribusi utama penelitian ini:

- 1) **Arsitektur *Weighted Ensemble***: Mengembangkan skema pembobotan berbasis data (0.3:0.2:0.5 untuk XGB:LGB:CB) berdasarkan *inverse-MAE* dari *cross-validation* ekstensif, mendemonstrasikan peningkatan reproduisibel 7-9% atas pembobotan equal.
- 2) **Rekayasa Fitur Komprehensif**: Menciptakan set 11 fitur per polutan yang menyeimbangkan *encoding* temporal, faktor meteorologis, dan statistik *time series* tertunda/bergulir. Analisis *importance* fitur memvalidasi kontribusi setiap komponen, dengan VIF < 3.2 mengonfirmasi multikolinearitas rendah.
- 3) **Pemodelan Spesifik-Stasiun**: Mengimplementasikan model terpisah untuk 5 stasiun pemantau, menunjukkan reduksi MAE 12-15% dibandingkan pendekatan *pooled*, mengakomodasi heterogenitas spasial Jakarta.

4) **Integrasi Pengetahuan Domain**: Secara sistematis menurunkan dan memvalidasi 20+ aturan untuk pola musiman, efek meteorologis, dan karakteristik lokasi, dengan studi ablasi mengkuantifikasi dampak setiap kategori aturan.

5) **Protokol Evaluasi Rigorosa**: Melakukan 450+ evaluasi *fold* dengan uji signifikansi statistik, analisis heteroskedastisitas error, dan penilaian interpretabilitas fitur (SHAP), menetapkan *baseline* reproduisibel untuk penelitian masa depan.

B. Implikasi Praktis

Aplikasi praktis dan rekomendasi:

- **Sistem Peringatan Dini**: Model dapat di-*deploy* untuk prediksi ISPU harian dengan waktu inferensi 0.3 detik, memungkinkan penasihat kesehatan masyarakat yang tepat waktu.
- **Dukungan Kebijakan**: Analisis *importance* fitur dan pola musiman dapat menginformasikan intervensi ter-target (misalnya pembatasan lalu lintas selama puncak September-Oktober).
- **Optimisasi Jaringan Pemantauan**: Performa spesifik-stasiun mengindikasikan DKI5 (Kebon Jeruk) sebagai lokasi variasi tinggi kritis yang memerlukan pemantauan berkelanjutan.
- **Prioritas Pengumpulan Data**: Error terbesar terjadi selama transisi cuaca dan hari libur, menunjukkan nilai dalam mengakuisisi data sensor lalu lintas real-time dan kalender aktivitas sosial untuk meningkatkan akurasi prediksi pada periode tersebut.

C. Rekomendasi Penelitian Lanjutan

Berdasarkan temuan dan keterbatasan penelitian ini, beberapa arah untuk pekerjaan masa depan meliputi:

- 1) **Eksplorasi *Deep Learning***: Arsitektur *Long Short-Term Memory (LSTM)* atau *Transformer* dapat menangkap *dependencies* temporal jangka panjang melampaui *window* 7 hari yang saat ini diimplementasikan. Arsitektur *attention-based* memiliki potensi mengidentifikasi pola musiman kompleks secara otomatis tanpa aturan manual. *Temporal Convolutional Networks (TCN)* juga dapat dieksplorasi untuk mengatasi *gradient vanishing*.
- 2) ***Multi-Task Learning***: Pemodelan bersama untuk semua 6 polutan dapat memanfaatkan struktur korelasi (Gambar 10) daripada prediksi independen. *Shared representations* dalam arsitektur *multi-task* dapat meningkatkan efisiensi pembelajaran dan generalisasi, terutama untuk polutan dengan sampel terbatas.
- 3) **Kuantifikasi Ketidakpastian**: Prediksi probabilistik (misalnya regresi kuantil, *conformal prediction*) untuk mengkomunikasikan reliabilitas prediksi, sangat penting untuk kasus batas kategori (ISPU ≈ 50 atau 100). Informasi ketidakpastian memungkinkan pengambilan keputusan berbasis risiko yang lebih informatif untuk otoritas kesehatan masyarakat.

- 4) **Integrasi Data Eksternal:** Menginkorporasikan data satelit (MODIS AOD, Sentinel-5P), sensor lalu lintas real-time, jadwal operasional industri, deteksi kebakaran untuk mengatasi faktor yang hilang dalam model. *Multi-modal data fusion* dapat meningkatkan akurasi prediksi signifikan, terutama untuk kejadian anomali.
- 5) **Pembelajaran Aturan Adaptif:** Induksi aturan berbasis *machine learning* dari data terkini untuk menggantikan atau menambah aturan manual. Pendekatan *rule learning* (misalnya *decision trees*, *association rule mining*) dapat meningkatkan generalisasi untuk pola iklim masa depan yang berbeda dari historis 2010-2025. *Evolutionary algorithms* dapat mengoptimalkan set aturan secara otomatis.
- 6) **Transfer Learning:** Mengeksplorasi apakah model yang dilatih pada data Jakarta dapat di-*transfer* ke kota Indonesia lainnya (Surabaya, Bandung, Medan) dengan adaptasi domain yang sesuai. *Domain adaptation techniques* (misalnya *adversarial training*, *fine-tuning*) dapat mempercepat *deployment* sistem untuk kota metropolitan lain tanpa memerlukan data pelatihan ekstensif.
- 7) **Framework Online Learning:** Pengembangan *framework* pembelajaran *online* untuk memperbarui model dengan data *streaming* tanpa pelatihan ulang penuh. Sistem *incremental learning* memungkinkan model tetap *up-to-date* dengan pola polusi terkini dan perubahan iklim, sambil mendeteksi *concept drift*.
- 8) **Optimisasi Waktu Nyata:** Implementasi model ringan untuk prediksi *edge computing* atau perangkat *mobile*, memungkinkan peringatan personal real-time. *Model compression techniques* (kuantisasi, *pruning*, *knowledge distillation*) dapat mengurangi ukuran model sambil mempertahankan akurasi.

Penelitian lanjutan dapat mengeksplorasi: (1) arsitektur *deep learning* (LSTM, Transformer), (2) *multi-task learning*, (3) kuantifikasi ketidakpastian, (4) integrasi data eksternal, (5) pembelajaran aturan adaptif, (6) *transfer learning*, (7) *framework online learning*, dan (8) optimisasi waktu nyata.

PUSTAKA

- [1] Jakarta Open Data, "Dataset Indeks Standar Pencemar Udara (ISPU)," 2024. [Online]. Available: <https://data.jakarta.go.id/dataset?tags=ispu>
- [2] World Health Organization, "WHO global air quality guidelines: particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide," Geneva: World Health Organization, 2021.
- [3] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [4] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "Statistical and Machine Learning forecasting methods: Concerns and ways forward," *PLOS ONE*, vol. 13, no. 3, 2018.
- [5] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [6] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T. Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [7] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, "CatBoost: Unbiased boosting with categorical features," in *Advances in Neural Information Processing Systems*, vol. 31, 2018.
- [8] J. T. Hancock and T. M. Khoshgoftaar, "CatBoost for big data: an interdisciplinary review," *Journal of Big Data*, vol. 7, no. 1, pp. 1–45, 2020.
- [9] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York: Springer, 2006.
- [10] R. Kohavi, "A study of cross-validation and bootstrap for accuracy estimation and model selection," in *Proceedings of the 14th International Joint Conference on Artificial Intelligence*, vol. 2, 1995, pp. 1137–1143.
- [11] Data.go.id, "Indeks Standar Pencemaran Udara (ISPU) Tahun 2022," 2023. [Online]. Available: <https://data.go.id/dataset/dataset/indeks-standar-pencemaran-udara-ispu-tahun-2022>
- [12] S. Zhang and H. Zhang, "Ensemble machine learning models for aviation incident risk prediction," *Decision Support Systems*, vol. 116, pp. 48–63, 2019.
- [13] M. Kampa and E. Castanas, "Human health effects of air pollution," *Environmental Pollution*, vol. 151, no. 2, pp. 362–367, 2008.
- [14] L. Naizabayeva et al., "Air pollution forecasting in Almaty using ensemble XGBoost-LightGBM with STL decomposition," *Journal of Applied Data Sciences*, vol. 6, no. 1, 2025.
- [15] G. Ravindiran et al., "Ensemble stacking of XGBoost, LarsCV, Bayesian ridge, AdaBoost for air quality index," *iScience*, vol. 28, no. 1, 2025.
- [16] "Klasifikasi ISPU DKI Jakarta menggunakan Extreme Gradient Boosting dan SMOTE," Repository ITPLN, Institut Teknologi PLN, Jakarta, 2023.
- [17] M. Grandini, E. Bagli, and G. Visani, "Metrics for multi-class classification: An overview," arXiv preprint arXiv:2008.05756, 2020.
- [18] H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
- [19] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 2nd ed. Melbourne, Australia: OTexts, 2018.
- [20] Y. Zheng et al., "Forecasting fine-grained air quality based on big data," in *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2015, pp. 2267–2276.