

Prediksi Indeks Standar Pencemaran Udara Provinsi DKI Jakarta Menggunakan Metode Hybrid Recursive Classification dengan Confidence-based Re-Anchoring

1st Gabriel Edbert Liandrew
Faculty of Informatics
Telkom University
Bandung, Indonesia
edbertliandrew@gmail.com

2nd Naufal Arkan Wahib
Faculty of Informatics
Telkom University
Bandung, Indonesia
naufalarkanwahib@gmail.com

3rd Hanif Imaduddin
Faculty of Informatics
Telkom University
Bandung, Indonesia
hanifimaduddin2@gmail.com

Ringkasan—DKI Jakarta secara konsisten menempati peringkat atas kota paling tercemar di dunia, dengan konsentrasi $PM_{2.5}$ yang jauh melebihi batas aman WHO. Kondisi ini telah berdampak serius terhadap kesehatan masyarakat dan menimbulkan beban ekonomi yang signifikan. Penelitian ini mengusulkan pendekatan *time series classification* untuk memprediksi kategori Indeks Standar Pencemaran Udara (ISPU) harian di Jakarta dengan metode *Hybrid Recursive Classification* yang dilengkapi dengan mekanisme *confidence-based re-anchoring*. Model menunjukkan performa prediksi yang stabil dengan skor F1-Macro mencapai 0,7245. Analisis ablation juga menunjukkan bahwa setiap komponen fitur lag, prior historis, dan *re-anchoring* berkontribusi terhadap peningkatan performa secara signifikan.

Index Terms—Air Quality Prediction, Time Series Classification, Hybrid Recursive Classification, Confidence-based Re-anchoring, LightGBM, ISPU, Peramalan Polusi Udara

I. PENDAHULUAN

DKI Jakarta menjadi kota yang kerap masuk daftar kota paling tercemar di dunia. Hal ini terlihat jelas pada kualitas udara yang semakin memburuk. Salah satu contohnya terjadi pada 31 Agustus 2023, Jakarta diselimuti oleh kabut asap tebal dan sempat menempati peringkat pertama kota berpolusi dunia [1]. Kota ini memiliki rata-rata tahunan konsentrasi $PM_{2.5}$ yang sangat tinggi, yakni di sekitar $35 \mu\text{g}/\text{m}^3$ pada tahun 2024. Angka ini merepresentasikan tingkat polusi yang tingginya tujuh kali lipat batas aman *World Health Organization* (WHO) [2]. Selain itu, polutan gas dan partikulat lainnya, seperti PM_{10} , SO_2 , NO_2 , CO , dan O_3 juga kerap kali dilaporkan berada di atas ambang batas aman [1]. Keadaan ini diperparah dengan adanya pola musiman. Selama musim kemarau (Juli-Agustus), pencemaran meningkat tajam akibat rendahnya curah hujan dan kondisi angin yang cenderung stagnan. Kajian dari WRI menunjukkan bahwa konsentrasi bulanan $PM_{2.5}$ dapat melonjak hingga rentang 40-80 $\mu\text{g}/\text{m}^3$ pada puncak musim kemarau [1]. Lonjakan polusi bisa menjadi lebih parah dengan adanya fenomena iklim global, seperti badai El Niño yang memperpanjang musim kemarau.

Paparan polutan berbahaya telah memberikan dampak serius pada kesehatan penduduk Jakarta. Sebuah studi kesehatan di Jakarta memperkirakan bahwa setiap tahun polusi udara menyebabkan lebih dari 10000 kematian prematur dan lebih dari 5000 kasus rawat inap terkait kardiorespirasi [3]. Dinas Kesehatan DKI Jakarta mencatat total 1.966.308 kasus Infeksi Saluran Pernapasan Akut (ISPA) sejak Januari hingga Oktober 2025 [4]. Ditambah, beban ekonomi yang ditimbulkan akibat kematian dan penyakit terkait polusi ini diperkirakan mencapai 2% dari Produk Domestik Regional Bruto (PDRB) DKI Jakarta [5].

Melihat skala ancaman tersebut, peramalan kualitas udara menjadi sangat krusial untuk dilakukan. Peramalan ini bisa menjadi sistem peringatan dini kesehatan masyarakat [5]. Dengan adanya peringatan dini pada Indeks Standar Pencemaran Udara (ISPU), otoritas dapat mengatur aktivitas publik dan meningkatkan proteksi pada kelompok rentan.

Dalam praktiknya, beberapa penelitian terbaru telah mengeksplorasi model prediksi dan klasifikasi kualitas udara Jakarta menggunakan data ISPU. Roris dalam penelitiannya membangun model *machine learning* untuk memprediksi ISPU maksimal harian di Jakarta. Dengan data dari bulan Januari-Agustus 2024, model Random Forest mencapai performa *mean absolute error* (MAE) sebesar 0,82 [6]. Sari dalam penelitian menerapkan algoritma XGBoost untuk memodelkan Indeks Kualitas Udara Jakarta berbasis polutan lingkungan. Abdul dkk dalam penelitiannya melakukan klasifikasi kualitas udara di DKI Jakarta menggunakan algoritma *Decision Tree* dengan rentang waktu Januari 2024 hingga November 2025. Penelitian ini berhasil mencapai akurasi 99,13% [5]. Anisa dkk dalam penelitiannya melakukan klasifikasi kualitas udara menggunakan *Decision Tree* dan mencapai akurasi 97,01% [7]. Sayangnya, belum ada penelitian yang melakukan peramalan dan klasifikasi dalam satu proses yang terintegrasi.

Berdasarkan penelitian-penelitian sebelumnya, metode yang digunakan untuk memprediksi konsentrasi polutan udara dan mengklasifikasikan tingkat kualitas udara dilakukan secara

terpisah. Pendekatan yang terpisah ini menimbulkan tantangan tersendiri, terutama dalam konteks upaya pencegahan dampak buruk polusi udara secara dini. Prediksi nilai polutan tanpa klasifikasi tingkat risiko tidak serta-merta memberikan informasi yang langsung dapat ditindaklanjuti oleh masyarakat atau pengambil kebijakan. Oleh karena itu, dibutuhkan pengembangan sistem peringatan dini yang mampu melakukan *time series classification*.

Penelitian ini mengusulkan pendekatan *time series classification* melalui metode *Hybrid Recursive Classification* dengan *Confidence-based Re-anchoring* untuk memprediksi kategori ISPU harian di DKI Jakarta. Metode ini mengintegrasikan model klasifikasi LightGBM dengan pola historis musiman dan harian dan penerapan mekanisme prediksi rekursif yang peka terhadap *error propagation*.

Kontribusi utama dari penelitian ini adalah sebagai berikut:

- 1) Mengembangkan metode prediksi melalui pendekatan *time series classification* melalui yang mampu melakukan peramalan kategori ISPU dalam periode yang panjang.
- 2) Mengembangkan pendekatan berbasis metode *Hybrid Recursive Classification* dengan memanfaatkan *confidence-based re-anchoring* yang dievaluasi menggunakan metrik *f1-score*.
- 3) Melakukan analisis performa model yang digunakan melalui metode studi *ablation*

Makalah ini disusun sebagai berikut: Bagian II membahas mengenai landasan teori yang digunakan dalam penelitian ini. Bagian III menjelaskan metode analisis yang mencakup deskripsi dataset, teknik *preprocessing*, serta pengembangan model BlockRNN dengan GRU, NHITS, dan TSMixer untuk peramalan harga komoditas pangan. Bagian III menyajikan hasil dan pembahasan yang mencakup evaluasi performa model berdasarkan berbagai metrik serta analisis perbandingan antar model. Bagian IV menyimpulkan temuan utama dari penelitian ini serta memberikan rekomendasi untuk penelitian lebih lanjut.

II. LANDASAN TEORI

A. Indeks Standar Pencemar Udara (ISPU)

Ispu merupakan adopsi dari istilah *Air Quality Index (AQI)*, yaitu indikator komposit yang digunakan untuk menggambarkan tingkat kualitas udara berdasarkan konsentrasi berbagai polutan utama di atmosfer. Polutan utama yang menjadi parameter dalam perhitungan AQI terdiri dari enam jenis, yaitu partikulat berukuran kurang dari 2,5 mikrometer ($PM_{2.5}$), partikulat berukuran kurang dari 10 mikrometer (PM_{10}), sulfur dioksida (SO_2), nitrogen dioksida (NO_2), karbon monoksida (CO), dan ozon (O_3). Nilai AQI diklasifikasikan ke dalam beberapa kategori yang mencerminkan tingkat risiko terhadap kesehatan manusia. Oleh karena itu, prediksi AQI dan ISPU memiliki peranan penting dalam memahami serta mengantisipasi dinamika kualitas udara yang semakin kompleks [8].

B. Time Series & Recursive Forecasting

Penggunaan data polutan menjadi tantangan baru karena merupakan data deret waktu yang tidak stasioner. Pendekatan

recursive modelling agar memungkinkan parameter model berubah secara adaptif. *Recursive forecasting* dilakukan dengan memanfaatkan setiap hasil estimasi pada waktu sebelumnya untuk memprediksi data di waktu berikutnya, sehingga memungkinkan untuk dilakukan peramalan multi-step ke depannya [9].

C. Feature Engineering pada Time Series

Tantangan non-stasioner dengan pola tren, musiman, dan penuh dengan noise akan menyebabkan representasi fitur menjadi tidak sempurna. *Feature engineering* terhadap data ini perlu dilakukan agar mampu melihat pola dari data tersebut. Beberapa metode yang umum digunakan dalam data deret waktu antara lain, *decomposition-based features*, *lag & rolling features*, *time-frequency features*, *patch-based & windowing representation*, dan *calendar & exogenous features*. Kualitas model akan dipengaruhi dengan ketepatan dari *feature engineering* yang sesuai dan mampu menjaga stabilitas [10].


D. Light Gradient Boosting Machine (LGBM)

Algoritma *Light Gradient Boosting Machine (LGBM)* merupakan sebuah arsitektur algoritma *Gradient Boosting Decision Tree* dengan sebuah perancangan agar lebih meningkatkan efisiensi dan skalabilitas pada data berdimensi besar. Dua teknik utama yang ditawarkan adalah *Gradient-based One-Side Sampling (GOSS)* untuk mengurangi jumlah data yang diproses supaya tetap mempertahankan data bergradien besar, dan teknik *Exclusive Feature Bundling (EFB)* untuk menghubungkan fitur-fitur yang bersifat saling eksklusif agar menurunkan kompleksitas fitur [11].

E. Hybrid Model dengan Historical Prior

Hybrid model dengan historical prior mengombinasikan model pembelajaran mesin dengan informasi pola historis deret waktu untuk meningkatkan stabilitas hasil prediksi data deret waktu. Pendekatan dengan peramalan rekursif memanfaatkan hasil prediksi sebelumnya serta menghasilkan estimasi probabilistik yang merepresentasikan ketidakpastian dari hasil prediksi. Integrasi distribusi historis sebagai prior akan mengurangi akumulasi error prediksi dan meningkatkan robustitas prediksi [12].

III. METODE ANALISIS



Gambar 1. Alur penelitian

Gambar (1) menunjukkan alur metode analisis dalam pengembangan model kami. Proses diawali dengan *Data Collecting*, yang kemudian diproses menjadi dataset untuk memastikan data siap digunakan. Setelah itu, data masuk dalam proses *data preprocessing* dengan lima tahap, yaitu *data cleaning*, standarisasi, deduplikasi, *time series reconstruction*, dan penanganan *missing value*. Selanjutnya, data akan digabung dengan data pendukung untuk masuk dalam proses *historical prior module*. Selanjutnya, data akan dilakukan *feature engineering* dan pelatihan model. Terakhir, dilakukan *hybrid recursive prediction* untuk mendapatkan peramalan di masa yang akan datang.

A. Data Collecting

Tahap *data collecting* dilakukan untuk mendapatkan dataset ISPU dari tahun 2010 hingga 2025 dan data pendukung lainnya yang bisa membantu dalam prediksi. Dataset yang digunakan dalam penelitian ini adalah data ISPU di DKI Jakarta yang mencakup lima stasiun. Dalam dataset ini terdapat tanggal, stasiun, dan kolom-kolom polutan, yaitu $PM_{2.5}$, PM_{10} , SO_2 , NO_2 , CO , dan O_3 serta kolom kategori dari ISPU.

B. Data Preprocessing

1) *Data Cleaning*: Setiap baris yang memenuhi kriteria sebagai berikut:

- nilai dalam kolom *max* sama dengan *null* atau 0, dan
- nilai kolom *category* sama dengan 'TIDAK ADA DATA', akan dihapus dari dataset.

2) *Standardization*: Melakukan standarisasi pada kolom stasiun menjadi format DKI(i) untuk menjaga konsistensi nama stasiun.

3) *Deduplication*: Proses deduplikasi mencakup proses menghapus setiap baris yang duplikat berdasarkan kombinasi tanggal dan stasiun dan menyisakan baris pertama untuk setiap kombinasi duplikat.

4) *Time Series Reconstruction*: Proses ini dilakukan agar setiap deret waktu menjadi lengkap tanpa adanya *gap* untuk setiap stasiun. Proses dilakukan dengan membuat kerangka tanggal lengkap dan digabungkan dengan data yang ada.

5) *Handling Missing Values*: Untuk menangani *missing values* dalam variabel-variabel polutan udara, dilakukan dua tahap penanganan, yaitu interpolasi dan metode propagasi nilai. Metode interpolasi dilakukan secara independen pada masing-masing stasiun. Interpolasi digunakan untuk memperkirakan nilai polutan yang hilang berdasarkan tren lokal waktu. Secara umum, interpolasi pada titik waktu t dihitung menggunakan persamaan:

$$x_t = x_{t_1} + \frac{(x_{t_2} - x_{t_1})}{(t_2 - t_1)} \times (t - t_1)$$

dengan x_{t_1} dan x_{t_2} adalah dua nilai valid terdekat sebelum dan sesudah waktu t . Metode ini efektif untuk mengisi celah nilai hilang yang pendek dan tidak berturut-turut panjang. Selanjutnya, untuk mengatasi *missing value* yang masih tersisa setelah interpolasi, digunakan metode propagasi nilai. Metode ini terdiri dari:


- *forward fill*: Mengisi *missing value* dengan nilai valid terakhir sebelumnya.
- *backward fill*: Mengisi *missing value* dengan nilai valid pertama setelahnya.

Kedua teknik ini mempertahankan kontinuitas deret waktu dan memastikan tidak ada variabel numerik yang kosong pada data sebelum digunakan dalam pemodelan.

C. Merge Data

Data deret waktu ISPU yang sudah melalui tahap *preprocessing* akan digabungkan dengan data pendukung, yaitu data liburan di Indonesia. Data ini mencakup tanggal, nilai *boolean* yang menyatakan hari libur nasional, nilai *boolean* yang menyatakan hari tersebut adalah akhir pekan, dan nama hari libur.

D. Historical Prior Module



Gambar 2. Alur Historical Prior Module

Gambar (2) menyajikan alur dari proses *historical module prior*. penelitian ini mengembangkan sebuah modul distribusi prior berbasis historis. Modul ini menyimpan informasi distribusi probabilitas kategori ISPU berdasarkan pola musiman dan temporal pada tiap stasiun pengamatan.

Distribusi prior dihitung dari data historis berdasarkan empat dimensi waktu:

- 1) *Day-of-Year (DOY)*: pola musiman tahunan (1-366),
- 2) *Month*: pola musiman bulanan (1-12),
- 3) *Day-of-Week (DOW)*: pola mingguan (Senin-Minggu),
- 4) *Station-level*: distribusi umum per stasiun.

Distribusi probabilitas dihitung menggunakan *laplace smoothing* untuk menghindari pembobotan nol, dengan rumus:

$$P(y = c_i) = \frac{n_i + \alpha}{N + \alpha \cdot K}$$

dengan:

- n_i = jumlah kemunculan kategori c_i ,
- N = total observasi,
- K = jumlah total kategori,
- α = konstanta smoothing (default: 1.0).

Distribusi ini dihitung dan disimpan secara terpisah untuk setiap stasiun dan granularitas waktu yang disebutkan.

1) *Kombinasi Prior Berbobot*: Ketika model memerlukan referensi historis, distribusi prior untuk tanggal dan stasiun tertentu dihitung dengan metode kombinasi berbobot (*weighted prior combination*). Bobot diberikan sesuai tingkat spesifisitas waktu:

- Day-of-Year (DOY): bobot 3.0,
- Month: bobot 2.0,
- Day-of-Week (DOW): bobot 1.0,
- Station Prior: bobot 0.5.

Distribusi akhir dihitung dengan rumus:

$$\hat{P}(y = c) = \frac{1}{Z} \sum_{i=1}^n w_i \cdot P_i(c)$$

dengan:

- $P_i(c)$ = distribusi probabilitas dari sumber prior ke- i ,
- w_i = bobot untuk sumber prior ke- i ,
- Z = normalisasi bobot: $Z = \sum_i w_i$.

E. Feature Engineering

Proses *feature engineering* dilakukan untuk memperkaya model. Proses ini membangun berbagai fitur yang bersifat temporal, spasial, kategorikal, dan statistik historis, termasuk informasi hari libur nasional.

1) *Fitur Temporal dan Musiman*: Fitur waktu diturunkan dari kolom tanggal, yang meliputi: `day_of_year`, `day_of_week`, `month`, `day_of_month`, `week_of_year`, dan `quarter`. Untuk menangkap sifat siklikal dari waktu, digunakan pendekatan *cyclical encoding* melalui transformasi sinus dan kosinus:

$$\text{doy_sin} = \sin\left(2\pi \cdot \frac{\text{day_of_year}}{365}\right),$$

$$\text{doy_cos} = \cos\left(2\pi \cdot \frac{\text{day_of_year}}{365}\right)$$

Transformasi serupa diterapkan pada variabel `day_of_week`, `month`, dan `day_of_month`. Fitur tambahan, seperti `is_month_start` dan `is_month_end` digunakan untuk menandai awal dan akhir bulan.

2) *Fitur Hari Libur dan Akhir Pekan*: Modul ini juga menggabungkan data hari libur nasional dari dataset eksternal, mencakup kolom `is_holiday_nasional` dan `is_weekend`. Fitur tambahan `is_holiday_or_weekend` dibuat sebagai gabungan biner dari kedua status tersebut. Jika data hari libur tidak tersedia, maka akhir pekan dihitung dari logika `day_of_week ≥ 5`.

3) *Encoding Kategorikal*: Kolom *category* (target ISPU) diubah menjadi bentuk numerik dengan pemetaan ordinal, diatur berdasarkan urutan tingkat polusi. Kolom stasiun juga di-*encode* menggunakan teknik label encoding untuk menghasilkan variabel `station_encoded`.

4) *Fitur Lag dan Rolling*: Untuk mendukung skenario prediksi rekursif, dibuat fitur lag dari kategori ISPU sebelumnya, seperti:

category_lag_k = kategori encoded pada hari $t - k$,

$$k \in \{1, 2, 3, 7, 14, 30\}$$

Selain itu, dihitung juga statistik *rolling window* dari nilai kategori ISPU yang sudah di-encode, untuk periode 7, 14, dan 30 hari:

$$\text{mean}_w = \frac{1}{w} \sum_{i=1}^w x_{t-i},$$

$$\text{std}_w = \sqrt{\frac{1}{w} \sum_{i=1}^w (x_{t-i} - \bar{x})^2},$$

$$\text{max}_w = \max(x_{t-1}, \dots, x_{t-w})$$


di mana x_{t-i} adalah kategori ISPU encoded pada hari ke- $t - i$.

5) *Transformasi Akhir*: Semua fitur tersebut digabungkan dalam proses transformasi akhir, menghasilkan matriks fitur yang siap digunakan dalam pelatihan model. Fitur lag dan rolling hanya dimasukkan ketika data target tersedia, yaitu selama pelatihan atau validasi, dan tidak digunakan saat inferensi hari pertama.

F. Model Training

Pelatihan model dilakukan menggunakan data yang sudah melalui tahap sebelumnya. Pelatihan menggunakan model LightGBM Classifier dengan memanfaatkan *framework* Optuna untuk *hyperparameter tuning*. Model dilatih dengan validasi *time series* untuk menyimulasikan skenario prediksi ke depan. Setelah mendapatkan parameter terbaik, model dilatih dengan keseluruhan data latih.

G. Hybrid Recursive Prediction



Gambar 3. Alur Hybrid Recursive Prediction

Komponen *Hybrid Recursive Predictor* bertugas melakukan prediksi kategori ISPU harian untuk horizon waktu mendatang dengan pendekatan rekursif. Setiap langkah prediksi bergantung pada hasil langkah sebelumnya, baik dalam hal fitur input maupun hasil kategori.

Inti dari metode ini adalah mekanisme confidence-based re-anchoring, yaitu pencampuran adaptif antara distribusi prediksi model dan distribusi historis apabila model tidak cukup yakin terhadap hasil prediksinya.

1) *Mekanisme Prediksi*: Proses prediksi harian mengikuti langkah-langkah berikut:

- Data historis dikombinasikan dengan baris dummy untuk tanggal yang akan diprediksi.
- Fitur diperoleh melalui modul *Feature Engineering*, termasuk fitur lag dan rolling dari kategori sebelumnya.
- Model klasifikasi (*LightGBM*) menghitung distribusi probabilitas kategori:

$$P_{\text{model}}(y) = \text{model.predict_proba}(\text{features})$$

- Confidence dihitung sebagai:

$$\text{confidence} = \max(P_{\text{model}}(y))$$

- Jika confidence di bawah ambang batas θ , dilakukan pencampuran dengan distribusi prior:

$$\lambda = \text{blend_weight} \cdot \left(1 - \frac{\text{confidence}}{\theta}\right)$$

$$P_{\text{final}}(y) = (1 - \lambda) \cdot P_{\text{model}}(y) + \lambda \cdot P_{\text{prior}}(y)$$

- Kategori akhir dipilih berdasarkan:

$$\hat{y}_t = \arg \max(P_{\text{final}}(y))$$

- Kategori $\hat{y}_t$ digunakan sebagai input lag untuk prediksi hari berikutnya.

2) *Prediksi Rekursif*: Prediksi dilakukan untuk seluruh kombinasi tanggal dan stasiun dalam urutan kronologis. Untuk setiap iterasi, hasil prediksi digunakan untuk memperbarui dataset, sehingga lag dan rolling feature pada hari berikutnya tetap konsisten dengan skenario nyata. Dengan pendekatan ini, prediksi menjadi adaptif dan mempertimbangkan dinamika kategori ISPU secara berurutan.

3) *Re-anchoring*: Metode ini menyesuaikan bobot prior secara dinamis berdasarkan tingkat confidence model. Semakin rendah confidence, semakin besar kontribusi prior historis terhadap hasil akhir. Strategi ini membuat sistem lebih *robust* terhadap kondisi out-of-distribution dan mencegah akumulasi error dalam jangka panjang.

Algorithm 1 Hybrid Recursive Prediction

Require: historical_df, prediction_dates, stations, model, prior_module, confidence_threshold, blend_weight

Ensure: predictions: DataFrame hasil prediksi kategori ISPU

```

1: working_df ← salinan dari historical_df
2: results ← list kosong
3: for setiap tanggal  $t$  dalam prediction_dates do
4:   for setiap stasiun  $s$  dalam stations do
5:     hitung fitur waktu dan lag → features
6:     prediksi probabilitas kategori → model_proba
7:     hitung confidence = max(model_proba)
8:     if confidence < confidence_threshold then
9:       prior_proba ← prior_module.get_prior( $t, s$ )
10:      final_proba ←  $(1 - \lambda) \cdot \text{model\_proba} + \lambda \cdot \text{prior\_proba}$ 
11:      reanchored ← True
12:     else
13:       final_proba ← model_proba
14:       reanchored ← False
15:     end if
16:     predicted_category ← arg max(final_proba)
17:     simpan hasil prediksi, confidence, dan status reanchored ke results
18:     tambahkan hasil ke working_df sebagai input hari berikutnya
19:   end for
20: end for
21: return hasil prediksi dalam bentuk DataFrame =0

```

IV. HASIL DAN PEMBAHASAN

A. Data Collecting

Dataset ISPU diperoleh dari sumber terbuka dan mencakup data historis dari tahun Januari 2010 hingga Agustus 2025. Dataset ini memiliki bentuk sebagai berikut pada tabel (I).


Tabel I
INFORMASI UMUM DATASET ISPU

Atribut	Nilai
Jumlah baris	16.902
Jumlah kolom	11
Periode data	1 Januari 2010 s.d. 31 Agustus 2025

Adapun atribut-atribut yang tersedia pada dataset ISPU adalah:

- tanggal: Tanggal observasi
- stasiun: Nama stasiun pemantauan
- pm10, pm25, so2, co, o3, no2: Konsentrasi polutan utama (dalam $\mu\text{g}/\text{m}^3$)
- max: Nilai maksimum dari seluruh polutan per baris
- critical: Polutan dominan yang menyumbang nilai maksimum
- kategori: Kategori ISPU

Gambar (4) menunjukkan distribusi polutan di setiap stasiun.



Gambar 4. Diagram Garis untuk Setiap Polutan di Setiap Stasiun

Dataset pendukung yang digunakan adalah data hari libur nasional dan akhir pekan selama periode yang sama. Dataset ini terdiri dari 5.844 entri dan mencakup kolom sebagai berikut.

- tanggal: Tanggal kalender
- is_holiday_nasional: Indikator biner untuk hari libur nasional
- nama_libur: Nama hari libur
- is_weekend: Indikator akhir pekan (1 jika Sabtu atau Minggu)
- day_name: Nama hari (Senin hingga Minggu)

Informasi dari dataset ini digunakan untuk membentuk fitur biner is_holiday_or_weekend yang membantu model memahami variasi perilaku kategori ISPU pada hari libur dan akhir pekan, di mana emisi kendaraan atau aktivitas industri biasanya menurun.

B. Data Preprocessing

Sebelum data digunakan untuk pelatihan dan evaluasi model, dilakukan serangkaian tahap *preprocessing* untuk memastikan integritas dan kelengkapan data. Proses ini mencakup *data cleaning*, standarisasi nama stasiun, deduplikasi, rekonstruksi deret waktu, dan penanganan *missing value*. Tahapan ini penting untuk menjamin bahwa input yang diberikan kepada model mencerminkan kondisi aktual dan tidak mengandung bias dari data rusak atau hilang.

1) *Data Cleaning*: Langkah awal dalam pembersihan data adalah menghapus baris-baris yang tidak relevan atau tidak valid. Secara khusus, baris yang memiliki nilai max bernilai null atau nol, serta memiliki kategori TIDAK ADA DATA, dihapus dari dataset. Hasil dari proses pembersihan ini dapat dilihat pada Tabel (II), yang menunjukkan distribusi kategori ISPU setelah data yang tidak valid dihilangkan.

Tabel II
DISTRIBUSI KATEGORI ISPU SETELAH DATA CLEANING

Kategori ISPU	Jumlah Observasi
SEDANG	5239
TIDAK SEHAT	926
BAIK	805
SANGAT TIDAK SEHAT	4
Total	6974

2) *Standardization dan Deduplication*: Untuk menjaga konsistensi identitas stasiun pemantauan, nama stasiun distandarisasi menjadi format DKI1 hingga DKI5. Selanjutnya, dilakukan proses deduplikasi berdasarkan kombinasi unik antara tanggal dan stasiun. Tabel III merangkum hasil proses standarisasi dan deduplikasi tersebut.

Tabel III
RINGKASAN STANDARISASI DAN DEDUPLIKASI DATA

Langkah	Hasil
Format nama stasiun	Diseragamkan ke DKI1–DKI5
Baris sebelum deduplikasi	27.080
Baris setelah deduplikasi	26.785
Baris duplikat dihapus	295

3) *Time Series Reconstruction*: Agar analisis deret waktu dapat dilakukan secara utuh dan tanpa celah, dilakukan proses rekonstruksi deret waktu dengan membentuk kerangka tanggal lengkap dari 1 Januari 2010 hingga 31 Agustus 2025 untuk setiap stasiun. Hasil rekonstruksi menghasilkan 28.610 baris data, sebagaimana dirangkum pada Tabel IV.

Tabel IV
RINGKASAN REKONSTRUKSI DERET WAKTU

Atribut	Nilai
Rentang tanggal	1 Januari 2010 s.d. 31 Agustus 2025
Jumlah hari	5.722
Jumlah stasiun	5
Baris diharapkan	28.610
Baris aktual	28.610
Missing values setelah rekonstruksi	1.886 (6,59%)

4) *Missing Value Handling*: Data ISPU memiliki tingkat missing value yang cukup signifikan, khususnya pada variabel polutan seperti PM2.5 dan NO₂. Untuk mengatasinya, dilakukan dua tahap penanganan: interpolasi dan *forward/backward fill*. Tabel V menyajikan perkembangan jumlah nilai hilang sebelum dan sesudah proses interpolasi serta pengisian lanjutan. Setelah kedua tahap dilakukan, seluruh nilai hilang berhasil ditangani dan dataset menjadi lengkap secara numerik.

Tabel V
MISSING VALUE HANDLING PADA VARIABEL POLUTAN

Variabel	Data Awal	Setelah Interpolasi	Setelah FFill/BFill
PM10	5.370	4.029	0
PM2.5	22.363	22.120	0
SO ₂	4.864	3.817	0
CO	4.684	3.745	0
O ₃	4.922	3.734	0
NO ₂	4.864	3.749	0
Max	1.886	1.755	0
Total	49.953	43.949	0

C. Merge Data

Setelah dilakukan proses *merge* antara data ISPU dengan dataset hari libur nasional berdasarkan kolom tanggal, diperoleh total 28.610, baris observasi dengan 15 kolom.

Tabel VI berikut menyajikan distribusi tiga fitur utama yang dihasilkan dari integrasi ini:

Tabel VI
DISTRIBUSI FITUR HARI LIBUR DAN AKHIR PEKAN

Fitur	Label	Jumlah Baris
is_holiday_nasional	0 (bukan hari libur)	27.335
	1 (hari libur)	1.275
is_weekend	0 (hari kerja)	20.430
	1 (akhir pekan)	8.180
is_holiday_or_weekend	0 (hari biasa)	19.480
	1 (libur)	9.130

Fitur-fitur ini penting karena pola aktivitas masyarakat dan tingkat emisi cenderung berbeda antara hari kerja dan hari libur. Sebagai contoh, pada akhir pekan dan hari libur nasional, lalu lintas dan aktivitas industri biasanya menurun, yang dapat berdampak pada penurunan level polusi udara.

D. Historical Prior Module

Modul *Historical Prior* menghitung distribusi probabilitas kategori ISPU berdasarkan pola temporal dan spasial dari data historis. Tujuan dari modul ini adalah menyediakan estimasi probabilitas yang dapat digunakan sebagai penahan prediksi ketika model klasifikasi memiliki tingkat kepercayaan yang rendah.

Distribusi prior global dihitung dari seluruh data lintas waktu dan stasiun, dan mencerminkan proporsi kategori secara umum dalam dataset. Seperti terlihat pada Tabel VII, data menunjukkan dominasi kategori **SEDANG** secara signifikan, yakni sebesar lebih dari 94%. Hal ini menunjukkan bahwa dataset memiliki ketidakseimbangan kelas yang tinggi, dan justru memperkuat pentingnya distribusi prior sebagai baseline yang konservatif dalam proses re-anchoring.

Tabel VII
DISTRIBUSI PRIOR GLOBAL KATEGORI ISPU

Kategori	Probabilitas
BAIK	0.0360
SEDANG	0.9436
TIDAK SEHAT	0.0204

Selain distribusi global, modul juga menghasilkan prior granular berdasarkan kombinasi tanggal dan stasiun. Sebagai ilustrasi, Tabel VIII menunjukkan distribusi prior untuk tanggal 15 September 2025 pada stasiun **DKI1**. Terlihat bahwa proporsi kategori **TIDAK SEHAT** meningkat menjadi 6.34% dari yang sebelumnya hanya 2.04% secara global. Hal ini mencerminkan kemampuan modul untuk menyesuaikan distribusi dengan pola musiman dan lokasi.

Tabel VIII
DISTRIBUSI PRIOR UNTUK TANGGAL 2025-09-15 DI STASIUN DKI1

Kategori	Probabilitas
BAIK	0.0359
SEDANG	0.9007
TIDAK SEHAT	0.0634

Distribusi seperti ini akan digunakan oleh model prediktor dalam proses blending saat confidence rendah, dengan proporsi bobot prior yang disesuaikan secara adaptif.

E. Feature Engineering

Hasil proses feature engineering menghasilkan total 33 fitur yang mencakup informasi temporal, musiman, spasial, historis, dan perilaku kategori sebelumnya. Fitur-fitur yang dihasilkan digunakan untuk merepresentasikan dimensi waktu, seperti hari dalam setahun atau hari dalam minggu secara kontinu. Informasi hari libur dan akhir pekan ditambahkan untuk menangkap variasi aktivitas masyarakat. Selain itu, fitur lag dan rolling statistik dari kategori ISPU sebelumnya disertakan untuk memberikan konteks historis jangka pendek dan menengah, yang penting dalam pendekatan prediksi rekursif. Tabel IX merangkum seluruh fitur yang digunakan sebagai input model.

Tabel IX
RINGKASAN FITUR HASIL FEATURE ENGINEERING

No.	Nama Fitur	Deskripsi
1–2	doy_sin, doy_cos	Cyclical encoding day-of-year
3–4	dow_sin, dow_cos	Cyclical encoding day-of-week
5–6	month_sin, month_cos	Cyclical encoding month
7–8	dom_sin, dom_cos	Cyclical encoding day-of-month
9	is_weekend	1 jika Sabtu/Minggu
10	is_month_start	1 jika tanggal 1–5
11	is_month_end	1 jika tanggal 25–31
12	station_encoded	Label encoded nama stasiun
13–18	category_lag_k	Nilai kategori sebelumnya
19–27	category_rolling_*	Mean, std, max rolling window

F. Model Training

Setelah proses feature engineering selesai, model dilatih menggunakan algoritma *LightGBM* untuk melakukan klasifikasi kategori ISPU. Dataset dibagi menjadi dua bagian berdasarkan rentang waktu: **training set** dari 1 Januari 2010 hingga 1 Juni 2025 sebanyak 26.324 baris, dan **validation set** dari 2 Juni 2025 hingga 31 Agustus 2025 sebanyak 452 baris. Proses pelatihan melibatkan optimasi hiperparameter


menggunakan *Optuna* selama 50 iterasi untuk memaksimalkan skor F1-Macro pada data validasi.

Hiperparameter terbaik yang diperoleh ditunjukkan sebagai berikut:

- `n_estimators`: 974
- `max_depth`: 10
- `num_leaves`: 134
- `learning_rate`: 0.289
- `min_child_samples`: 59
- `subsample`: 0.940
- `colsample_bytree`: 0.821
- `reg_alpha`: 0.0035
- `reg_lambda`: 0.0165

1) *Analisis Feature Importance*: Gambar 5 menunjukkan 20 fitur terpenting berdasarkan kontribusi kumulatif terhadap model. Terlihat bahwa fitur berbasis waktu, khususnya encoding siklikal dari `day_of_year` dan `day_of_month`, mendominasi kontribusi terhadap prediksi model. Fitur `doy_sin` dan `doy_cos` secara konsisten muncul sebagai dua fitur terkuat, menunjukkan bahwa model sangat bergantung pada pola musiman tahunan.

Selain itu, fitur `station_encoded` juga memberikan kontribusi signifikan, yang menunjukkan bahwa karakteristik lokasi pengamatan berperan penting dalam penentuan kategori ISPU. Fitur historis seperti `category_rolling_std_30` dan `category_lag_1` juga berkontribusi, meskipun secara relatif lebih rendah.



Gambar 5. Top 20 Fitur Terpenting Berdasarkan Importance Score dari Model LightGBM

G. Evaluasi Model dan Analisis Ablasi


Untuk menilai kontribusi masing-masing komponen dalam model, dilakukan eksperimen ablation serta eksplorasi pengaruh parameter *confidence threshold* terhadap performa model. Evaluasi menggunakan metrik F1 Macro Score karena klasifikasi terdiri dari kategori yang tidak seimbang.

1) *Ablation Study*: Gambar 6 menunjukkan hasil evaluasi terhadap tiga variasi model: tanpa fitur lag, tanpa distribusi prior historis, dan tanpa mekanisme re-anchoring. Hasilnya menunjukkan bahwa:

- Menghilangkan fitur lag menyebabkan penurunan skor menjadi 0.7023.

- Menghilangkan prior historis menurunkan performa lebih drastis ($F1 = 0.6855$), menunjukkan pentingnya pola musiman dalam prediksi.
- Menghapus mekanisme re-anchoring mengurangi skor menjadi 0.7136.


Model kami mencatatkan skor tertinggi sebesar **0.7245**, menegaskan bahwa ketiga komponen (lag, prior historis, dan re-anchoring) berkontribusi terhadap kinerja terbaik.



Gambar 6. Perbandingan F1 Macro Score dalam Ablation Study

2) *Eksperimen Threshold Confidence*: Untuk mengevaluasi sensitivitas model terhadap parameter *confidence threshold*, dilakukan pengujian pada lima nilai berbeda antara 0.3 hingga 0.8. Gambar 7 (kiri) menunjukkan bahwa threshold optimal berada di sekitar **0.6**, dengan skor F1 tertinggi mencapai **0.7317**. Penurunan skor pada threshold lebih tinggi disebabkan oleh over-reliance terhadap prior.

Sementara itu, grafik kanan memperlihatkan hubungan antara threshold dan reanchoring rate yang semakin tinggi threshold, semakin sering model mengaktifkan distribusi prior. Pada threshold 0.8, reanchoring terjadi hingga 16% dari total prediksi.



Gambar 7. Kiri: Pengaruh Confidence Threshold terhadap F1 Score; Kanan: Reanchoring Rate

Keunggulan utama dari model yang dikembangkan terletak pada kemampuannya untuk menangkap dinamika temporal dan musiman yang kompleks dalam data kualitas udara, serta fleksibilitas dalam menghadapi ketidakpastian prediksi jangka panjang. Penggunaan fitur-fitur, seperti *cyclical encoding*, *rolling statistics*, dan lag historis memungkinkan model untuk belajar dari pola jangka pendek maupun jangka panjang. Selain itu, integrasi distribusi prior historis yang bersifat adaptif memungkinkan sistem untuk tetap menghasilkan prediksi yang masuk akal bahkan ketika data input tidak mencerminkan situasi yang familier bagi model.

Mekanisme *confidence-based re-anchoring* juga menjadi elemen kunci dalam meningkatkan akurasi model. Pendekatan

ini memberikan keseimbangan antara kepercayaan prediksi model dan pengetahuan historis yang telah teruji, sehingga mampu menahan efek akumulasi kesalahan dalam prediksi rekursif. Dengan mengaktifkan prior hanya saat confidence rendah, model tetap fleksibel namun terkendali. Kombinasi ketiga aspek, yaitu fitur waktu yang kaya, pemodelan historis granular, dan pengambilan keputusan adaptif, menjadi alasan mengapa model mencapai performa terbaik secara konsisten dibandingkan variasi tanpa komponen tersebut.

V. KESIMPULAN

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan, dapat disimpulkan bahwa pendekatan *Hybrid Recursive Classification* dengan mekanisme *confidence-based re-anchoring* berhasil memberikan performa prediksi yang stabil dan adaptif dalam memetakan kategori kualitas udara harian di DKI Jakarta. Model yang dikembangkan mampu memanfaatkan fitur temporal, lag historis, dan distribusi prior untuk mengatasi tantangan prediksi jangka panjang, bahkan saat data polutan aktual tidak tersedia.

Hasil evaluasi menunjukkan bahwa model lengkap yang menggabungkan seluruh komponen menghasilkan skor F1-Macro tertinggi sebesar 0.7245. Analisis ablation memperkuat pentingnya setiap komponen, terutama distribusi prior historis yang berkontribusi signifikan terhadap stabilitas prediksi. Selain itu, eksperimen terhadap parameter *confidence threshold* menemukan bahwa nilai ambang sebesar 0.6 memberikan keseimbangan terbaik antara akurasi prediksi dan tingkat intervensi oleh prior.

Sebagai rekomendasi, ke depan model ini dapat ditingkatkan dengan menambahkan variabel eksternal, seperti data cuaca (suhu, kelembaban, arah angin), data lalu lintas, atau data aktivitas industri yang dapat memengaruhi konsentrasi polutan. Selain itu, penerapan metode *handling class balance* atau strategi augmentasi data dapat membantu memperbaiki klasifikasi pada kategori minoritas seperti TIDAK SEHAT dan SANGAT TIDAK SEHAT yang cenderung jarang muncul. Pengembangan model ini juga dapat diarahkan menuju sistem peringatan dini kualitas udara real-time yang diintegrasikan dengan dashboard pemantauan publik atau kebijakan pengendalian aktivitas luar ruang.

PUSTAKA

- [1] WRI Indonesia, "Jakarta kembali jadi kota paling berpolusi di dunia: Apa yang terjadi?," Online, 2023. Accessed: 2026-02-06.
- [2] Nafas Indonesia, "Laporan kualitas udara jakarta 2025," Online, 2025. Accessed: 2026-02-06.
- [3] A. Syuhada, D. Fitriani, and R. Wibowo, "Estimasi dampak ekonomi dan kesehatan akibat polusi udara di jakarta," *Jurnal Kesehatan Masyarakat Indonesia*, vol. 18, no. 3, pp. 985–989, 2023.
- [4] L. W. Santosa, "Dinkes dki catat 1,9 juta kasus ispa hingga oktober 2025," October 2025.
- [5] A. Hadia, B. K. Hura, M. A. Abulkhoir, R. Abimur, L. N. W. Hulu, W. Ningsih, and I. Y. Deli, "Analisis klasifikasi kualitas udara di dki jakarta menggunakan algoritma decision tree," *Jurnal Ilmu Komputer dan Informatika*, vol. 2, pp. 90–97, January–March 2026. E-ISSN: 3063-9026.
- [6] H. Roris, A. Kurniawan, and N. Lestari, "Penerapan algoritma random forest untuk prediksi ispu di jakarta berdasarkan data polutan harian," *Jurnal Teknologi dan Sains Data*, vol. 12, no. 1, pp. 23–31, 2025.
- [7] A. P. A. V. Lubu, S. Mutiah, A. Praditya, N. Rahma, and P. R. Arum, "Analisis algoritma decision tree dalam pengklasifikasian indeks pencemaran udara kota jakarta dengan metode cross industry standard process for data mining," *Jurnal Fraction*, vol. 5, pp. 9–17, June 2025. E-ISSN: 2830-2028, P-ISSN: 2962-1402.
- [8] B. Zhang, M. Duan, Y. Sun, Y. Lyu, Y. Hou, and T. Tan, "Air quality index prediction in six major chinese urban agglomerations: A comparative study of single machine learning model, ensemble model, and hybrid model," *Atmosphere*, vol. 14, no. 10, 2023.
- [9] C. Ng and T. Van, "Recursive modelling and adaptive forecasting of air quality data," *WIT Transactions on Ecology and the Environment*, vol. 28, 2025.
- [10] X. Kong, Z. Chen, W. Liu, K. Ning, L. Zhang, S. M. Marlier, Y. Liu, Y. Chen, and F. Xia, "Deep learning for time series forecasting: A survey," *International Journal of Machine Learning and Cybernetics*, vol. 16, pp. 5079–5112, 2025.
- [11] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "Lightgbm: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems* (I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, eds.), vol. 30, Curran Associates, Inc., 2017.
- [12] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, "Deepar: Probabilistic forecasting with autoregressive recurrent networks," *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.