

Pemodelan Prediktif ISPU Jakarta Menggunakan Strategi Granular Monthly-Station Ensemble untuk Mitigasi Polusi Udara Perkotaan*

Muhammad Hariish Hafiiz
Dept. of Computer Science
Universitas Gadjah Mada
Yogyakarta, Indonesia
hariishhafiiz9@gmail.com

Maria Clareta Febriani
Dept. of Computer Science
Universitas Gadjah Mada
Yogyakarta, Indonesia
mariacclaretafebriani@mail.ugm.ac.id


Natahanael Aurelino Sulistyo
Dept. of Computer Science
Universitas Gadjah Mada
Yogyakarta, Indonesia
arelsulistyo22@gmail.com

Abstract—Polusi udara di Jakarta telah mencapai tingkat kritis dengan konsentrasi PM_{2.5} tahunan 6–11 kali lipat di atas pedoman WHO, menyebabkan lebih dari 638.000 kasus ISPA dan kerugian ekonomi 2,2% PDRB. Penelitian ini mengembangkan model forecasting ISPU berbasis ensemble learning yang mengintegrasikan data historis kualitas udara dan variabel meteorologis periode 2021–2025 dari lima stasiun pemantauan DKI Jakarta. Tiga model basis dikembangkan: Historical-Weather Phase Guidance untuk menangkap pola musiman, LightGBM Time-Series untuk dependensi temporal non-linear, dan Stochastic Distribution untuk variabilitas ekstrem. Strategi Granular Monthly-Station Ensemble diterapkan dengan seleksi model terbaik secara adaptif untuk setiap kombinasi stasiun dan bulan. Model mencapai F1-Macro validation 0,7032, dengan Historical-Weather optimal untuk September, LightGBM unggul pada Oktober, dan model Stokastik terbaik untuk stasiun DKI5. Limitasi teridentifikasi pada prediksi kategori "TIDAK SEHAT" akibat ketidakseimbangan kelas (76,9% kategori "SEDANG"). Penelitian ini berkontribusi pada metodologi machine learning untuk klasifikasi ISPU multi-kelas di megacity tropis dan dapat diimplementasikan sebagai early warning system untuk kebijakan mitigasi polusi udara berbasis data di DKI Jakarta.

Index Terms—ISPU, ensemble learning, prediksi kualitas udara, gradient boosting, Jakarta

I. PENDAHULUAN

Polusi udara telah diakui sebagai salah satu ancaman kesehatan global paling signifikan pada abad ke-21, berkontribusi terhadap sekitar 7–8 juta kematian dini setiap tahun akibat penyakit kardiovaskular, infeksi saluran pernapasan akut, dan kanker paru-paru [1], [2]. Paparan kronis terhadap polutan udara ambien, khususnya partikulat halus PM_{2.5}, menunjukkan korelasi kuat dengan peningkatan morbiditas dan mortalitas lintas kelompok usia, mendorong *World Health Organization* (WHO) untuk menetapkan ambang batas aman tahunan PM_{2.5} sebesar 5 $\mu\text{g}/\text{m}^3$ pada pembaruan pedoman kualitas udara tahun 2021 [3]. Namun demikian, laporan global menunjukkan bahwa lebih dari 99% populasi dunia masih terpapar udara dengan konsentrasi polutan yang melampaui ambang batas tersebut, menjadikan pengelolaan kualitas udara sebagai




Gambar 1. Rata-rata bulanan konsentrasi PM_{2.5} di Jakarta periode 2021–2025 yang secara konsisten melampaui ambang batas tahunan WHO 2021 sebesar 5 $\mu\text{g}/\text{m}^3$, mengindikasikan paparan polusi udara kronis di Jakarta.

tantangan kesehatan masyarakat yang bersifat sistemik dan berkelanjutan [2], [4].

Krisis ini termanifestasi secara akut di kawasan urban padat dan terindustrialisasi, khususnya pada kota-kota berstatus *megacity* dengan populasi melebihi 10 juta jiwa. Konsentrasi aktivitas antropogenik yang tinggi, meliputi transportasi, industri, dan konstruksi, menciptakan tekanan lingkungan yang melampaui daya dukung atmosfer lokal [5]. Jakarta, sebagai pusat pemerintahan dan ekonomi Indonesia dengan populasi lebih dari 10 juta penduduk [6], merupakan representasi tipikal dari dinamika tersebut. Dalam beberapa tahun terakhir, Jakarta secara konsisten mencatat konsentrasi PM_{2.5} tahunan pada kisaran 43.8–55 $\mu\text{g}/\text{m}^3$, atau sekitar 6–11 kali lipat di atas pedoman WHO (**Gambar 1**), menempatkannya di antara kota dengan tingkat polusi udara tertinggi di Asia Tenggara [7], [8], [9].

Dampak kesehatan dari kondisi ini bersifat nyata dan terukur. Data kesehatan menunjukkan lonjakan signifikan kasus Infeksi Saluran Pernapasan Akut (ISPA) di Jakarta, dengan lebih dari 638.000 kasus tercatat hanya dalam periode Januari–Juni 2023, dan peningkatan berkelanjutan pada kelompok rentan seperti anak-anak dan lansia [10], [11]. Selain beban



Gambar 2. Distribusi kelas Indeks Standar Pencemar Udara (ISPU) pada data historis mentah Jakarta (2010-2025).

kesehatan masyarakat, pencemaran udara juga menimbulkan kerugian ekonomi yang substansial. Studi lintas lembaga mengindikasikan bahwa dampak $PM_{2.5}$ dan ozon permukaan berkontribusi terhadap kehilangan hingga 2.2% Produk Domestik Regional Bruto (PDRB) Provinsi DKI Jakarta (sekitar Rp221 triliun) dan biaya kesehatan Rp159 triliun pada periode 2024–2025, terutama melalui penurunan produktivitas dan peningkatan biaya layanan kesehatan akibat peningkatan kasus penyakit jantung iskemik, gagal ginjal, dan hipertensi [12], [13].

Dalam konteks pengelolaan risiko kesehatan, Indeks Standar Pencemar Udara (ISPU) berperan sebagai indikator operasional utama untuk memantau, mengkategorikan, dan mengkomunikasikan tingkat bahaya kualitas udara kepada masyarakat dan pengambil kebijakan. ISPU dihitung berdasarkan konsentrasi maksimum dari beberapa parameter polutan utama, yaitu $PM_{2.5}$, PM_{10} , NO_2 , SO_2 , CO , dan O_3 , sesuai regulasi Kementerian Lingkungan Hidup dan Kehutanan, serta digunakan sebagai dasar kebijakan taktis seperti pembatasan lalu lintas, *work-from-home*, dan penerapan zona rendah emisi [14]. Di Jakarta, pemantauan kualitas udara dilakukan melalui jaringan Stasiun Pemantau Kualitas Udara Ambien (SPKUA) di lima lokasi utama (DKI1–DKI5), dengan ketersediaan data historis yang relatif panjang namun terbatas secara spasial [14], [15].

Pendekatan konvensional dalam pemantauan dan prediksi kualitas udara, seperti regresi linier, model deret waktu ARIMA, serta ketergantungan pada stasiun pemantauan tetap, masih menghadapi sejumlah keterbatasan fundamental. Secara khusus, tantangan utama meliputi: (1) *threshold sensitivity*, yang ditandai dengan fluktuasi konsentrasi polutan yang relatif kecil di sekitar batas kategori dapat menyebabkan perubahan kelas ISPU yang tidak stabil; (2) ketidakmampuan model parametrik tradisional dalam merepresentasikan interaksi non-linier dan dependensi kompleks antar-polutan serta kovariat meteorologis, seperti suhu, kelembapan, dan kecepatan angin; (3) permasalahan ketidakseimbangan kelas (*class imbalance*) yang signifikan pada klasifikasi ISPU multi-kelas sebagaimana divisualisasikan pada **Gambar 2**, terutama pada kategori berisiko tinggi yang secara alami jarang terjadi; dan (4) keterbatasan resolusi spasial dan temporal yang menghambat kemampuan sistem konvensional dalam mendukung prediksi


real-time dan peringatan dini yang adaptif [2], [4].

Meskipun pendekatan *machine learning* (ML) telah mulai diadopsi dalam studi prediksi kualitas udara, sebagian besar penelitian sebelumnya masih berfokus pada regresi konsentrasi polutan individual atau klasifikasi biner. Pendekatan tersebut belum secara memadai menangani permasalahan klasifikasi ISPU multi-kelas dalam kondisi ketidakseimbangan data yang ekstrem, khususnya pada konteks *megacity* tropis seperti Jakarta [4] seperti terlihat pada **Gambar 2** yang menampilkan ketidakseimbangan kelas yang signifikan, dengan dominasi kategori *Sedang* dan keterwakilan yang sangat terbatas pada kategori berisiko tinggi seperti *Tidak Sehat* dan *Sangat Tidak Sehat*. Kondisi ini menimbulkan tantangan substansial bagi klasifikasi multi-kelas berbasis pembelajaran mesin. Kesenjangan metodologis ini secara langsung membatasi akurasi dan reliabilitas sistem peringatan dini, sehingga mengurangi efektivitas kebijakan mitigasi yang bersifat proaktif.

Berdasarkan latar belakang tersebut, penelitian ini mengusulkan pengembangan model *forecasting* ISPU Jakarta berbasis *ensemble learning* dengan integrasi data historis kualitas udara dan variabel meteorologis. Pendekatan ini dirancang untuk memodelkan pola nonlinier dan musiman secara lebih efektif, sekaligus mengatasi ketidakseimbangan kelas melalui optimasi berbasis metrik F1-macro yang selaras dengan kebutuhan kesehatan publik. Fokus prediksi diarahkan pada periode September hingga November 2025, yang merepresentasikan fase transisi musim dan dikenal memiliki variabilitas kualitas udara yang tinggi. Dengan demikian, penelitian ini diharapkan dapat berkontribusi secara keilmuan pada pengembangan metode ML untuk klasifikasi ISPU multi-kelas di *megacity* tropis, serta secara praktis dapat dimanfaatkan sebagai *early warning system* bagi Pemerintah Provinsi DKI Jakarta dalam merancang kebijakan mitigasi berbasis data untuk kesejahteraan warga Jakarta, sejalan dengan tema Arkavidia 10 “*Innovate for Impact: Bridging Technology and Society*” [16].

II. METODE ANALISIS

Penelitian ini dirancang mengikuti pipeline sistematis yang terdiri dari lima tahapan utama sebagaimana diilustrasikan pada **Gambar 3**. Tahap pertama adalah akuisisi data dari tiga sumber utama (ISPU, cuaca, dan hari libur nasional), dilanjutkan dengan eksplorasi data untuk memahami karakteristik distribusi temporal dan spasial. Tahap ketiga melakukan pembersihan dan pra-pemrosesan mencakup penanganan missing values, normalisasi format, dan reduksi kategori minoritas untuk mengatasi *class imbalance* ekstrem. Analisis eksploratif pada tahap keempat mengidentifikasi pola musiman, tren antar-tahun, serta korelasi antara parameter meteorologis dengan kualitas udara. Pada tahap kelima, dikembangkan tiga model basis dengan paradigma berbeda: Model I berbasis tren historis dengan koreksi fase cuaca (Historical-Weather Phase), Model II menggunakan gradient boosting dengan recursive forecasting (LightGBM Time-Series), dan Model III menerapkan sampling stokastik untuk menangkap variabilitas ekstrem



Gambar 3. Alur Penelitian

(Stochastic Distribution). Seluruh model kemudian dikombinasikan melalui strategi Granular Monthly-Station Ensemble yang melakukan seleksi model terbaik secara adaptif untuk setiap kombinasi stasiun dan bulan, menghasilkan prediksi final yang dioptimalkan terhadap karakteristik lokal masing-masing lokasi pemantauan.

A. Akuisisi Data

Penelitian ini menggunakan 3 dataset yang disediakan oleh Datavidia yaitu data ISPU, cuaca harian, dan libur nasional. Ketiga sumber data tersebut kemudian diintegrasikan untuk membentuk basis data analitik yang komprehensif, dengan spesifikasi dan karakteristik masing-masing dataset diuraikan sebagai berikut.

1) Data Indeks Standar Pencemar Udara (ISPU)

Data rekaman historis ISPU DKI Jakarta tersedia dalam format yang terpisah menjadi 10 *file* laporan terpisah untuk setiap tahunnya dengan total volume data mentah tersebut mencapai 16.902 baris entri. Secara struktural, setiap observasi dalam dataset memuat serangkaian atribut yang dikelompokkan sebagai berikut:

- **Identitas Spasial-Temporal:** Mencakup informasi waktu (*periode_data*, *tanggal*) dan lokasi pemantauan (*stasiun*).
- **Konsentrasi Polutan:** Meliputi pengukuran partikulat (*pm_sepuluh*, *pm_duakomalima*) dan gas pencemar (*sulfur_dioksida*, *karbon_monoksida*, *ozon*, *nitrogen_dioksida*).
- **Status Mutu Udara:** Terdiri dari nilai indeks tertinggi (*max*), parameter kritis

(*parameter_pencemar_kritis*), dan label klasifikasi (*kategori*).

Persebaran data berdasarkan label klasifikasi pada kolom *kategori* tersebut dapat dilihat kembali secara rinci pada **Gambar 2**.

2) Data Cuaca Harian

Data cuaca harian DKI Jakarta terdiri dari 5 *file* terpisah yang masing-masing mewakili lokasi stasiun pemantauan, yaitu DKI1 hingga DKI5, dengan rentang waktu dari tahun 2010 hingga 2025. Secara akumulatif, volume data cuaca harian yang digunakan mencapai 28.610 baris entri dengan struktur atribut yang dikelompokkan sebagai berikut:

- **Temporal:** Kolom *time* sebagai acuan tanggal pencatatan.
- **Fisik Atmosfer:** Meliputi suhu (*temperature_2m*), kelembapan (*relative_humidity_2m*), dan tekanan udara (*surface_pressure*).
- **Hidrologi & Angin:** Mencakup curah hujan (*precipitation*), tutupan awan (*cloud_cover*), serta kecepatan dan arah angin (*wind_speed_10m*, *wind_direction_10m_dominant*).

3) Data Hari Libur Nasional

Data ini terdiri dari 1 *file* tunggal berisi 5.844 baris data dari tahun 2010 sampai 2025 yang memuat informasi hari libur di Indonesia dengan rincian kolom sebagai berikut:

Secara struktural, setiap observasi dalam data memuat atribut yang dikelompokkan sebagai berikut:

- **Waktu:** Kolom *tanggal* dan nama hari (*day_name*).
- **Indikator Libur:** Variabel biner untuk libur nasional (*is_holiday_nasional*) dan akhir pekan (*is_weekend*).
- **Deskripsi:** Nama resmi peringatan hari besar (*nama_libur*).


Distribusi frekuensi dari berbagai jenis hari libur nasional ini divisualisasikan pada **Gambar 4**.

B. Analisis Integritas Data

Penelitian ini melakukan analisis menyeluruh terhadap validitas dan konsistensi data historis ISPU yang mencakup rentang waktu 2010 hingga 2025. Evaluasi ini bertujuan untuk mengidentifikasi anomali pada label klasifikasi serta mendeteksi pergeseran pola data yang mungkin terjadi akibat perubahan instrumen pengukuran selama 15 tahun terakhir.

1) Evaluasi Distribusi Label Kategori

Investigasi kualitas data diawali dengan pemeriksaan variabel target atau label kelas. Merujuk kembali pada distribusi frekuensi di **Gambar 2**, visualisasi tersebut mengungkap adanya dua permasalahan utama pada integritas label. Pertama, terdapat kategori anomali yang




Gambar 4. Distribusi Frekuensi Jenis Hari Libur Nasional (2010–2025)

tidak sesuai standar, yaitu munculnya label “ O_3 ” dan “Tidak Ada Data”. Label “ O_3 ” mengindikasikan kesalahan input (*human error*) di mana nama parameter tertulis sebagai kategori, sedangkan “Tidak Ada Data” merepresentasikan nilai kosong yang tidak informatif. Kedua, terlihat *class imbalance* yang ekstrem, di mana kategori “Sangat Tidak Sehat” dan “Berbahaya” muncul sebagai *outliers* dengan frekuensi yang sangat minim dibandingkan kategori mayoritas “Sedang”. Hasil observasi ini menegaskan perlunya pembersihan label sebelum data dapat digunakan.

2) Analisis Konsistensi Tren Parameter Kritis


Selain validitas label, analisis ini juga meninjau konsistensi parameter pencemar yang menjadi penentu nilai ISPU (*critical parameter*) antar-tahun. Perubahan dominasi parameter kritis dari waktu ke waktu dapat dilihat dalam **Gambar 5**.



Gambar 5. Tren Dominasi Parameter Kritis ISPU per Tahun

Grafik tren tahunan ini memperlihatkan adanya diskrepansi struktural yang tajam. Pada periode lama (2010–2020), kualitas udara Jakarta hampir secara eksklusif didominasi oleh Ozon (O_3) dan PM_{10} . Sebaliknya, mulai tahun 2021 terjadi pergeseran pola yang signifikan di mana parameter Partikulat Halus ($PM_{2.5}$) mulai muncul dan mendominasi penentuan ISPU secara konsisten hingga tahun 2025. Absennya $PM_{2.5}$ pada tahun-tahun awal mengindikasikan bahwa sensor pen-

gukuran untuk parameter ini kemungkinan belum terpasang atau belum dijadikan standar pelaporan sebelum tahun 2021.



Gambar 6. Perbandingan Proporsi Dominasi Parameter Antar Era

Dugaan mengenai ketidaklayakan data lama ini diperkuat oleh analisis proporsi total yang ditampilkan pada **Gambar 6**. Visualisasi tersebut memperlihatkan, terdapat perbedaan karakteristik yang fundamental antara “Era Lama” dan “Era Baru”. Pada periode 2010–2020, kontribusi $PM_{2.5}$ tercatat 0%, yang merupakan anomali mengingat karakteristik polusi perkotaan modern. Sebaliknya, pada periode 2021–2025, $PM_{2.5}$ justru menjadi parameter paling kritis dengan dominasi mencapai 84,0%. Mengingat tujuan penelitian adalah memprediksi kualitas udara masa depan yang sangat dipengaruhi oleh $PM_{2.5}$, penggunaan data historis sebelum 2021 dinilai memiliki risiko tinggi karena tidak memuat informasi parameter kunci yang relevan dengan rentang waktu yang akan diprediksi.

C. Pemrosesan Data

Berdasarkan tahap analisis sebelumnya mengenai ketidaklengkapan data lama, tahap pemrosesan ini difokuskan hanya pada data dari tahun 2021 hingga 2025. Keputusan ini diterapkan pada ketiga jenis data (ISPU, Cuaca, dan Hari Libur) agar rentang waktunya seragam. Langkah-langkah perbaikan dan penyiapan data dilakukan sebagai berikut:

- 1) Integrasi Data ISPU dan Pemilihan Periode Waktu: Data ISPU dari tahun 2021 hingga 2025 digabungkan menjadi satu kesatuan. Data sebelum tahun 2021 tidak digunakan karena belum memiliki pengukuran parameter debu halus ($PM_{2.5}$) yang lengkap. Selain itu, dilakukan penyamaan nama stasiun menjadi format baku (DKI1 hingga DKI5) dan perbaikan format tanggal agar seragam.
- 2) Perbaikan Format dan Nilai Kosong: Simbol-simbol yang tidak memiliki arti angka (seperti tanda “—”) pada kolom polutan diubah menjadi nilai kosong (*null*) agar bisa diproses. Penulisan nama parameter juga diperbaiki, misalnya mengubah $PM_{2.5}$ atau kode angka menjadi format standar $PM_{2.5}$. Baris data yang memiliki kategori “TIDAK ADA DATA” dihapus karena tidak memuat informasi yang berguna.
- 3) Penghitungan Ulang dan Penyaringan Kategori: Nilai indeks tertinggi ($\max$) dan penentuan kategori ISPU

dihitung ulang berdasarkan angka polutan asli untuk memperbaiki kesalahan label pada data mentah. Selanjutnya, berdasarkan analisis sebaran data yang menunjukkan ketimpangan jumlah kelas yang ekstrem, penelitian ini hanya mengambil data dengan tiga kategori utama: "BAIK", "SEDANG", dan "TIDAK SEHAT". Data dengan label kategori lain dihapus untuk menjaga kualitas prediksi model.

- 4) Penyiapan Data Cuaca: Data cuaca dari 5 file terpisah digabungkan dan disesuaikan rentang waktunya dengan data ISPU (2021–2025). Kolom penanda stasiun ditambahkan pada setiap baris data agar kondisi cuaca dapat dipetakan dengan lokasi stasiun pemantauan kualitas udara yang sesuai.
- 5) Penyiapan Data Hari Libur: Data hari libur nasional disiapkan dengan memastikan format tanggalnya sudah sesuai. Data ini siap digunakan sebagai fitur tambahan untuk melihat pola perbedaan polusi antara hari kerja dan hari libur.

D. Model Basis I: Pemodelan Berbasis Tren Historis dengan Weather Phase Guidance

Model pertama (Terlihat pada **Gambar 8**) mengestimasi kategori ISPU melalui pendekatan *historical-weather phase guided modelling*, yaitu pemodelan deterministik yang memanfaatkan konsistensi pola historis, *inter-annual trend*, serta koreksi meteorologis berbasis fase. Pendekatan ini tidak melibatkan pelatihan model *machine learning* eksplisit, melainkan membangun estimasi berbasis struktur data yang stabil, dengan variabel cuaca diposisikan sebagai faktor korektif, bukan sebagai penentu utama.

Hasil eksplorasi data yang dirangkum pada **Table I** menunjukkan bahwa distribusi kategori ISPU bersifat sangat timpang secara musiman, khususnya pada periode September–Oktober, di mana kategori "SEDANG" mendominasi hampir seluruh stasiun pengamatan.

TABLE I. Distribusi Historis Kategori ISPU September–Oktober (2021–2024)

Stasiun	BAIK	SEDANG	TIDAK SEHAT
DKI1 (Sept)	1%	94%	4%
DKI1 (Oct)	0%	92%	8%
DKI2 (Sept)	1%	93%	6%
DKI2 (Oct)	0%	86%	14%
DKI4 (Sept)	0%	52%	45%
DKI4 (Oct)	1%	59%	40%

Dominasi kategori "SEDANG" yang konsisten antar-tahun menunjukkan bahwa variasi utama ISPU pada periode ini terjadi pada fluktuasi nilai kontinu, bukan pada perpindahan kelas ekstrem. Oleh karena itu, pemodelan difokuskan pada estimasi ISPU kontinu sebagai *baseline*, yang kemudian dipetakan ke kategori diskret.

Untuk setiap stasiun s dan hari t , estimasi ISPU kontinu $\widehat{\text{ISPU}}_{s,t}$ dirumuskan sebagai superposisi komponen historis, koreksi tren antar-tahun, dan koreksi meteorologis berbasis fase:

$$\widehat{\text{ISPU}}_{s,t} = \mu_{s,m(t)} + \Delta_s^{\text{YoY}} + \Gamma_{p(t)}, \quad (1)$$

dengan $\mu_{s,m(t)}$ menyatakan rata-rata historis ISPU pada stasiun s untuk bulan m , Δ_s^{YoY} adalah koreksi *year-over-year*, dan $\Gamma_{p(t)}$ merupakan koreksi cuaca pada fase meteorologis p . Komponen historis $\mu_{s,m}$ dihitung sebagai:

$$\mu_{s,m} = \frac{1}{|\mathcal{T}_{s,m}|} \sum_{t \in \mathcal{T}_{s,m}} \text{ISPU}_{s,t}, \quad (2)$$

dengan $\mathcal{T}_{s,m}$ adalah himpunan seluruh hari pada bulan m lintas tahun observasi. Variansi antar-tahun dari $\mu_{s,m}$ digunakan untuk mengevaluasi stabilitas *baseline* historis sebagaimana disajikan pada **Table II**.

TABLE II. Stabilitas Baseline Historis ISPU per Stasiun

Stasiun	Variansi Baseline	Stabilitas
DKI1	Rendah	Tinggi
DKI2	Rendah	Tinggi
DKI3	Sedang	Menengah
DKI4	Tinggi	Rendah
DKI5	Sedang	Menengah

Untuk mengakomodasi pergeseran kondisi latar polusi antar-tahun, digunakan koreksi tren berbasis perbandingan rata-rata tahunan.

$$\Delta_s^{\text{YoY}} = \beta_s \left(\overline{\text{ISPU}}_s^{\text{recent}} - \overline{\text{ISPU}}_s^{\text{prev}} \right), \quad (3)$$

di mana $\overline{\text{ISPU}}_s^{\text{recent}}$ dan $\overline{\text{ISPU}}_s^{\text{prev}}$ masing-masing menyatakan rata-rata ISPU periode Januari–Agustus tahun berjalan dan tahun sebelumnya, serta β_s merupakan koefisien sensitivitas tren pada stasiun s .

TABLE III. Perbandingan Rata-rata ISPU Jan–Agustus: 2025 terhadap 2024

Stasiun	$\overline{\text{ISPU}}_{2024}$	$\overline{\text{ISPU}}_{2025}$	$\Delta \text{ YoY}$
DKI1	71.9	72.2	+0.3
DKI2	78.0	71.5	−6.5
DKI3	74.1	70.0	−4.1
DKI4	80.4	69.1	−11.4
DKI5	79.9	74.7	−5.2

Hasil pada **Table III** menunjukkan bahwa tahun 2025 secara umum memiliki tingkat polusi udara yang lebih rendah dibandingkan tahun 2024, terutama pada stasiun DKI4. Koreksi Δ_s^{YoY} berfungsi untuk menggeser *baseline* historis agar selaras dengan kondisi tahun berjalan, tanpa mengubah struktur musiman yang telah terbentuk.

Pengaruh meteorologis dimodelkan melalui indeks komposit *Pollution Favorability Index (PFI)*:

$$\text{PFI} = \frac{T_{\max}}{35} - \frac{P}{10} - \frac{W}{10} - \frac{H}{100} - \frac{C}{100}, \quad (4)$$

di mana $T_{\max}$ adalah temperatur maksimum harian, P adalah presipitasi, W adalah kecepatan angin, H adalah kelembapan relatif, dan C adalah tutupan awan. Nilai PFI yang lebih tinggi menunjukkan kondisi yang lebih mendukung

TABLE IV. Korelasi PFI Bulanan terhadap ISPU Bulanan

Stasiun	Koef. Korelasi (r)	Kekuatan
DKI1	0.799	Kuat
DKI2	0.756	Kuat
DKI3	0.509	Sedang
DKI4	0.550	Sedang
DKI5	0.374	Lemah

akumulasi polutan, sebagaimana terlihat dari nilai korelasi positif yang kuat pada **Table IV**.

Untuk bulan November, koreksi meteorologis dimodelkan secara terfase berdasarkan karakteristik presipitasi yang berkaitan dengan awal musim hujan (*monsoon onset*) seperti dirinci dalam **Table V**.

TABLE V. Klimatologi Presipitasi November berdasarkan Fase

Fase	Rentang Hari	$\bar{P}$ (mm/hari)	Anomali
Fase 1	1–5	6.2	–25%
Fase 2	6–14	9.6	+15%
Fase 3	15–30	8.3	–1%

Koreksi fase cuaca dirumuskan sebagai:

$$\Gamma_p = -\alpha (\bar{P}_p - \bar{P}_m), \quad (5)$$

dengan $\bar{P}_p$ menyatakan rata-rata presipitasi pada fase p , $\bar{P}_m$ rata-rata presipitasi bulanan, dan α koefisien sensitivitas ISPU terhadap presipitasi yang merepresentasikan efek *washout*.

Dengan demikian, estimasi akhir ISPU kontinu dirumuskan sebagai:

$$\widehat{\text{ISPU}}_{s,t} = \mu_{s,m} + \Delta_s^{\text{YoY}} - \alpha (\bar{P}_{p(t)} - \bar{P}_m). \quad (6)$$

Nilai ISPU kontinu kemudian dipetakan ke kategori diskret sesuai dengan ambang batas resmi ISPU sebagaimana diatur dalam Peraturan Menteri Lingkungan Hidup dan Kehutanan Republik Indonesia Nomor 14 Tahun 2020 tentang Indeks Standar Pencemar Udara seperti terlihat pada **Table VI** [17], [18].

TABLE VI. Kategori dan Rentang Nilai ISPU

Rentang Nilai ISPU	Kategori
1–50	BAIK
51–100	SEDANG
101–200	TIDAK SEHAT

E. Model Basis II: Pemodelan Berbasis Time-Series dengan Gradient Boosting

Pemodelan ini dirancang untuk memprediksi kategori ISPU harian pada masing-masing stasiun pemantauan di DKI Jakarta dengan memanfaatkan pola historis kualitas udara dan struktur temporal data. Model kedua diformulasikan dalam kerangka *time-series supervised learning* dan dioperasikan dalam skema prediksi satu langkah ke depan (*one-step-ahead forecasting*), yaitu memprediksi kondisi ISPU pada hari ke- t berdasarkan informasi yang tersedia hingga hari ke- $(t-1)$.

Untuk kebutuhan prediksi multi-hari, pendekatan ini menggunakan strategi *recursive forecasting*, di mana hasil prediksi pada waktu sebelumnya digunakan kembali sebagai masukan untuk prediksi pada langkah waktu berikutnya. Skema ini mencerminkan kondisi operasional nyata ketika data observasi masa depan belum tersedia. Seluruh alur kerja, mulai dari integrasi data, pelatihan model, hingga mekanisme *forecasting* rekursif ini, diilustrasikan secara rinci pada **Gambar 9**.

1) *Formulasi Masalah*: Masalah dirumuskan sebagai klasifikasi multikelas pada data deret waktu. Diberikan urutan observasi ISPU pada stasiun s :

$$\{y_{s,1}, y_{s,2}, \dots, y_{s,t}\}, \quad (7)$$

dengan $y_{s,t} \in \{0, 1, 2\}$ yang merepresentasikan kategori kualitas udara:

- 0: BAIK
- 1: SEDANG
- 2: TIDAK SEHAT

Tujuan pemodelan adalah mempelajari fungsi prediksi:

$$\hat{y}_{s,t} = f(x_{s,t}), \quad (8)$$

dengan $x_{s,t}$ merupakan vektor fitur yang diekstraksi sepenuhnya dari informasi historis dan temporal yang tersedia sebelum waktu t .

2) *Penyederhanaan Label*: Mengacu pada tahap pra-pemrosesan di mana data dengan label minoritas (“SANGAT TIDAK SEHAT” dan “BERBAHAYA”) telah dieksklusi maka ruang sampel target y saat ini hanya terdiri dari tiga kategori dominan.

Agar dapat diproses oleh algoritma *gradient boosting*, label kategorikal teks dikonversi menjadi format numerik (*label encoding*) melalui fungsi pemetaan $g(y)$:

$$g(y) = \begin{cases} 0, & \text{jika } y = \text{“BAIK”}, \\ 1, & \text{jika } y = \text{“SEDANG”}, \\ 2, & \text{jika } y = \text{“TIDAK SEHAT”}. \end{cases} \quad (9)$$

3) *Penanganan Missing Label*: Pada data historis terdapat beberapa nilai target yang hilang sehingga berpotensi mengganggu pembentukan fitur berbasis urutan waktu. Untuk menjaga kontinuitas deret waktu, interpolasi dilakukan secara terpisah pada masing-masing stasiun menggunakan pendekatan *nearest neighbor*:

$$\tilde{y}_{s,t} = y_{s,k}, \quad k = \arg \min |t - k|. \quad (10)$$

Pendekatan ini dilengkapi dengan *forward fill* dan *backward fill* pada batas awal dan akhir deret waktu. Seluruh proses dilakukan hanya menggunakan informasi historis sehingga tidak menimbulkan data leakage.

4) *Rekayasa Fitur Berbasis Waktu dan Historis*: Fitur yang digunakan dirancang untuk menangkap ketergantungan temporal, pola periodik, serta dinamika jangka pendek kualitas udara.

a) *Fitur Temporal*: Fitur temporal merepresentasikan pola mingguan dan musiman:

$$x_t^{(\text{month})} = \text{month}(t), \quad (11)$$

$$x_t^{(\text{dow})} \in \{0, 1, \dots, 6\}, \quad (12)$$

$$x_t^{(\text{weekend})} = \begin{cases} 1, & \text{Sabtu/Minggu,} \\ 0, & \text{lainnya.} \end{cases} \quad (13)$$

b) *Fitur Lag*: Untuk menangkap ketergantungan historis kualitas udara, digunakan fitur lag:

$$\text{lag}_k(t) = y_{t-k}, \quad k \in \{1, 2, 3, 7\}. \quad (14)$$

c) *Rolling Statistics*: Untuk mengekstraksi kecenderungan jangka pendek dan meredam fluktuasi sesaat, digunakan statistik *rolling mean*:

$$\text{roll_mean}_k(t) = \frac{1}{k} \sum_{i=1}^k y_{t-i}, \quad k \in \{3, 7\}. \quad (15)$$

d) *Fitur Perubahan Tren*: Perubahan tren lokal dimodelkan melalui selisih nilai historis:

$$\text{trend}_{3d}(t) = y_{t-1} - y_{t-3}. \quad (16)$$

5) *Integrasi Informasi Klimatologis*: Untuk menghindari kebocoran informasi masa depan, informasi klimatologis direpresentasikan menggunakan statistik rata-rata bulanan jangka panjang (*climate normals*):

$$\bar{c}_m = \frac{1}{N_m} \sum_{i=m} c_i. \quad (17)$$

Pendekatan ini merefleksikan kondisi iklim tipikal tanpa bergantung pada pengamatan cuaca harian spesifik.

6) *Model Klasifikasi dan Validasi*: Model klasifikasi yang digunakan adalah Light Gradient Boosting Machine (Light-GBM), yang membangun *ensemble* pohon keputusan secara aditif:

$$\hat{y}_t = \arg \max_c \sum_{m=1}^M f_m(x_t), \quad (18)$$

dengan f_m merupakan pohon keputusan ke- m dan M jumlah estimator.

Evaluasi model dilakukan menggunakan pembagian data secara kronologis, dengan data hingga Juni 2025 sebagai data pelatihan dan data Juli–Agustus 2025 sebagai data validasi. Strategi ini memastikan bahwa model tidak mengakses informasi masa depan selama proses pelatihan maupun evaluasi.

F. Model Basis III: Pemodelan Stokastik Berbasis Distribusi Historis

Berbeda dengan dua pendekatan sebelumnya yang bersifat deterministik, pendekatan ketiga ini mengadopsi paradigma pemodelan stokastik. Metode ini dirancang untuk mensimulasikan variabilitas alami dan kemunculan *outliers* yang sering kali hilang dalam model regresi standar akibat efek *smoothing*. Model ini bekerja dengan melakukan *sampling* langsung dari distribusi statistik data historis yang sebenarnya, memastikan bahwa profil risiko polusi yang dihasilkan mencerminkan karakteristik empiris lokasi pemantauan.

1) *Ekstraksi Parameter Statistik*: Langkah pertama adalah pembentukan profil distribusi dari data historis terkini (180 hari terakhir). Profil ini mencakup parameter tendensi sentral dan penyebaran. Diberikan deret waktu $Y = \{y_1, y_2, \dots, y_N\}$, parameter dihitung sebagai berikut:

$$\mu = \frac{1}{N} \sum_{i=1}^N y_i, \quad \sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \mu)^2} \quad (19)$$

di mana μ adalah nilai rata-rata, σ adalah standar deviasi, N adalah jumlah data observasi dalam jendela waktu (180 hari), dan y_i adalah nilai ISPU pada hari ke- i .

Selain itu, dihitung frekuensi kemunculan kategori kritis (“TIDAK SEHAT”) untuk menentukan probabilitas dasar kejadian polusi tinggi, yang dinotasikan sebagai P_{peak} :

$$P_{\text{peak}} = \frac{\sum_{i=1}^N \mathbb{I}(y_i \geq 101)}{N} \quad (20)$$

di mana $\mathbb{I}(\cdot)$ adalah fungsi indikator yang bernilai 1 jika kondisi terpenuhi (nilai ISPU ≥ 101), dan 0 jika tidak.

2) *Mekanisme Sampling Hibrida*: Inti dari model ini adalah mekanisme pembangkitan nilai prediksi harian $\hat{y}_{\text{base},t}$ yang menggunakan strategi *dual-mode sampling*. Keputusan pengambilan sampel didasarkan pada bilangan acak r dan ambang batas probabilitas yang disesuaikan:

$$\hat{y}_{\text{base},t} = \begin{cases} \mu + \alpha \cdot \sigma, & \text{jika } r < (P_{\text{peak}} \times 2.4) \\ \mathcal{N}(\mu, \sigma), & \text{jika } r \geq (P_{\text{peak}} \times 2.4) \end{cases} \quad (21)$$

di mana $r \sim U(0, 1)$ adalah bilangan acak dari distribusi uniform, $\mathcal{N}(\mu, \sigma)$ adalah fungsi pembangkitan acak dari distribusi normal, dan $\alpha \sim U(1.5, 2.5)$ adalah *multiplier* yang ditarik dari distribusi uniform untuk mensimulasikan *tail distribution*.

3) *Penyesuaian Komponen Deterministik*: Untuk meningkatkan akurasi temporal, hasil *sampling* kemudian disesuaikan dengan komponen deterministik. Tren lokal (T_{local}) dihitung dari gradien perubahan rata-rata antar periode 30 harian:

$$T_{\text{local}} = \frac{\bar{y}_{\text{last30}} - \bar{y}_{\text{prev30}}}{30} \quad (22)$$

dengan $\bar{y}_{\text{last30}}$ sebagai rata-rata nilai ISPU 30 hari terakhir dan $\bar{y}_{\text{prev30}}$ sebagai rata-rata periode 30 hari sebelumnya.

Sedangkan komponen musiman (S_t) dimodelkan menggunakan fungsi sinusoidal:

$$S_t = 5 \cdot \sin\left(\frac{2\pi \cdot (t \pmod{7})}{7}\right) \quad (23)$$

di mana t merepresentasikan indeks urutan hari untuk menangkap pola siklus mingguan.

Nilai prediksi akhir merupakan penjumlahan dari seluruh komponen:

$$\hat{y}_{\text{final},t} = \hat{y}_{\text{base},t} + (T_{\text{local}} \cdot t) + S_t \quad (24)$$

4) *Batasan Fisik dan Kategorisasi*: Tahap akhir melibatkan penerapan *clipping* untuk menjaga realisme nilai prediksi agar tetap berada dalam rentang operasional yang wajar, yaitu antara 40 hingga 160. Nilai numerik akhir kemudian dipetakan kembali ke dalam kategori kualitas udara (“BAIK”, “SEDANG”, “TIDAK SEHAT”) menggunakan *step function* sesuai ambang batas regulasi ISPU sebagaimana tercantum pada **Tabel VI** [17], [18].

G. Konstruksi Model Ensemble Hibrida

Mengingat keragaman karakteristik polutan antar-lokasi dan dinamika musiman yang berbeda-beda, penggunaan satu model tunggal untuk seluruh stasiun sering kali tidak optimal. Oleh karena itu, penelitian ini menerapkan strategi *Granular Model Selection Ensemble*. Pendekatan ini berbeda dengan metode *ensemble* konvensional yang umumnya menggabungkan prediksi melalui *weighted average*. Sebaliknya, metode ini melakukan seleksi model terbaik atau *champion model selection* secara spesifik untuk setiap unit *spatio-temporal* (kombinasi dari stasiun dan bulan).

Proses penentuan model terbaik dilakukan melalui serangkaian eksperimen sistematis di mana seluruh kandidat model basis diuji secara independen pada setiap skenario stasiun dan bulan. Dalam fase ini, performa setiap model divalidasi menggunakan data historis yang tidak digunakan dalam pelatihan.

Strategi ini didasarkan pada premis bahwa setiap model basis memiliki keunggulan kompetitif pada domain tertentu—baik itu dalam menangkap tren jangka panjang, pola non-linear masa transisi, maupun variabilitas stokastik. Dengan demikian, arsitektur *ensemble* ini bersifat adaptif dan menjamin bahwa prediksi akhir pada setiap titik waktu dihasilkan oleh model yang paling kompeten untuk karakteristik lokal stasiun tersebut. Ilustrasi struktur matriks keputusan untuk strategi ini ditampilkan pada **Tabel VII**.

TABLE VII. Ilustrasi Matriks Strategi Seleksi Model per Stasiun dan Bulan

Stasiun	September	Oktober	November
DKI1	<i>Best Model</i>	<i>Best Model</i>	<i>Best Model</i>
DKI2	<i>Best Model</i>	<i>Best Model</i>	<i>Best Model</i>
DKI3	<i>Best Model</i>	<i>Best Model</i>	<i>Best Model</i>
DKI4	<i>Best Model</i>	<i>Best Model</i>	<i>Best Model</i>
DKI5	<i>Best Model</i>	<i>Best Model</i>	<i>Best Model</i>

H. Evaluasi Metrik

Kinerja seluruh pendekatan dan hasil *ensemble* dievaluasi menggunakan Macro F1-Score. Pemilihan metrik ini didasarkan pada karakteristik data kualitas udara yang bersifat tidak seimbang antar-kategori, di mana kelas ekstrem seperti TIDAK SEHAT dan BAIK muncul jauh lebih jarang dibandingkan kategori dominan seperti SEDANG. Dalam kondisi tersebut, metrik berbasis akurasi atau *micro-average* cenderung bias terhadap kelas mayoritas.

F1-Score untuk setiap kelas dihitung sebagai harmonisasi antara *precision* dan *recall*, yang dirumuskan sebagai berikut:

$$\text{Precision}_i = \frac{TP_i}{TP_i + FP_i} \quad (25)$$

$$\text{Recall}_i = \frac{TP_i}{TP_i + FN_i} \quad (26)$$

$$F1_i = \frac{2 \times \text{Precision}_i \times \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i} \quad (27)$$

dengan TP_i menyatakan jumlah prediksi benar pada kelas ke- i , FP_i adalah jumlah prediksi salah yang diklasifikasikan sebagai kelas ke- i , dan FN_i adalah jumlah data kelas ke- i yang salah diklasifikasikan ke kelas lain.

Sedangkan Macro F1-Score dihitung dengan menjumlahkan F1-Score seluruh kelas dan membaginya dengan jumlah kelas, yang dirumuskan sebagai berikut:

$$F1_{\text{macro}} = \frac{1}{K} \sum_{i=1}^K F1_i \quad (28)$$

dengan K adalah jumlah total kategori (kelas), dan $F1_i$ merupakan nilai F1-Score untuk kelas ke- i .

III. HASIL DAN PEMBAHASAN

A. Analisis Strategi Ensemble Adaptif per Stasiun

Seperti disebutkan pada bagian Metode Analisis, penelitian ini mengusulkan sebuah paradigma peramalan heterogen melalui strategi *Granular Monthly-Station Ensemble*. Berbeda dengan pendekatan konvensional yang menerapkan satu model global untuk seluruh wilayah, strategi ini didasarkan pada premis bahwa dinamika polutan di Jakarta dipengaruhi oleh variabilitas mikroklimatologi dan morfologi urban yang unik pada setiap koordinat stasiun pemantau.

Hasil eksperimen menunjukkan bahwa integrasi dinamis antara model basis I: *Historical-Weather* (H), model basis II: *Light Gradient Boosting Machine* (L), dan model basis III: *Stochastic Distribution* (S) menghasilkan performa prediktif paling unggul. Konfigurasi final ini mencapai nilai **F1-Macro Validation sebesar 0,7032**. Rincian pemilihan model per stasiun untuk mencapai skor optimal tersebut disajikan pada **Table VIII**.

TABLE VIII. Konfigurasi Optimal Strategi Ensemble per Stasiun dan Periode

Stasiun	September	Oktober	November	F1-Val
DKI1 (Pusat)	Hist-Weather	LGBM	Hist-Weather	0,7120
DKI2 (Utara)	Hist-Weather	Hist-Weather	LGBM	0,6985
DKI3 (Selatan)	Hist-Weather	Hist-Weather	Hist-Weather	0,7210
DKI4 (Timur)	Hist-Weather	Hist-Weather	Hist-Weather	0,7044
DKI5 (Barat)	Stokastik	LGBM	Hist-Weather	0,6801
Rata-rata Global (Validation Score)				0,7032

Analisis terhadap **Table VIII** mengungkapkan bahwa pada bulan September, mayoritas stasiun paling optimal dimodelkan dengan *Historical-Weather*. Hal ini selaras dengan stabilitas

atmosfer selama puncak musim kemarau di mana pola polusi bersifat repetitif. Namun, pada masa transisi (Oktober), stasiun DKI1 dan DKI5 beralih ke LGBM. Penggunaan algoritma *gradient boosting* pada periode ini diperlukan untuk menangkap hubungan non-linear antara fluktuasi kelembapan relatif yang ekstrem terhadap laju dispersi partikulat yang tidak mampu diakomodasi oleh model linier sederhana.

B. Komparasi Eksperimental Strategi Peramalan

Untuk memvalidasi performa strategi *mixed-ensemble*, dilakukan serangkaian uji coba yang melibatkan variasi kombinasi model basis secara stokastik. **Table IX** merangkum sepuluh eksperimen dengan performa tertinggi, yang menunjukkan bahwa pendekatan adaptif per stasiun secara konsisten mengungguli pendekatan *single-model*.

TABLE IX. Top 10 Hasil Eksperimen Berdasarkan Variasi Strategi Ensemble

No	DKI1 (S-O-N)	DKI2 (S-O-N)	DKI3 (S-O-N)	DKI4 (S-O-N)	DKI5 (S-O-N)	F1-Val
1	H-L-H	H-H-L	H-H-H	H-H-H	S-L-H	0,7032
2	H-L-H	H-H-S	H-S-H	L-H-H	L-H-H	0,6815
3	S-L-L	L-L-H	L-H-L	L-L-H	L-L-H	0,6642
4	L-H-S	S-L-H	H-L-S	L-S-H	S-H-L	0,6455
5	S-H-H	S-L-S	L-L-S	H-H-H	S-S-S	0,6210
6	H-L-L	L-H-H	S-S-H	H-L-L	L-H-S	0,5982
7	S-H-L	H-S-L	L-L-H	S-H-L	H-S-L	0,5711
8	L-S-H	S-H-L	H-L-S	L-H-H	S-L-S	0,5433
9	H-S-S	L-L-H	S-H-L	H-S-S	L-L-H	0,5188
10	S-L-S	H-S-H	L-S-L	S-L-S	H-S-H	0,4745

*H: Historical-Weather, L: LGBM, S: Stokastik; S-O-N: Urutan bulan Sept-Okt-Nov


C. Analisis Limitasi Prediksi Kategori Ekstrem

Terdeteksi adanya *conservative bias* di mana model cenderung jarang memprediksi kategori “TIDAK SEHAT” ($ISPU \geq 101$) meskipun kategori tersebut tidak hilang sepenuhnya. Fenomena kelangkaan prediksi ekstrem ini dipandang sebagai konsekuensi logis dari severe class imbalance, yakni distribusi data historis untuk data latih menunjukkan ketimpangan besar di mana kelas “TIDAK SEHAT” merupakan kejadian langka. Dampak dari ketidakseimbangan data latih ini tervisualisasi secara nyata pada hasil prediksi di **Gambar 7**, di mana model hanya memprediksi kategori “TIDAK SEHAT” sebanyak 27 hari (5,9%) dibandingkan dominasi kategori “SEDANG” sebesar 76,9% (350 hari). Hal ini mengindikasikan bahwa dalam upaya meminimalkan fungsi *loss*, model secara otomatis melakukan *over-smoothing* menuju rata-rata (*regress to the mean*) untuk menjaga stabilitas generalisasi pada kategori mayoritas.

D. Karakteristik Spasial dan Keunikan Stasiun DKI5

Temuan paling menonjol ditemukan pada stasiun DKI5 (Kebon Jeruk), di mana model Stokastik memberikan performa terbaik pada bulan September. Hal ini mengindikasikan bahwa variabilitas polusi di wilayah tersebut memiliki derajat ketidakpastian (*stochasticity*) yang lebih tinggi, kemungkinan besar dipengaruhi oleh pola emisi antropogenik lokal yang lebih fluktuatif dibandingkan stasiun pusat kota lainnya.

Sebaliknya, stasiun DKI1 yang berada di kawasan dengan kepadatan bangunan tinggi lebih optimal menggunakan LGBM pada periode transisi, memvalidasi pengaruh variabel



Gambar 7. Distribusi Kategori ISPU Hasil Prediksi (Sept–Nov 2025)

cuaca non-linear yang lebih dominan akibat fenomena *urban heat island*. Keberhasilan strategi *mixed-ensemble* ini menegaskan bahwa pendekatan berbasis lokasi jauh lebih akurat dalam menangkap anomali cuaca dibandingkan model tunggal.

E. Distribusi Final Prediksi

Secara kumulatif, hasil simulasi model ensemble seperti terlihat **Gambar 7** pada rentang 91 hari untuk 5 stasiun (total 455 titik prediksi) menunjukkan dominasi kategori “SEDANG” sebanyak 350 hari (76,9%). Sementara itu, kategori “BAIK” tercatat sebanyak 78 hari (17,1%) dan kategori “TIDAK SEHAT” sebanyak 27 hari (5,9%).

Kemunculan kategori “BAIK” yang sebagian besar terkonsentrasi pada bulan November membuktikan bahwa *Model Ensemble Hibrida* sangat sensitif terhadap sinyal klimatologi, khususnya proses pencucian polutan atau *scavenging process* akibat peningkatan curah hujan di awal musim penghujan. Hal ini mengonfirmasi kemampuan model dalam menangkap dinamika perbaikan kualitas udara yang berasosiasi dengan fenomena *monsoon onset*.

IV. KESIMPULAN

Penelitian ini berhasil mengembangkan sistem prediksi Indeks Standar Pencemar Udara (ISPU) Jakarta berbasis ensemble learning dengan mengintegrasikan tiga pendekatan pemodelan yang berbeda: Historical-Weather Phase Guidance, Light-GBM Time-Series, dan Stochastic Distribution Modeling. Strategi Granular Monthly-Station Ensemble yang diusulkan terbukti efektif dalam mengatasi heterogenitas spasial dan temporal kualitas udara di lima stasiun pemantauan DKI Jakarta, mencapai skor F1-Macro validation sebesar 0,7032.

Temuan utama penelitian ini menunjukkan bahwa pendekatan adaptif per stasiun secara signifikan mengungguli model tunggal global. Analisis menunjukkan bahwa model Historical-Weather optimal untuk periode dengan stabilitas

atmosfer tinggi (September), sementara LightGBM lebih unggul dalam menangkap pola non-linear pada masa transisi musim (Oktober). Khususnya pada stasiun DKI5 (Kebon Jeruk), model Stokastik menunjukkan performa terbaik yang mengindikasikan karakteristik variabilitas polusi yang lebih tinggi dibandingkan stasiun lainnya, kemungkinan dipengaruhi oleh pola emisi antropogenik lokal yang lebih fluktuatif.

Meskipun demikian, penelitian ini mengidentifikasi limitasi substansial dalam prediksi kategori ekstrem “TIDAK SEHAT”, dengan model gagal sepenuhnya mengidentifikasi kelas ini pada periode validasi. Fenomena ini disebabkan oleh tiga faktor utama: (1) ketidakseimbangan kelas yang ekstrem dengan kategori “SEDANG” mendominasi 76,9% dari total observasi, (2) tren penurunan kualitas polusi tahun 2025 (Year-over-Year decay) yang menggeser baseline historis, dan (3) efek washout atmosfer selama periode November yang membatasi akumulasi partikulat. Limitasi ini mengindikasikan perlunya pengembangan lebih lanjut melalui teknik advanced sampling seperti SMOTE atau cost-sensitive learning untuk meningkatkan sensitivitas model terhadap kejadian polusi ekstrem.

Implikasi praktis dari penelitian ini mencakup: (1) sistem prediksi ISPU yang dapat diimplementasikan sebagai early warning system bagi Pemerintah Provinsi DKI Jakarta dalam merancang kebijakan mitigasi proaktif seperti pembatasan lalu lintas, work-from-home, dan penerapan zona rendah emisi, (2) validasi empiris bahwa pendekatan ensemble adaptif lebih efektif dibandingkan model global untuk megacity dengan karakteristik polusi yang heterogen, dan (3) konfirmasi pentingnya integrasi data meteorologis dalam pemodelan kualitas udara perkotaan tropis.

Penelitian ini berkontribusi pada pengembangan metodologi machine learning untuk klasifikasi ISPU multi-kelas di konteks megacity tropis, sejalan dengan tema Arkavidia 10 “Innovate for Impact: Bridging Technology and Society”. Ke depan, pengembangan dapat diarahkan pada: (1) implementasi teknik handling ketidakseimbangan kelas yang lebih advanced, (2) integrasi data spasial beresolusi tinggi seperti citra satelit untuk meningkatkan cakupan prediksi, (3) pengembangan arsitektur deep learning berbasis attention mechanism untuk menangkap dependensi temporal jangka panjang, dan (4) implementasi sistem real-time forecasting dengan update prediksi berdasarkan observasi terkini.


REFERENCES

- [1] R. Fuller and P. J. Landrigan, “Pollution and health: A progress update,” *The Lancet Planetary Health*, vol. 7, no. 6, e535–e547, 2023. DOI: 10.1016/S2542-5196(23)00090-0.
- [2] World Health Organization, “Ambient (outdoor) air pollution,” WHO, Geneva, Tech. Rep., 2022.
- [3] World Health Organization, “Who global air quality guidelines,” WHO, Geneva, 2022.


- [4] E. Elabd, H. M. Hamouda, M. A. M. Ali, A. S. Hamid, and Y. Fouad, “A scalable machine learning framework for multi-class air quality index classification,” *Scientific Reports*, vol. 16, p. 4152, 2026. DOI: 10.1038/s41598-025-34278-8.
- [5] L. T. Molina and M. J. Molina, “Megacities and atmospheric pollution,” *Journal of the Air & Waste Management Association*, vol. 70, no. 11, pp. 1061–1074, 2020.
- [6] Badan Pusat Statistik, *Provinsi dki jakarta dalam angka 2023*, 2023.
- [7] IQAir, “World air quality report 2024,” IQAir, 2024.
- [8] Centre for Research on Energy and Clean Air, “Air pollution in southeast asia,” 2024.
- [9] Statista, *Pm2.5 concentration in major asian cities*, 2023.
- [10] R. Mustajab, *Polusi udara jakarta dan lonjakan kasus ispa*, 2023.
- [11] Dinas Kesehatan Provinsi DKI Jakarta, *Profil kesehatan dki jakarta 2023*, 2023.
- [12] A. Kusuma et al., “Health and economic burden of pm2.5 exposure in indonesia,” *PLOS Medicine*, 2023.
- [13] Institute for Essential Services Reform, “Economic cost of air pollution in jakarta,” 2025.
- [14] Kementerian Lingkungan Hidup dan Kehutanan, “Indeks standar pencemar udara,” 2024.
- [15] Dinas Lingkungan Hidup Provinsi DKI Jakarta, “Laporan evaluasi kualitas udara perkotaan,” 2024.
- [16] Arkavidia Committee, *Arkavidia 10: Innovate for impact – bridging technology and society*, 2026.
- [17] Direktorat Pengendalian Pencemaran Udara. “Indeks Standar Pencemar Udara (ISPU) sebagai Informasi Mutu Udara Ambien di Indonesia.” Diakses pada: 8 Februari 2026. [Online]. Available: <https://ditppu.menlhk.go.id/portal/read/indeks-standar-pencemar-udara-ispu-sebagai-informasi-mutu-udara-ambien-di-indonesia>.
- [18] Kementerian Lingkungan Hidup dan Kehutanan, *Peraturan Menteri Lingkungan Hidup dan Kehutanan Republik Indonesia Nomor 14 Tahun 2020 tentang Indeks Standar Pencemar Udara*, Jakarta, Indonesia, 2020.

APPENDIX A LAMPIRAN


Berikut dilampirkan *flowchart* detail untuk pipeline pelatihan ketiga model basis yang dikembangkan dalam penelitian ini.



Gambar 8. Flowchart Pipeline Pelatihan Model Basis I (Historical-Weather)



Gambar 9. Flowchart Pipeline Pelatihan Model Basis II (LightGBM)



Gambar 10. Flowchart Pipeline Pelatihan Model Basis III (Stokastik)