

DSC

Data Science Competition

ID Tim: DSC26082

MIDAS (*Multi-objective Integrated Dixon-Coles Adjusted Symmetric-Poisson*): Prediksi Skor Sepak Bola Internasional dengan *Gender-Stratified LightGBM* dan Kalibrasi Dixon-Coles Berbasis Distribusi Poisson

I. PENDAHULUAN

Analitika olahraga berbasis kecerdasan buatan tumbuh dengan CAGR 18,5% hingga 2033 [10], didorong kebutuhan prediksi berbasis data dalam industri yang bernilai 112 miliar dolar AS pada 2025 [11]. Namun, mayoritas model *machine learning* yang ada masih terbatas pada klasifikasi menang, seri, atau kalah [12], sehingga mengabaikan informasi skor eksak dan bobot signifikansi turnamen yang krusial bagi pengambil keputusan. Untuk menutup kesenjangan ini, penelitian ini mengusulkan [MIDAS](#), sebuah kerangka yang mengintegrasikan pendekatan statistik klasik dan *machine learning* modern guna memprediksi skor eksak pertandingan secara lebih akurat.

II. LANDASAN TEORI

A. Distribusi Poisson untuk Pemodelan Gol

Jumlah gol satu tim dalam satu laga adalah data cacah [1]. Probabilitas tim mencetak (k) gol dinyatakan sebagai:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

dengan λ sebagai rata-rata jumlah gol yang diharapkan.

B. Dixon-Coles

Model Dixon-Coles merupakan pengembangan regresi Poisson yang mengestimasi ekspektasi gol tim tuan rumah (λ) dan tim tamu (μ) berdasarkan kekuatan serang (α), kekuatan bertahan (β), dan keuntungan kandang (γ) [2]:

$$\lambda = \alpha_i \beta_j \gamma, \quad \mu = \alpha_j \beta_i$$

Keunggulan utama Dixon-Coles adalah fungsi koreksi (τ), yang menyesuaikan probabilitas skor rendah sehingga lebih sesuai dengan data pertandingan nyata:

$$Pr(X_{i,j} = x, Y_{i,j} = y) = \tau_{\lambda,\mu}(x, y) \frac{\lambda^x e^{-\lambda}}{x!} \frac{\mu^y e^{-\mu}}{y!}$$

C. LightGBM

LightGBM (*Light Gradient Boosting Machine*) adalah algoritma *gradient boosting* yang digunakan karena mendukung fungsi objektif Poisson sesuai pemodelan jumlah gol [3]. Dengan $\lambda = e^{f(x)}$, fungsi *loss* dinyatakan sebagai:

$$\mathcal{L} = \sum_{i=1}^n (e^{f(x_i)} - y_i f(x_i))$$

Selain itu, LightGBM mampu menangani *missing values* secara internal dan memiliki mekanisme regularisasi yang membantu mengurangi *overfitting* [5].

D. Metrik Evaluasi AW-MAE

AW-MAE (*Accuracy-Weighted Mean Absolute Error*) merupakan metrik utama yang digunakan. AW-MAE mempertimbangkan selisih gol, ketepatan skor, hasil pertandingan, serta [bobot turnamen](#). Kesalahan dasar dihitung menggunakan:

$$MAE = \frac{|tg_{pred} - tg_{aktual}| + |og_{pred} - og_{aktual}|}{2}$$

Kemudian ditambahkan [penalti](#) berdasarkan ketepatan skor eksak, hasil pertandingan, dan selisih gol, serta diperbesar jika arah hasil salah.

$$loss = ((MAE + penalti) \times multiplier)^{1.5}, AW - MAE = \frac{\sum_m loss_m \times w_{turnamen, m}}{\sum_m w_{turnamen, m}}$$

III. PROSES ANALISIS

A. Exploratory Data Analysis

[Perbedaan jumlah kolom](#) antara data *train* dan data *test* menjadi tantangan utama karena 25 fitur historis, seperti statistik performa tim, ELO, dan peringkat tim tidak tersedia pada data *test*. Analisis *missing values* dan korelasi menunjukkan bahwa fitur-fitur tersebut merupakan prediktor terkuat, sehingga perlu direkonstruksi sebelum proses prediksi. [Distribusi gol](#) menunjukkan perbedaan karakteristik antara pertandingan pria dan wanita, sementara [distribusi hasil pertandingan](#) tidak seimbang pada jumlah hasil seri. Data juga mengkonfirmasi adanya [team advantage](#) serta [mirror symmetry](#), di mana setiap pertandingan direkam dari perspektif kedua tim. Temuan-temuan ini menjadi dasar dalam perancangan fitur dan pemilihan metode pemodelan.

B. Data Preprocessing

Tahap pra pemrosesan dilakukan untuk memastikan kualitas data sebelum pemodelan. Nilai anomali pada [altitude venue](#) sebesar -9999 diubah menjadi *NaN*, melakukan [label encoding](#) pada kolom *confederation*, dan *null values* pada *tournament* diimputasi serta dinormalisasi formatnya. Selain itu, kolom *date* dikonversi menjadi tipe tanggal untuk mendukung pengolahan temporal, sedangkan baris yang tidak memiliki nilai target gol dihapus karena tidak dapat digunakan dalam proses pelatihan model.

C. Rekayasa Fitur

Fitur-fitur yang tidak terdapat pada data *test* direkonstruksi secara kronologis menggunakan *sliding window* dan secara *real-time*. Selain itu, [rating ELO](#) dibangun ulang dari skor dasar 1500 dan diperbarui secara sekuensial menggunakan *Tournament-Weighted K-Factor* untuk merepresentasikan kekuatan tim secara dinamis [4]. Untuk memperkaya informasi, ditambahkan [fitur turunan](#) seperti probabilitas kemenangan berbasis ELO, *rating* serangan dan pertahanan berbasis *exponential weighted moving average*, *expected goals* [7], statistik historis gol dan kebobolan, serta *log-transform* pada fitur sosioekonomi guna menormalkan distribusi data.

D. Skema Validasi dan Desain Pemodelan

Validasi dilakukan dengan memisahkan data berdasarkan *gender* untuk mengakomodasi perbedaan distribusi gol, serta menerapkan [mirror symmetry enforcement](#) guna mengurangi bias antara perspektif tim dan lawan. Data kemudian diurutkan secara kronologis dan dibagi menggunakan [hold-out chronological split](#) (80% latih, 20% validasi). Dilakukan *hyperparameter tuning* menggunakan Optuna [6] dengan 5 *k-fold* sebelum model final dilatih pada seluruh data *train*. Pemodelan menggunakan pendekatan hibrida yang menggabungkan LightGBM dan Dixon-Coles. LightGBM dipilih karena memberikan performa terbaik dibanding model *boosting* lainnya. Prediksi akhir diperoleh dengan menggunakan Dixon-Coles untuk pertandingan yang timpang dan LightGBM untuk pertandingan yang lebih seimbang.

IV. HASIL ANALISIS

A. Performa Model

[Integrasi LightGBM dan Dixon-Coles](#) menghasilkan performa terbaik pada seluruh metrik evaluasi. Model hibrida mencapai AW-MAE 1,5871, akurasi hasil 72,83%, ketepatan skor eksak 16,54%, dan MAE gol 0,763, melampaui kedua model tunggal yang diuji.

Tabel 1. Perbandingan Model Akhir

Model	AW-MAE	Outcome Acc	Exact Score	MAE Goals
Dixon-Coles	2,1053	60,14%	11,37%	0,934
LightGBM (<i>tuned</i>)	1,8342	67,41%	14,23%	0,841
LightGBM (<i>tuned</i>) + Dixon-Coles	1,5871	72,83%	16,54%	0,763

Meskipun Dixon-Coles memiliki AW-MAE yang lebih tinggi dibandingkan LightGBM, model ini menunjukkan akurasi hasil yang lebih baik berkat kalibrasi probabilitas yang dihasilkannya. Ketika dikombinasikan dengan LightGBM, AW-MAE turun 13,5% dibandingkan LightGBM, sementara akurasi hasil meningkat lebih dari 5%. Hasil ini menunjukkan bahwa kedua pendekatan saling melengkapi dalam meningkatkan kualitas prediksi.

B. Interpretasi dan Analisis Kesalahan Model

Faktor paling berpengaruh dalam prediksi adalah kekuatan historis tim yang direpresentasikan oleh fitur ELO dan faktor sosioekonomi, sementara *temperature_venue* berperan sebagai proksi bagi faktor lain. Model masih mengalami kesulitan dalam memprediksi hasil seri (recall 52,5%) dan pertandingan dengan skor sangat ekstrem. Meskipun demikian, model umumnya mampu mengenali arah hasil pertandingan dengan baik dengan recall 82,1% untuk kemenangan dan 76,1% untuk kekalahan.

V. KESIMPULAN DAN REKOMENDASI

A. Kesimpulan

Penelitian ini mengembangkan MIDAS, kerangka hibrida prediksi skor sepak bola internasional yang menggabungkan LightGBM terstratifikasi gender dan kalibrasi Dixon-Coles berbasis distribusi Poisson. Hasil penelitian menunjukkan bahwa rekayasa fitur historis berperan penting dalam menghasilkan prediksi yang akurat, dengan LightGBM menjadi model dasar terbaik di antara model yang diuji. Integrasi dengan kalibrasi Dixon-Coles meningkatkan kinerja model hingga mencapai AW-MAE 1,5871 dan akurasi hasil pertandingan 72,83%, sehingga mengungguli seluruh model tunggal. Meskipun demikian, model masih memiliki keterbatasan dalam memprediksi hasil seri dan pertandingan dengan skor yang sangat ekstrem.

B. Rekomendasi


Beberapa pengembangan dapat dilakukan pada penelitian selanjutnya. Untuk meningkatkan prediksi hasil seri, dapat digunakan distribusi Poisson bivariat yang memodelkan ketergantungan gol kedua tim. Selain itu, fitur yang berpotensi menjadi proksi, seperti *temperature_venue*, perlu dikaji lebih lanjut agar interpretasi model tetap valid.

DAFTAR PUSTAKA

- [1] M. J. Maher, "Modelling association football scores," *Statistica Neerlandica*, vol. 36, no. 3, pp. 109–118, 1982. doi: 10.1111/j.1467-9574.1982.tb00782.x.
- [2] M. J. Dixon and S. G. Coles, "Modelling association football scores and inefficiencies in the football betting market," *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, no. 2, pp. 265–280, 1997. doi: 10.1111/1467-9876.00065.
- [3] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, Long Beach, CA, USA, 2017, pp. 3146–3154. [Online]. Tersedia: <https://papers.nips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree>
- [4] A. E. Elo, *The Rating of Chessplayers, Past and Present*. New York, NY, USA: Arco Publishing, 1978.
- [5] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD '16)*, San Francisco, CA, USA, 2016, pp. 785–794. doi: 10.1145/2939672.2939785.
- [6] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proc. 25th ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD '19)*, Anchorage, AK, USA, 2019, pp. 2623–2631. doi: 10.1145/3292500.3330701.
- [7] J. Mead, A. O'Hare, and P. McMenemy, "Expected goals in football: Improving model performance and demonstrating value," *PLoS ONE*, vol. 18, no. 4, p. e0282295, 2023. doi: 10.1371/journal.pone.0282295.

- [8] R. Pollard, "Home advantage in soccer: A retrospective analysis," *Journal of Sports Sciences*, vol. 4, no. 3, pp. 237–248, 1986. doi: 10.1080/02640418608732122.
- [9] D. Karlis and I. Ntzoufras, "Analysis of sports data by using bivariate Poisson models," *Journal of the Royal Statistical Society: Series D (The Statistician)*, vol. 52, no. 3, pp. 381–393, 2003. doi: 10.1111/1467-9884.00366.
- [10] Grand View Research, "Sports analytics market size, share & trends analysis report," Grand View Research, San Francisco, CA, USA, 2024. [Online]. Tersedia: <https://www.grandviewresearch.com/industry-analysis/sports-analytics-market>
- [11] The Insight Partners, "Sports technology market size and forecasts (2023–2031)," The Insight Partners, Pune, India, 2024. [Online]. Tersedia: <https://www.theinsightpartners.com/en/reports/sports-technology-market>
- [12] J. Hucaljuk and A. Rakipović, "Predicting football scores using machine learning techniques," in *Proc. 34th Int. Convention MIPRO*, Opatija, Croatia, 2011, pp. 1623–1627.

LAMPIRAN



Gambar 1. Workflow Diagram

Tabel 2. Bobot Turnamen

Turnamen	Bobot
FIFA World Cup	2.00
UEFA Euro	1.90
Copa America	1.90
AFC Asian Cup	1.80
AFC Championship	1.80
Africa Cup of Nations	1.80
CONCACAF Gold Cup	1.80
Gold Cup	1.80
OFC Nations Cup	1.80
Confederations Cup	1.70
Olympic Games	1.60
UEFA Nations League	1.60
Friendly	0.96

Tabel 3. Komponen Penalti AW-MAE

Komponen	Benar	Salah
Skor eksak	+0	+0,30
Arah hasil (W/D/L)	+0	+0,25
Selisih Gol	+0	+0,15


Train shape : (78772, 47)
Test shape : (42422, 20)

Terdapat **25 missing columns** di data test (di luar target)


Missing Columns on Test

- team_points_last5
- opp_points_last5
- points_last5_diff
- team_gd_last5
- opp_gd_last5
- gd_last5_diff
- h2h_points_last5
- h2h_gd_last5
- days_since_last_match_team
- days_since_last_match_opp
- team_points_last10
- opp_points_last10
- team_avg_goals_last5
- team_avg_conceded_last5
- opp_avg_goals_last5
- opp_avg_conceded_last5
- team_win_rate_last10
- opp_win_rate_last10
- elo_team
- elo_opponent
- rank_team
- rank_opponent
- rank_diff
- rank_missing_team
- rank_missing_opp


Gambar 2. Kolom Hilang pada Data Uji



Gambar 3. Distribusi Gol dan Kecocokan Poisson



Gambar 4. Distribusi Hasil



Gambar 5. Home Advantage

Match 0001	Row A: SCO 0-0 ENG	Row B: ENG 0-0 SCO	[OK] Mirror OK
Match 0002	Row A: ENG 4-2 SCO	Row B: SCO 2-4 ENG	[OK] Mirror OK
Match 0003	Row A: SCO 2-1 ENG	Row B: ENG 1-2 SCO	[OK] Mirror OK
Match 0004	Row A: ENG 2-2 SCO	Row B: SCO 2-2 ENG	[OK] Mirror OK
Match 0005	Row A: SCO 3-0 ENG	Row B: ENG 0-3 SCO	[OK] Mirror OK
Match 0006	Row A: SCO 4-0 WAL	Row B: WAL 0-4 SCO	[OK] Mirror OK
Match 0007	Row A: ENG 1-3 SCO	Row B: SCO 3-1 ENG	[OK] Mirror OK
Match 0008	Row A: WAL 0-2 SCO	Row B: SCO 2-0 WAL	[OK] Mirror OK

Gambar 6. Ilustrasi *Mirror Symmetry*

Id	match_id	altitude_venue
7096	M003549_Fiji	M003549
7097	M003549_New Zealand	M003549
7302	M003652_Fiji	M003652
7303	M003652_New Zealand	M003652
7306	M003654_Fiji	M003654
...	...	...
78767	M034981_Mayotte	M034981
78768	M034982_Seychelles	M034982
78769	M034982_Comoros	M034982
78770	M034983_Maldives	M034983
78771	M034983_Mauritius	M034983

766 rows x 3 columns


➔

Id	match_id	altitude_venue
7096	M003549_Fiji	M003549
7097	M003549_New Zealand	M003549
7302	M003652_Fiji	M003652
7303	M003652_New Zealand	M003652
7306	M003654_Fiji	M003654
...	...	...


Gambar 7. Penanganan Nilai Anomali

['confederation_team'] / ['confederation_opp']	
UEFA	0
CONMEBOL	1
CAF	2
AFC	3
CONCACAF	4
OFC	5
NaN	6


Gambar 8. Label Encoding




Gambar 9. Rekonstruksi Fitur ELO Two Pass



Gambar 10. Rekonstruksi Fitur Turunan



Gambar 11. Mirror Symmetry Enforcement




Gambar 12. Hold-Out Chronological Split

Tabel 4. Baseline Benchmarking


Model	AW-MAE	Outcome Acc	Exact Score	MAE Goals
XGBoost	2,5214	54,73%	9,47%	1,067
CatBoost	2,4873	55,89%	9,93%	1,041
Ensemble	2,3591	57,15%	10,21%	1,014
LightGBM	2,2137	58,32%	10,84%	0,982

Tabel 5. Hyperparameter Tuning (LightGBM)


Model	AW-MAE	Outcome Acc	Exact Score	MAE Goals
Before Tuning	2,2137	58,32%	10,84%	0,982
After Tuning	1,8342	67,41%	14,23%	0,841




Gambar 13. Alur Pelatihan Dixon-Coles



Gambar 14. Integrasi LightGBM dan Dixon-Coles



Gambar 15. Feature Importance



Gambar 16. *Confusion Matrix*