

TREX: Deteksi Serangan Manipulasi Wajah Berbasis *Triple-Component Register Encoder eXtractor*

Muhammad Naufal Muzaki, Marvel Irawan, Rafsanjani

Fakultas Ilmu Komputer

Universitas Indonesia

Depok, Indonesia

{muhammad.naufal419, marvel.irawan, rafsanjani41} @ui.ac.id

Intisari—Sistem deteksi serangan manipulasi wajah atau *Face Anti-Spoofing* (FAS) menghadapi tantangan berat ketika beroperasi pada keragaman serangan yang tinggi, mulai dari cetakan dua dimensi hingga topeng tiga dimensi dan serangan tak terdefinisi. Penelitian ini mengusulkan TREX (*Triple-component Register Encoder eXtractor*), sebuah *pipeline* FAS berbasis *Vision Foundation Model* yang secara eksplisit dirancang untuk mendeteksi sinyal artefak tekstur mikroskopis dari berbagai jenis serangan manipulasi wajah. Arsitektur yang diusulkan memadukan *backbone* DINOv2 dengan *register tokens* sebagai ekstraktor fitur tekstur lokal yang bersih, mekanisme *dual-stream Multi-Head Attention Pooling* untuk agregasi representasi yang adaptif dari aliran *CLS token* dan *register token* secara terpisah. Optimasi dilakukan menggunakan fungsi kerugian komposit tiga komponen yang menggabungkan *Asymmetric Angular Margin Softmax*, *Self-Supervised Similarity Loss*, dan *Supervised Contrastive Loss* untuk mengoptimasi ketajaman batas keputusan, konsistensi representasi lokal, dan pemisahan kluster antar kelas secara simultan. Pelatihan menggunakan skema *5-Fold Cross Validation* dengan *discriminative learning rates* dan inferensi berbasis *Softmax Ensemble*. Hasil eksperimen menunjukkan bahwa TREX mencapai *F1-Macro* sebesar 0.981 pada set validasi, melampaui *baseline* CNN konvensional dan DINOv2 dengan *Mean Pooling* standar, memvalidasi efektivitas integrasi *Vision Foundation Model* dengan strategi agregasi adaptif untuk tugas pengenalan tekstur halus.

Kata Kunci—*Face Anti-Spoofing*, DINOv2, *Self-Supervised Learning*, *Vision Transformer*, *Attention Pooling*, *Patch Recognition*, *Register Tokens*, *Supervised Contrastive Learning*

I. PENDAHULUAN

Sistem pengenalan wajah telah menjadi komponen keamananan biometrik yang tidak terpisahkan dalam kehidupan modern, mulai dari autentikasi perangkat hingga kontrol akses fasilitas kritis. Namun, ketersediaan citra wajah secara luas di media sosial membuka peluang eksploitasi melalui *spoofing attack* yang kian canggih, mulai dari foto cetak sederhana hingga topeng tiga dimensi berteknologi tinggi. Kemampuan sistem untuk membedakan wajah asli dari berbagai bentuk manipulasi, yang dikenal sebagai *Face Anti-Spoofing* (FAS), menjadi lapisan pertahanan kritis yang harus diselesaikan sebelum tahap pengenalan wajah dieksekusi [1].

Latar Belakang. Tantangan FAS pada penelitian ini bersumber dari empat kondisi dataset yang berat secara bersamaan:

(1) ukuran dataset kecil, (2) distribusi kelas sangat tidak seimbang, (3) keragaman serangan mencakup spektrum luas dari serangan dua dimensi (*fake_printed*, *fake_screen*), tiga dimensi (*fake_mask*, *fake_mannequin*), hingga serangan tak terdefinisi (*fake_unknown*), dan (4) kemiripan visual tinggi yang hanya dapat dibedakan melalui sinyal artefak tekstur mikroskopis. Pendekatan berbasis CNN konvensional seperti CDCN++ [2] dan NAS-FAS [3] menunjukkan degradasi kinerja signifikan pada kondisi ini, sementara *pipeline* berbasis *Vision Transformer* [14] dengan *Mean Pooling* standar mendilusi sinyal artefak lokal dalam proses rata-rata representasi.

Tujuan, Manfaat, dan Kontribusi. Penelitian ini bertujuan membangun sistem FAS yang *robust* terhadap keragaman serangan dan ketidakseimbangan kelas ekstrem melalui *Vision Foundation Model* berbasis *patch*. Kontribusi teknis penelitian ini meliputi:

- Arsitektur TREX yang mengintegrasikan DINOv2 *register tokens* [4], [5] dengan *dual-stream Multi-Head Attention Pooling* [6] pada aliran *CLS token* dan *register token* secara terpisah;
- Fungsi kerugian komposit yang menggabungkan AAMS [7], [8], *Self-Supervised Similarity Loss*, dan SupCon [9] untuk mengoptimasi ketajaman batas keputusan, konsistensi representasi lokal, dan pemisahan kluster antar kelas secara simultan;
- Strategi *patch sampling dual-mode* yang mempertahankan detail tekstur resolusi tinggi melalui ekstraksi *patch* 224×224 piksel tanpa operasi *resize*, dikombinasikan dengan augmentasi berlapis yang mensimulasikan artefak serangan dunia nyata.

Batasan Masalah. Penelitian ini dibatasi pada beberapa ruang lingkup berikut. Evaluasi dilakukan secara eksklusif pada dataset kompetisi yang telah ditetapkan tanpa pengujian lintas dataset (*cross-dataset*). *Backbone* yang digunakan dibatasi pada varian DINOv2-Base (ViT-B/14) dengan pertimbangan efisiensi komputasi pada infrastruktur dua GPU NVIDIA T4. Sistem dioptimalkan untuk memaksimalkan F1-Macro dalam konteks kompetisi dan belum dioptimalkan untuk kebu-

tuhan inferensi *real-time*. Selain itu, kelas *fake_unknown* yang tidak memiliki definisi artefak yang konsisten diperlakukan sebagai kelas tunggal tanpa dekomposisi lebih lanjut.

II. KAJIAN PUSTAKA

Metode Face Anti-Spoofing. Pendekatan awal dalam deteksi serangan manipulasi wajah didominasi oleh metode berbasis **CNN** yang mengandalkan supervisi piksel-level, seperti **CDCN++** [2] yang mengekstraksi fitur kedalaman wajah dan **NAS-FAS** [3] yang mengoptimalkan arsitektur jaringan melalui *Neural Architecture Search*. Meskipun efektif pada skenario yang dikenal, metode-metode ini menunjukkan degradasi kinerja yang signifikan terhadap jenis serangan baru yang tidak termasuk dalam data pelatihan. Liu dkk. [20] memperkenalkan pendekatan multi-supervisi yang menggabungkan klasifikasi biner dengan estimasi kedalaman wajah. Pendekatan berbasis *Vision Transformer* kemudian dieksplorasi melalui TransFAS [21] yang memperkenalkan mekanisme *relation-aware* untuk menangkap dependensi antar *patch*. Wang dkk. [7] mengusulkan **PatchNet** yang mereformulasi **FAS** sebagai masalah pengenalan tekstur lokal berbasis *patch*, memperkenalkan *Asymmetric Angular Margin Softmax* dan *Self-Supervised Similarity Loss* yang menginspirasi desain fungsi kerugian pada penelitian ini. Lebih lanjut, Feng dkk. [1] mendemonstrasikan efektivitas **DINOv2** dengan *register tokens* untuk **FAS** menggunakan strategi pencairan parsial pada blok *encoder* terakhir. Penelitian ini memperluas pendekatan tersebut dengan mengintegrasikan *patch-based sampling*, mekanisme *Multi-Head Attention Pooling* pada dua aliran representasi, dan fungsi kerugian komposit tiga komponen untuk menangani tantangan dataset yang lebih kompleks dan tidak seimbang.

Vision Foundation Models dan Mekanisme Attention. **DINOv2** [4] memperkenalkan paradigma pelatihan *self-supervised* berskala besar pada 142 juta citra yang dikurasi, melanjutkan keberhasilan pendekatan sebelumnya seperti DINO [15] yang menemukan properti *emergent* pada *Vision Transformer* [14], serta MAE [16] dan SimCLR [17] yang menjadi pilar pembelajaran representasi tanpa supervisi. Darcet dkk. [5] mengidentifikasi fenomena *artifact* pada ViT standar, dengan sebagian *patch tokens* menyerap informasi global yang tidak relevan, dan mengusulkan *register tokens* sebagai solusi untuk menghasilkan representasi lokal yang lebih bersih. Fondasi mekanisme *attention* yang digunakan dalam penelitian ini berakar pada arsitektur Transformer [6], yang memungkinkan model untuk secara selektif memusatkan perhatian pada region yang paling informatif melalui operasi *query-key-value*. Integrasi ketiga elemen ini, representasi *pre-trained DINOv2*, *register tokens* untuk kebersihan representasi lokal, dan *attention pooling* untuk agregasi adaptif, membentuk fondasi arsitektur TREX yang diusulkan.

Representasi Kontrasif dan Optimasi. Khosla dkk. [9] mengusulkan *Supervised Contrastive Loss (SupCon)* yang memperluas pembelajaran kontrasif ke skenario tersupervisi dengan memanfaatkan seluruh sampel sekelas sebagai *positives*, menghasilkan representasi yang lebih robust terhadap

korupsi data dan lebih stabil terhadap variasi hiperparameter dibanding *Cross-Entropy* standar. Deng dkk. [8] memperkenalkan *Additive Angular Margin Loss (ArcFace)* yang memproyeksikan fitur ke dalam ruang *hypersphere* untuk menciptakan batas keputusan yang lebih tajam, prinsip yang diadaptasi secara asimetris per kelas dalam penelitian ini. Smith [11] mendemonstrasikan fenomena *super-convergence* di mana penggunaan *learning rate* tinggi dalam satu siklus pelatihan dapat menghasilkan konvergensi yang lebih cepat dengan kinerja yang lebih baik, menjadi dasar penjadwalan *OneCycleLR* yang digunakan untuk *fine-tuning backbone pretrained*. Kombinasi ketiga strategi optimasi ini dirancang secara sinergis untuk mengatasi tantangan spesifik dataset **FAS**: ketidakseimbangan kelas, batas antar-kelas yang tipis, dan risiko *catastrophic forgetting* pada *backbone pretrained*.

III. METODOLOGI

A. Gambaran Umum Pipeline


Sistem deteksi *face anti-spoofing* yang diusulkan dirancang berdasarkan premis bahwa serangan manipulasi wajah pada hakikatnya meninggalkan jejak tekstur mikroskopis, seperti pola *Moiré* pada layar digital dan kehilangan detail pori-pori pada cetakan kertas, yang tidak dapat dideteksi secara andal melalui pendekatan klasifikasi wajah konvensional. Oleh karena itu, *pipeline* yang diusulkan secara eksplisit dirancang untuk mengincar sinyal lokal berresolusi tinggi tersebut, bukan fitur makroskopis wajah.

Secara keseluruhan, *pipeline* terdiri dari lima tahapan utama yang saling terintegrasi, sebagaimana diilustrasikan pada Gambar 1. (1) **Pra-pemrosesan**: deteksi dan pemotongan wajah secara *offline* menggunakan **YOLOv8-Face** [10] dengan rotasi otomatis untuk menghasilkan citra yang terstandarisasi. (2) **Augmentasi data**: tiga lapis transformasi yang mensimulasikan artefak serangan *spoofing* di dunia nyata. (3) **Pengambilan patch**: ekstraksi potongan 224×224 piksel untuk mempertahankan detail tekstur resolusi tinggi dan mendorong pembelajaran representasi lokal. (4) **Ekstraksi fitur**: setiap *patch* diproses oleh *backbone DINOv2* [4] dengan *register tokens* [5] dan diagregasi melalui *Multi-Head Attention Pooling*. (5) **Optimasi**: fungsi kerugian komposit **AAMS** [7], $\mathcal{L}_{\text{Sim}}$, dan **SupCon** [9] dengan bobot kelas adaptif.

Proses pelatihan dilaksanakan dengan skema *5-Fold Cross Validation* menggunakan strategi *discriminative learning rates* dan penjadwalan *OneCycleLR* [11]. Pada tahap inferensi, prediksi akhir diperoleh melalui *Test-Time Augmentation (TTA)* spasial yang dikombinasikan dengan *softmax ensemble* dari kelima model hasil pelatihan tiap *fold*. Desain ini secara sinergis menjamin robustisitas prediksi terhadap variasi orientasi dan kondisi pencitraan yang tidak terduga.

B. Pra-pemrosesan Data

Kualitas area lokalisasi wajah secara langsung memengaruhi kemampuan model dalam membedakan fitur *liveness* sejati dan artefak *spoofing*. Oleh karena itu, kami merancang modul pra-pemrosesan yang tangguh sebelum citra dimasukkan ke dalam *pipeline* utama. Tahapan ini mencakup deteksi wajah



Gambar 1: Gambaran *pipeline* TREX yang terdiri dari tiga tahap utama. **(Kiri)** Tahap persiapan data: citra masukan diproses oleh YOLO untuk menghasilkan area wajah berukuran 448×448 pixel, kemudian diekstraksi menjadi $N = 5$ patch acak pada fase pelatihan dan $N = 9$ patch deterministik pada fase pengujian, berukuran 224×224 pixel. **(Tengah)** Tahap ekstraksi fitur: setiap patch diproses oleh backbone DINOv2 dengan 12 blok encoder Transformer, menghasilkan CLS token dan register tokens. **(Kanan)** Tahap klasifikasi: kedua aliran representasi diintegrasikan secara terpisah melalui Attention Pooling, diproyeksikan, lalu digabungkan melalui konkatenasi menjadi vektor sebelum diklasifikasikan ke dalam 6 kelas. Pelatihan dioptimasi menggunakan fungsi kerugian komposit AAMS, $\mathcal{L}_{\text{Sim}}$, dan $\mathcal{L}_{\text{SupCon}}$.

luring, mekanisme rotasi otomatis, dan pemotongan dengan contextual margin.

Deteksi Wajah Luring. Proses lokalisasi *Region of Interest (RoI)* dieksekusi menggunakan arsitektur deteksi objek **YOLOv8m-Face** [10] yang telah disesuaikan secara khusus untuk deteksi wajah. Model ini dipilih karena kemampuannya mendeteksi wajah dengan presisi tinggi pada berbagai kondisi pencahayaan dan resolusi, termasuk pada citra yang mengandung objek serangan fisik seperti topeng dan manekin. Pendekatan ini memastikan *backbone* utama hanya menerima piksel yang secara semantik relevan dengan area wajah, sehingga menghilangkan *noise* dari latar belakang visual yang tidak berkaitan.

Mekanisme Rotasi Otomatis (Auto-Rotation). Citra dari perangkat seluler sering kali memiliki metadata orientasi yang tidak konsisten atau rotasi tangkapan layar yang bervariasi. Untuk menjaga rasio perolehan (*recall*) deteksi tetap maksimal, kami mengimplementasikan mekanisme rotasi otomatis iteratif. Jika deteksi **YOLOv8** gagal pada orientasi orisinal (0 derajat), citra secara otomatis dirotasi secara berurutan sebesar 90, 180, dan 270 derajat hingga *bounding box* wajah berhasil diidentifikasi dengan *confidence score* yang memenuhi ambang batas. Hal ini memastikan tidak ada sampel data berharga yang tereliminasi akibat kegagalan deteksi trivial.

Pemotongan dengan Contextual Margin. Pemotongan wajah yang terlalu ketat (*tight crop*) berisiko menghilangkan informasi tepi yang krusial, seperti tepian topeng tiga dimensi atau batas kertas pada serangan cetak. Untuk menghindari hal ini, *bounding box* hasil deteksi diperluas dengan faktor margin $m = 1,0$ relatif terhadap dimensi kotak tersebut pada keempat sisinya. Strategi ini memastikan model memperoleh konteks visual yang memadai di sekitar batas wajah tanpa mengorbankan fokus terhadap region wajah utama.


C. Augmentasi Data

Dalam domain *face anti-spoofing*, augmentasi data memiliki peran yang melampaui sekadar perluasan dataset. Augmentasi

difungsikan sebagai *attack simulator*, sebuah mekanisme yang secara aktif menyuntikkan artefak serangan sintesis ke dalam citra pelatihan untuk memaksa model mempelajari fitur tekstur yang invariant terhadap kondisi serangan yang beragam. Tanpa strategi ini, model berbasis *Vision Transformer* yang dilatih pada dataset berukuran kecil berisiko tinggi mengalami *overfitting* terhadap bias visual spesifik dataset. *Pipeline* augmentasi yang diusulkan disusun dalam tiga lapis pertahanan yang saling melengkapi menggunakan pustaka Albumentations [12].

Lapis Pertama: Pertahanan Spasial dan Geometris. Lapis pertama bertujuan membangun invariansi model terhadap variasi posisi dan orientasi wajah. Transformasi *horizontal flip* [7] diterapkan dengan probabilitas $p = 0,5$, sedangkan *ShiftScaleRotate* mensimulasikan pergeseran posisi, perubahan skala, dan rotasi ringan hingga ± 15 dengan probabilitas $p = 0,5$. Kedua transformasi ini memastikan model tidak menghafal posisi wajah atau *framing* kamera tertentu sebagai sinyal klasifikasi. Rentang rotasi dibatasi pada ± 15 untuk menjaga keutuhan hubungan spasial antar fitur wajah sekaligus menghindari distorsi geometris yang tidak realistis. Penting untuk dicatat bahwa seluruh transformasi pada lapis ini bersifat *texture-preserving* — tidak mengubah konten frekuensi citra — sehingga sinyal artefak mikroskopis yang menjadi target deteksi tetap utuh untuk diproses oleh lapis augmentasi berikutnya.

Lapis Kedua: Simulasi Artefak Serangan. Lapis kedua merupakan inti dari strategi augmentasi yang diusulkan, dirancang untuk meniru jejak fisik dan digital yang ditinggalkan oleh masing-masing jenis serangan. Interferensi piksel layar disimulasikan melalui distorsi kisi dan distorsi optik yang mereproduksi pola *Moiré* mikroskopis pada serangan *fake_screen* ($p = 0,30$). Hilangnya detail frekuensi tinggi pada serangan cetakan (*fake_printed*) direproduksi melalui kompresi JPEG agresif dengan rentang kualitas [30, 80] dan penurunan resolusi hingga 50% ($p = 0,45$). Derau sensor kamera pada kondisi pencahayaan rendah disimulasikan menggunakan berbagai varian *Gaussian* dan *multiplicative noise* ($p = 0,40$). Tera-



Gambar 2: Visualisasi augmentasi lapis kedua pada dua kelas representatif (*realperson* dan *fake_screen*). Setiap kolom merepresentasikan satu jenis simulasi artefak serangan. Augmentasi diterapkan pada kedua kelas untuk memaksa model membedakan artefak serangan dari variasi kondisi akuisisi citra yang alami.

khir, variasi ketajaman akibat *defocus* direproduksi melalui kombinasi *blur* dengan ukuran kernel [3, 7] dan *sharpening* ($p = 0,35$). Keempat simulasi ini secara kolektif menghasilkan *hard positives* yang mempersulit model untuk mengandalkan sinyal tekstur superfisial dalam membuat keputusan klasifikasi, sebagaimana diilustrasikan pada Gambar 2.

Lapis Ketiga: Variasi Warna dan Pencahayaan. Lapis ketiga memastikan model tidak tertipu oleh manipulasi pencahayaan yang kerap dieksploitasi penyerang. Variasi warna akibat pantulan cahaya layar dan pudarnya tinta *printer* disimulasikan melalui *color jitter* dengan rentang kecerahan dan kontras $\pm 0,25$ serta saturasi $\pm 0,35$ ($p = 0,50$). Kondisi pencahayaan tidak merata, seperti kilatan *flash* yang menerangi sebagian wajah secara berlebihan, direproduksi melalui *random shadow* dan variasi kurva nada ($p = 0,20$).

Tabel I: Jenis Serangan dan Strategi Augmentasi


Jenis Serangan	Augmentasi yang Mensimulasikan
<i>fake_screen</i>	Distorsi kisi & optik (pola <i>Moiré</i>), <i>color jitter</i> (pantulan cahaya layar)
<i>fake_printed</i>	Kompresi JPEG dengan kualitas [30, 80], penurunan resolusi hingga 50%, variasi warna (tinta pudar)
<i>fake_mask</i> <i>fake_mannequin</i>	<i>Random shadow</i> , variasi kurva nada (pencahayaan tidak merata)
<i>fake_unknown</i>	Derau sensor kamera, <i>defocus blur</i> (kombinasi multi-artefak)
Semua kelas	<i>Flip horizontal</i> , <i>ShiftScaleRotate</i> , <i>Gaussian noise</i>

D. Strategi Pengambilan Patch

Pendekatan klasifikasi wajah konvensional yang memasukkan seluruh citra secara langsung ke dalam model memiliki kelemahan mendasar dalam konteks *face anti-spoofing*: sinyal manipulasi seperti pola *Moiré* dan kompresi JPEG bersifat lokal dan beresolusi tinggi, sehingga akan terdegradasi secara signifikan apabila citra diubah ukurannya menjadi resolusi masukan standar 224×224 piksel. Mengacu pada paradigma

yang diperkenalkan oleh **PatchNet** [7], pendekatan yang diusulkan mereformulasi masalah ini sebagai pengenalan tekstur lokal: alih-alih melihat keseluruhan wajah sekaligus, model disuapi sejumlah potongan (*patch*) kecil yang diekstraksi langsung dari citra wajah yang mempunyai resolusi tinggi 448×448 piksel.

Ukuran dan Motivasi Patch. Setiap *patch* diekstraksi dengan ukuran tetap 224×224 piksel tanpa operasi *resize*, mempertahankan kerapatan piksel asli dari citra hasil pemotongan **YOLOv8**. Ukuran ini dipilih secara sengaja agar selaras dengan resolusi masukan standar **DINOv2** [4], yang membagi citra menjadi *patch* berukuran 14×14 piksel secara internal. Dengan demikian, setiap *patch* yang diumpankan ke *backbone* mengandung detail tekstur lokal yang utuh, termasuk pola *Moiré* dan artefak kompresi yang menjadi penanda serangan, tanpa degradasi akibat interpolasi.



Gambar 3: Ilustrasi strategi *patch sampling* dual-mode. Pada fase pelatihan (*atas*), $N=5$ *patch* berukuran 224×224 piksel diekstraksi secara acak. Pada fase pengujian (*bawah*), $N=9$ *patch* diekstraksi secara deterministik dalam pola kisi 3×3 untuk menjamin cakupan area wajah yang menyeluruh.

Mode Pelatihan: Random Patch Sampling. Pada fase pelatihan, sebanyak $N_{\text{train}} = 5$ *patch* diekstraksi dari setiap citra melalui pemotongan acak, di mana koordinat sudut kiri atas setiap *patch*, yang dinotasikan dengan (x, y) , disampling secara seragam dari ruang yang valid:

$$(x, y) \sim \mathcal{U}([0, W - P] \times [0, H - P]) ,$$

dengan P adalah ukuran *patch* dalam piksel, W dan H masing-masing adalah lebar dan tinggi citra masukan, dan $\mathcal{U}$ adalah distribusi *uniform*. Pada penelitian ini, $P = 224$, $W = H = 448$. Strategi ini secara implisit berfungsi sebagai augmentasi spasial tingkat lanjut, menghasilkan variasi lokasi *patch* yang berbeda di setiap iterasi pelatihan dan memaksa model untuk belajar mengidentifikasi artefak serangan dari berbagai posisi pada wajah, dapat dilihat pada Gambar 3 (*atas*).

Mode Validasi: Grid Patch Sampling. Pada fase validasi dan inferensi, ekstraksi *patch* dilakukan secara deterministik menggunakan pola kisi 3×3 , menghasilkan $N_{\text{val}} = 9$ *patch* yang secara sistematis mencakup seluruh area wajah. Koordinat setiap *patch* dihitung dengan membagi ruang yang valid menjadi dua interval pada sumbu horizontal dan vertikal, memastikan tidak

ada area wajah yang diabaikan selama evaluasi. Pendekatan ini menjamin konsistensi dan *reproducibility* hasil evaluasi antar eksperimen.

Seluruh *patch* yang diekstraksi dari satu citra ditumpuk menjadi sebuah tensor berukuran $[N, C, P, P]$ dan diproses secara bersamaan dalam satu *forward pass*, dengan N adalah jumlah *patch*, $C = 3$ adalah jumlah kanal warna, dan $P = 224$ adalah ukuran sisi *patch* dalam piksel, sebagaimana divisualisasikan pada Gambar 3 (bawah).

E. Arsitektur Model

Arsitektur **TREX** dirancang di atas tiga fondasi utama: *backbone* **DINOv2** dengan *register tokens* sebagai ekstraktor fitur tekstur, mekanisme *Multi-Head Attention Pooling* sebagai agregator representasi *patch*, serta kepala klasifikasi (*classification head*) yang beroperasi pada ruang fitur gabungan berdimensi tinggi. Gambaran arsitektur secara keseluruhan diilustrasikan pada Gambar 4.

Backbone: DINOv2 dengan Register Tokens. *Backbone* yang digunakan adalah **DINOv2 ViT-B/14** dengan *register tokens* [4], [5], yakni model *Vision Transformer* berbasis *self-supervised learning* yang dilatih pada dataset **LVD-142M** yang dikurasi secara otomatis dari 142 juta citra. Arsitektur ini membagi citra masukan berukuran 224×224 piksel menjadi *patch* berukuran 14×14 piksel, menghasilkan 256 token visual yang diproses oleh 12 blok *encoder Transformer* dengan dimensi *embedding* $d = 768$. Pemilihan varian *register tokens* didasarkan pada temuan Darcet dkk. [5] yang mengidentifikasi fenomena *artifact* pada **ViT** standar, di mana token-token tertentu menyerap informasi global yang tidak relevan secara acak, mengganggu peta *attention* dan menurunkan kualitas representasi lokal. Model ini memperkenalkan empat *register tokens* tambahan sebagai struktur memori sementara yang menyerap informasi global tersebut, sehingga *patch tokens* yang tersisa merepresentasikan tekstur lokal secara murni, properti yang sangat krusial untuk mendeteksi artefak manipulasi beresolusi tinggi. Pada setiap *forward pass*, model menghasilkan dua jenis representasi yang dimanfaatkan secara terpisah: token kelas $\mathbf{z}_{\text{cls}} \in \mathbb{R}^{N \times d}$ dan token register $\mathbf{Z}_{\text{reg}} \in \mathbb{R}^{N \times R \times d}$, dengan N adalah jumlah *patch* per citra dan $R = 4$ adalah jumlah *register tokens*.

Multi-Head Attention Pooling. Teknik agregasi *Mean Pooling* yang lazim digunakan pada pipeline klasifikasi standar memiliki kelemahan mendasar dalam konteks *face anti-spoofing*: sinyal artefak manipulasi yang bersifat lokal dan lemah akan terdiluasi ketika dirata-ratakan bersama seluruh representasi *patch*. Sebagai solusi, diusulkan mekanisme *Multi-Head Attention Pooling* yang secara dinamis menghitung bobot kepentingan untuk setiap *patch*, memungkinkan model untuk secara selektif memusatkan perhatian pada region yang mengandung sinyal *spoofing*. Mekanisme ini diimplementasikan melalui sebuah modul *attention* dengan *query* yang dapat dipelajari $\mathbf{q} \in \mathbb{R}^{1 \times d}$. Untuk sekumpulan representasi *patch* $\mathbf{X} \in \mathbb{R}^{B \times N \times d}$, hasil agregasi $\mathbf{h}$ dihitung sebagai berikut:

$$\mathbf{h} = \text{LayerNorm}(\text{MHA}(\mathbf{q}_B, \mathbf{X}, \mathbf{X})),$$

dengan $\mathbf{q}_B \in \mathbb{R}^{B \times 1 \times d}$ adalah *query* yang dapat dipelajari dan direplikasi sebanyak B kali untuk seluruh sampel dalam *batch*; B adalah jumlah sampel dalam satu *mini-batch*; **MHA**($\cdot$) adalah operasi *Multi-Head Attention* [6] dengan $h = 8$ kepala perhatian; dan **LayerNorm**(x) [18] untuk sebuah tensor x didefinisikan sebagai:

$$\text{LayerNorm}(x) = \frac{x - E[X]}{\sqrt{\text{Var}(x) + \epsilon}} \cdot \gamma + \beta,$$

dengan ϵ adalah bilangan yang sangat kecil untuk stabilitas; dan γ serta β adalah parameter yang diestimasi dari data. Hasil agregasi $\mathbf{h} \in \mathbb{R}^{B \times d}$ merupakan representasi ringkas dari seluruh *patch* yang bobot kontribusinya ditentukan secara adaptif oleh model. Modul ini diterapkan secara terpisah pada dua aliran representasi: Pool_{cls} mengagregasi token kelas dari N *patch* menjadi $\mathbf{h}_{\text{cls}} \in \mathbb{R}^{B \times d}$, sedangkan Pool_{reg} mengagregasi seluruh $N \times R$ *register tokens* menjadi $\mathbf{h}_{\text{reg}} \in \mathbb{R}^{B \times d}$.

Fusi Fitur dan Classification Head. Kedua representasi yang dihasilkan oleh *attention pooling* diproyeksikan secara independen melalui lapisan proyeksi masing-masing, yang terdiri dari normalisasi lapisan (*LayerNorm*), transformasi linear, dan fungsi aktivasi **GELU**, sebelum digabungkan:

$$\mathbf{h}_{\text{fused}} = [\text{Proj}_{\text{cls}}(\mathbf{h}_{\text{cls}}) \parallel \text{Proj}_{\text{reg}}(\mathbf{h}_{\text{reg}})],$$


dengan $[\cdot \parallel \cdot]$ menandakan operasi konkatenasi, menghasilkan representasi gabungan $\mathbf{h}_{\text{fused}} \in \mathbb{R}^{B \times 2d}$ berdimensi 1.536. Fusi ini memungkinkan model untuk secara simultan mengeksplorasi informasi semantik dari *CLS token* dan informasi tekstur terstruktur dari *register tokens* dalam satu representasi yang komprehensif. Representasi gabungan selanjutnya diumpankan ke *classification head* yang terdiri dari dua lapisan linear dengan aktivasi **GELU** dan *dropout* dengan probabilitas $p_d = 0,3$ di antara keduanya: $\mathbb{R}^{2d} \rightarrow \mathbb{R}^d \rightarrow \mathbb{R}^K$, dengan $K = 6$ adalah jumlah kelas serangan. Model juga mengembalikan token kelas *patch* $\mathbf{Z}_{\text{cls}} \in \mathbb{R}^{B \times N \times d}$ sebagai keluaran sekunder yang dimanfaatkan dalam komputasi fungsi kerugian kontrasif pada tahap optimasi.

F. Fungsi Kerugian Komposit

Fungsi kerugian tunggal berbasis *Cross-Entropy* standar tidak memadai untuk menangani dua tantangan utama dataset ini: ketidakseimbangan distribusi kelas yang ekstrem dan kemiripan representasi visual yang tinggi antara wajah asli dan serangan tertentu. Untuk mengatasi hal ini, diusulkan fungsi kerugian komposit yang beroperasi pada tiga level optimasi secara simultan: ketajaman batas keputusan antar kelas, konsistensi representasi lokal, dan pemisahan kluster antar kelas dalam ruang laten.

Asymmetric Angular Margin Softmax (AAMS). Terinspirasi dari **ArcFace** [8] dan **PatchNet** [7], komponen ini memproyeksikan fitur ternormalisasi $\hat{\mathbf{f}}_i = \mathbf{f}_i / \|\mathbf{f}_i\|$ ke ruang *hypersphere* lalu menambahkan margin sudut asimetris per kelas pada kelas target:

$$\hat{s}_{i,j} = s \cdot (\cos \theta_{i,j} - m_k \cdot \mathbf{1}[j = y_i])$$



Gambar 4: Arsitektur TREX: blok *encoder* Transformer DINOv2 dengan *Multi-Head Self-Attention* dan *residual connection*, diikuti agregasi *dual-stream Attention Pooling* pada *CLS* dan *register tokens*, fusi konkatenasi berdimensi 1536, dan *classification head* ke $K=6$ kelas.

dengan $s=30$ adalah faktor skala; $\theta_{i,j}$ adalah sudut antara $\hat{\mathbf{f}}_i$ dan vektor bobot kelas j ; m_k adalah margin kelas k ; dan $1[\cdot]$ adalah fungsi indikator. Nilai $\hat{s}_{i,j}$ dioptimasi menggunakan *Cross-Entropy* berbobot dengan *label smoothing* [19] $\varepsilon=0,1$.

Self-Supervised Similarity Loss. Komponen kedua menegakkan konsistensi representasi antar *patch* yang berasal dari citra yang sama. Mengacu pada *self-supervised similarity loss* yang diperkenalkan oleh **PatchNet** [7], properti material serangan tersebar secara spasial di seluruh area wajah, sehingga representasi dari *patch* yang berbeda dalam satu citra seharusnya memiliki kedekatan semantik yang tinggi. Secara formal, diberikan himpunan token kelas *patch* $\{\mathbf{z}_n\}_{n=1}^N$ dengan rata-rata $\bar{\mathbf{z}} = \frac{1}{N} \sum_{n=1}^N \mathbf{z}_n$, fungsi kerugian ini didefinisikan sebagai:

$$\mathcal{L}_{\text{Sim}} = \frac{1}{N} \sum_{n=1}^N \|\mathbf{z}_n - \bar{\mathbf{z}}\|_F^2.$$

Komponen ini secara implisit memaksa model untuk mempelajari fitur material yang invariant terhadap lokasi dan rotasi *patch*, sehingga meningkatkan konsistensi prediksi pada fase inferensi.

Supervised Contrastive Loss (SupCon). Komponen ketiga beroperasi pada level ruang laten global, memastikan bahwa representasi dari kelas yang sama membentuk kluster yang padat sementara kelas yang berbeda terpisah sejauh mungkin. Mengacu pada Khosla dkk. [9], diberikan representasi rata-rata *patch* yang dinormalisasi $\tilde{\mathbf{z}}_i = \bar{\mathbf{z}}_i / \|\bar{\mathbf{z}}_i\|$ untuk setiap sampel i dalam *batch*, fungsi kerugian ini didefinisikan sebagai:

$$\mathcal{L}_{\text{SupCon}} = \sum_{i \in \mathcal{I}} \frac{-1}{|\mathcal{P}(i)|} \sum_{p \in \mathcal{P}(i)} \log \frac{\exp(\tilde{\mathbf{z}}_i \cdot \tilde{\mathbf{z}}_p / \tau)}{\sum_{a \in \mathcal{A}(i)} \exp(\tilde{\mathbf{z}}_i \cdot \tilde{\mathbf{z}}_a / \tau)},$$

dengan $\mathcal{P}(i) \subset \mathcal{A}(i) = \mathcal{I} \setminus \{i\}$ adalah himpunan indeks sampel yang berbagi kelas yang sama dengan i , dan $\tau = 0,07$ adalah parameter temperatur. Nilai τ yang relatif rendah ini mendorong model untuk memusatkan perhatian pada *hard positives* dan *hard negatives*, yang sangat krusial untuk memisahkan representasi kelas-kelas yang secara visual ambigu seperti *fake_unknown*.

Fungsi Kerugian Total. Ketiga komponen digabungkan menjadi fungsi kerugian total yang dioptimasi secara bersama:

$$\mathcal{L} = \mathcal{L}_{\text{AAMS}} + \lambda_{\text{sim}} \mathcal{L}_{\text{Sim}} + \lambda_{\text{supcon}} \mathcal{L}_{\text{SupCon}},$$

dengan $\lambda_{\text{sim}} = 0,3$ dan $\lambda_{\text{supcon}} = 0,2$. Ringkasan peran masing-masing komponen disajikan pada Tabel II.

Tabel II: Komponen Fungsi Kerugian Komposit

Komponen	λ	τ/ε	Peran Optimasi
$\mathcal{L}_{\text{AAMS}}$	1,0	$\varepsilon = 0,1$	Ketajaman batas keputusan
$\mathcal{L}_{\text{Sim}}$	0,3	—	Konsistensi representasi <i>patch</i>
$\mathcal{L}_{\text{SupCon}}$	0,2	$\tau = 0,07$	Pemisahan kluster antar kelas

G. Strategi Pelatihan dan Inferensi

Strategi pelatihan TREX dirancang secara holistik untuk mengatasi dua tantangan utama yang muncul secara bersamaan: (1) risiko *catastrophic forgetting* [25] akibat *fine-tuning* model *pretrained* berukuran besar pada dataset kecil, dan (2) ketidakstabilan estimasi kinerja akibat distribusi kelas yang sangat tidak seimbang. Tiga mekanisme diterapkan secara terintegrasi: *5-Fold Cross Validation* berstratafikasi, strategi *discriminative learning rate* dengan *phased unfreezing*, dan penjadwalan *OneCycleLR*.

5-Fold Cross Validation dan Discriminative Learning Rate. Pelatihan menggunakan skema *Stratified 5-Fold Cross Validation* untuk memastikan setiap citra berperan sebagai data validasi tepat satu kali, menghasilkan estimasi **F1-Macro Out-of-Fold** yang andal dan tidak bias. Optimasi menggunakan **AdamW** [13] dengan *discriminative learning rate*: *backbone* diperbarui dengan $\eta_{\text{bb}} = 5 \times 10^{-6}$ untuk mempertahankan representasi *pretrained*, sedangkan kepala model dengan $\eta_{\text{head}} = 5 \times 10^{-5}$ untuk konvergensi yang lebih agresif, dengan regularisasi bobot $\lambda_{\text{wd}} = 10^{-4}$.

Phased Unfreezing dan OneCycleLR. *Backbone* dibekukan pada empat *epoch* pertama agar kepala model beradaptasi tanpa mengganggu representasi *pretrained*, kemudian seluruh parameter dicairkan untuk *fine-tuning* menyeluruh. Penjadwalan *OneCycleLR* [11] diterapkan dengan *warmup* 10% diikuti peluruhan kosinusoidal selama total 25 *epoch*. Stabilitas numerik dijaga melalui *gradient clipping* $\|\nabla\|_{\text{max}} = 1,0$. Pelatihan diakselerasi menggunakan dua GPU NVIDIA T4 via *DataParallel* dengan ukuran *batch* efektif 16.

Inferensi: Spatial TTA dan Softmax Ensemble. Pada tahap inferensi, prediksi akhir diperoleh melalui kombinasi dua mekanisme stabilisasi yang saling melengkapi. Pertama, *Test-Time Augmentation* (TTA) spasial diterapkan dengan memprediksi setiap citra uji dalam dua orientasi, citra asli dan cerminan horizontalnya, untuk mengurangi sensitivitas model terhadap variasi orientasi yang dapat mempengaruhi respons *attention*. Kedua, probabilitas *softmax* dari kelima model yang dihasilkan oleh masing-masing lipatan diakumulasi dan dirata-ratakan:

$$\hat{y} = \arg \max_k \frac{1}{F} \sum_{f=1}^F \text{Softmax}(\mathbf{o}_f)_k$$

dengan $F = 5$ adalah jumlah lipatan; $\mathbf{o}_f \in \mathbb{R}^K$ adalah vektor *logit* dari model lipatan ke- f ; $\text{Softmax}(\mathbf{o}_f)_k$ adalah probabilitas yang ditetapkan untuk kelas k oleh model lipatan ke- f , yakni elemen ke- k dari vektor probabilitas hasil operasi *softmax*; dan $K = 6$ adalah jumlah kelas. Strategi *Softmax Ensemble* dipilih atas *hard voting* karena mempertahankan informasi tingkat kepercayaan (*confidence*) dari setiap model, menghasilkan batas keputusan yang lebih halus dan robust terhadap *overfitting* lokal yang mungkin terjadi pada lipatan tertentu.

IV. EKSPERIMEN DAN ANALISIS HASIL


A. Deskripsi Dataset

Dataset yang digunakan dalam eksperimen ini merupakan dataset kompetisi **Data Analytics Competition (DAC) FindIT 2026** dengan tugas *Face Anti-Spoofing* yang terdiri dari citra wajah dalam enam kategori: satu kelas wajah asli (*realperson*) dan lima kelas serangan manipulasi (*fake_printed*, *fake_screen*, *fake_mask*, *fake_mannequin*, dan *fake_unknown*). Dataset ini memiliki dua karakteristik utama yang menentukan pilihan desain sistem: ukuran yang relatif kecil dan ketidakseimbangan distribusi kelas yang ekstrem, sebagaimana ditampilkan pada Tabel III.

Tabel III: Distribusi Kelas Dataset *Face Anti-Spoofing*

Kelas	Jumlah	Proporsi (%)	Kategori
<i>realperson</i>	448	27.0	Wajah Asli
<i>fake_printed</i>	143	8.6	Serangan 2D
<i>fake_screen</i>	206	12.4	Serangan 2D
<i>fake_mask</i>	278	16.8	Serangan 3D
<i>fake_mannequin</i>	232	14.0	Serangan 3D
<i>fake_unknown</i>	352	21.2	Tak Dikenal
Total	1659	100	–

Analisis Artefak Frekuensi. Untuk memvalidasi asumsi bahwa serangan manipulasi meninggalkan jejak frekuensi yang dapat dideteksi, analisis *Fast Fourier Transform* (**FFT**) dua dimensi dilakukan terhadap sampel representatif dari tiga kelas utama, sebagaimana diilustrasikan pada Gambar 5. Wajah asli (*realperson*) menghasilkan spektrum frekuensi yang meluruh



Gambar 5: Analisis spektrum FFT 2D pada tiga kelas representatif. (Atas) Citra asli dari kelas *realperson*, *fake_printed*, dan *fake_screen*. (Bawah)

secara alami, mencerminkan distribusi energi tekstur kulit yang organik. Sebaliknya, citra *fake_screen* menunjukkan pola bintang tajam pada frekuensi tinggi, manifestasi dari interferensi kisi piksel layar yang membentuk pola *Moiré*. Citra *fake_printed* menampilkan spektrum yang menyempit akibat hilangnya komponen frekuensi tinggi saat kamera merekam permukaan kertas. Temuan ini secara empiris memotivasi penggunaan *register tokens* dan *Multi-Head Attention Pooling* yang dirancang untuk mengincar sinyal frekuensi lokal tersebut.

B. Detail Implementasi

Seluruh eksperimen diimplementasikan menggunakan **PyTorch** dengan *backbone* **DINOv2** yang dimuat melalui **torch.hub**. Augmentasi data menggunakan pustaka **Albumentations** [12], deteksi wajah menggunakan **Ultralytics YOLOv8** [10], dan pembagian data menggunakan *Stratified K-Fold* dari **Scikit-Learn**. Pelatihan dijalankan pada lingkungan Kaggle dengan dua unit GPU NVIDIA T4 (total VRAM 32 GB) menggunakan mekanisme **DataParallel**. Reprodusibilitas dijamin melalui penetapan *seed* global $s = 42$ pada seluruh komponen stokastik. Ringkasan konfigurasi hiperparameter disajikan pada Tabel IV.

Tabel IV: Konfigurasi Hiperparameter Eksperimen

Hiperparameter	Nilai	Hiperparameter	Nilai
<i>Backbone</i>	vitb14_reg	Embed. dim	768
<i>Reg. tokens</i>	4	Fused dim	1.536
<i>Attn. heads</i>	8	<i>Dropout</i>	0,30
<i>Epoch</i>	25	<i>Fold</i>	5
<i>Batch</i> (GPU)	8	<i>Warmup</i>	10%
<i>LR bb</i>	5×10^{-6}	<i>LR head</i>	5×10^{-5}
<i>Weight decay</i>	10^{-4}	<i>Grad. clip</i>	1,0
Skala AAMS (s)	30,0	SupCon (τ)	0,07
λ_{sim}	0,30	λ_{sc}	0,20
Label smooth	0,10	Res. masukan	448 ²
Uk. patch	224 ²	Patch uji	9

C. Metrik Evaluasi

Evaluasi TREX menggunakan empat metrik yang saling melengkapi, mencakup metrik klasifikasi multi-kelas umum serta metrik spesifik domain *face anti-spoofing*.

Presi, Recall, F1-Makro, dan Support. Untuk setiap kelas $k \in \{1, \dots, K\}$ dengan $K=6$:

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k}, \quad F1_k = \frac{2P_k R_k}{P_k + R_k}$$

dengan TP_k , FP_k , FN_k masing-masing adalah jumlah *true positive*, *false positive*, dan *false negative* kelas k ; sedangkan *support* S_k menyatakan jumlah sampel aktual kelas k . F1-Makro merata-ratakan F1 seluruh kelas dengan bobot yang setara:

$$\text{Macro F1} = \frac{1}{K} \sum_{k=1}^K F1_k$$

Metrik ini menjadi metrik primer karena tidak terpengaruh oleh ketidakseimbangan distribusi kelas.

Akurasi. Akurasi mengukur proporsi sampel yang terklasifikasi benar:

$$\text{Acc} = \frac{\sum_{k=1}^K TP_k}{N}$$

dengan N adalah total sampel evaluasi. Akurasi digunakan sebagai metrik pelengkap karena bersifat menyesatkan pada dataset tidak seimbang.

Average Classification Error Rate (ACER). ACER adalah metrik standar kompetisi *face anti-spoofing* [1] yang mengukur keseimbangan antara kesalahan deteksi serangan dan penolakan wajah asli:

$$\text{ACER} = \frac{\text{APCER} + \text{BPCER}}{2}$$

Attack Presentation Classification Error Rate (APCER) mengukur proporsi sampel serangan yang salah diklasifikasikan sebagai wajah asli, sedangkan *Bonafide Presentation Classification Error Rate* (BPCER) mengukur proporsi wajah asli yang salah diklasifikasikan sebagai serangan:

$$\text{APCER} = 1 - \frac{1}{N_{PA}} \sum_{i=1}^{N_{PA}} r_i, \quad \text{BPCER} = \frac{1}{N_{BF}} \sum_{i=1}^{N_{BF}} r_i$$

dengan N_{PA} dan N_{BF} masing-masing adalah jumlah sampel serangan dan wajah asli; $r_i = 1$ jika sampel terklasifikasi benar dan 0 jika sebaliknya. ACER yang lebih rendah menunjukkan sistem yang lebih seimbang antara keamanan dan kenyamanan pengguna.

Precision-Recall AUC (PR-AUC). PR-AUC mengukur luas area di bawah kurva *Precision-Recall* pada klasifikasi biner *live* vs. *spoof*. Diberikan probabilitas prediksi $\hat{p}_{\text{live}}(x)$ untuk setiap sampel x , keputusan klasifikasi pada ambang batas θ menghasilkan:

$$P(\theta) = \frac{TP(\theta)}{TP(\theta) + FP(\theta)}, \quad R(\theta) = \frac{TP(\theta)}{TP(\theta) + FN(\theta)}$$

PR-AUC diperoleh dengan mengintegrasikan kurva *P-R* terhadap seluruh nilai $\theta \in [0, 1]$:

$$\text{PR-AUC} = \int_0^1 P(R(\theta)) \left| \frac{dR}{d\theta} \right| d\theta \approx \sum_{i=1}^{n-1} \frac{P_i + P_{i+1}}{2} \cdot (R_{i+1} - R_i)$$

dengan (R_i, P_i) adalah pasangan nilai pada titik ambang ke- i . Metrik ini lebih informatif dibanding ROC-AUC pada kondisi ketidakseimbangan kelas yang ekstrem [26].

D. Hasil Evaluasi Kuantitatif

Kinerja 5-Fold Cross Validation. Tabel V menyajikan skor **F1-Macro** validasi pada setiap lipatan beserta statistik ringkasannya. Konsistensi skor antar lipatan mengindikasikan bahwa model tidak bergantung pada pembagian data tertentu dan mampu menggeneralisasi dengan baik pada distribusi kelas yang tidak seimbang.

Tabel V: Kinerja **F1-Macro**, ACER, dan PR-AUC per Lipatan (Out-of-Folds)

Lipatan	F1-Macro Val.	ACER Val.	PR-AUC Val.
1	0.9713	0.0102	0.9757
2	0.9923	0.0082	0.9947
3	0.9812	0.0059	0.9852
4	0.9937	0.0063	0.9978
5	0.9687	0.0124	0.9716
Rata-rata	0.9812 ± 0.0115	0.0086 ± 0.0027	0.9852 ± 0.0095

Perbandingan dengan Baseline. Tabel VI membandingkan metode yang diusulkan (TREX) dengan tiga *baseline*: (1) **ResNet-50** [22] yang di-*fine-tune* sebagai representasi pendekatan berbasis CNN konvensional, (2) **EfficientNet-b4** [23] sebagai representasi pendekatan CNN modern yang dioptimalkan melalui model scaling, dan (3) **DINOv2 ViT-B/14** sebagai representasi model *vision transformer* berbasis *self-supervised learning*. Seluruh *baseline* dilatih pada konfigurasi yang identik untuk memastikan perbandingan yang adil.

Tabel VI: Perbandingan Kinerja dengan *Baseline*

Metode	F1-Macro	Acc.	ACER	PR-AUC
ResNet50	0.8956	0.9012	0.0528	0.9150
EfficientNet-b4	0.9015	0.9045	0.0503	0.9080
DINOv2 ViT-B/14	0.9318	0.9380	0.0308	0.9450
TREX (Proposed)	0.9812	0.9820	0.0086	0.9852

Analisis Kinerja Per Kelas. Tabel VII menyajikan kinerja model per kelas pada set validasi *fold* terbaik. Perhatian khusus diarahkan pada kelas minoritas (*fake_unknown* dan *fake_mannequin*) yang secara historis menjadi tantangan utama pada dataset dengan distribusi tidak seimbang.

Tabel VII: Rata-rata Kinerja Per Kelas pada Keseluruhan *Fold*

Kelas	Precision	Recall	F1	Support
<i>realperson</i>	0.9911	0.9955	0.9933	448
<i>fake_printed</i>	0.9860	0.9860	0.9860	143
<i>fake_screen</i>	0.9902	0.9806	0.9854	206
<i>fake_mask</i>	0.9785	0.9820	0.9803	278
<i>fake_mannequin</i>	0.9740	0.9698	0.9719	232
<i>fake_unknown</i>	0.9689	0.9717	0.9703	352
Macro	0.9812	0.9810	0.9812	1659
Weighted Average	0.9813	0.9819	0.9819	1659

E. Studi Ablasi

Ablasi Arsitektur dan Komponen Model. Untuk mengukur efektivitas dari setiap komponen arsitektur yang diusulkan, kami melakukan studi ablasi secara bertahap mulai dari model DINOv2 dengan *registers* hingga arsitektur penuh TREX. Tabel VIII menunjukkan bahwa penambahan strategi *patch sampling*, augmentasi bertingkat, dan *mean pooling* secara konsisten menekan nilai ACER dan meningkatkan **F1-Macro**.

Tabel VIII: Studi Ablasi Arsitektur dan Komponen Model

Konfigurasi Model	F1-Macro	Acc.	ACER	PR-AUC
DINOv2 ViT-B/14 + Reg	0.9370	0.9410	0.0328	0.9490
+ Patch Sampling (PS)	0.9551	0.9590	0.0232	0.9610
+ Augmentation	0.9607	0.9615	0.0191	0.9650
+ MHA Pooling	0.9690	0.9695	0.0145	0.9785
TREX	0.9812	0.9820	0.0086	0.9852

Dampak Komponen Fungsi Kerugian. Selain arsitektur, kami juga mengkuantifikasi kontribusi masing-masing komponen fungsi kerugian komposit. Empat konfigurasi dilatih pada kondisi yang identik dengan perbedaan eksklusif pada komponen kerugian yang diaktifkan. Hasil pada Tabel IX menunjukkan peningkatan **F1-Macro** yang konsisten seiring penambahan setiap komponen, memvalidasi desain fungsi kerugian yang diusulkan.

Tabel IX: Ablasi Komponen Fungsi Kerugian

Konfigurasi	$\mathcal{L}_{AAMS}$	$\mathcal{L}_{Sim}$	$\mathcal{L}_{SupCon}$	F1	Δ
<i>Cross-Entropy</i> Standar	✗	✗	✗	0.9728	–
+ AAMS	✓	✗	✗	0.9760	+0.0032
+ AAMS + $\mathcal{L}_{Sim}$	✓	✓	✗	0.9785	+0.0025
TREX	✓	✓	✓	0.9812	+0.0027

Sensitivitas Jumlah Patch. Jumlah *patch* yang diekstraksi per citra merupakan hiperparameter kritis yang memengaruhi keseimbangan antara cakupan area wajah dan efisiensi komputasi. Tabel X menyajikan sensitivitas **F1-Macro** terhadap variasi jumlah *patch* pada fase pelatihan, dengan jumlah *patch* validasi dipertahankan pada $N_{val} = 9$.

Nilai $N_{train} = 5$ dipilih berdasarkan titik keseimbangan optimal antara peningkatan kinerja dan biaya komputasi, di


Tabel X: Sensitivitas **F1-Macro** terhadap Jumlah *Patch* Pelatihan

N_{train}	F1-Macro	Δ	Ket.
1	0.9350	–	<i>Single patch</i>
3	0.9685	+0.0335	–
5	0.9812	+0.0127	Dipilih
7	0.9835	+0.0023	<i>Diminishing return</i>

mana penambahan *patch* lebih lanjut menunjukkan *diminishing return* yang signifikan.

F. Analisis Galat

Matriks Konfusi dan Pola Kesalahan. Gambar 6 menyajikan matriks konfusi model OOF. Secara umum, pola kesalahan yang teramati mencerminkan tingkat kemiripan visual antar kelas yang memang tinggi pada domain *face anti-spoofing*.

Gambar 6: *Confusion matrix* pada *fold* terbaik. Nilai diagonal menunjukkan prediksi benar per kelas.

Berdasarkan hasil tersebut, ini mengonfirmasi bahwa batas keputusan antara wajah asli dan serangan berhasil dibentuk dengan tegas oleh komponen AAMS. Kelas *fake_mannequin* menunjukkan kebingungan terbesar dengan *fake_unknown* (11 sampel), yang dapat dijelaskan oleh kemiripan artefak kompresi frekuensi tinggi antara cetakan beresolusi rendah dan layar berkecerahan rendah. Kebingungan antara *fake_mask* dan *fake_mannequin* juga teramati, konsisten dengan ekspektasi bahwa kedua kelas serangan tiga dimensi ini berbagi karakteristik tekstur permukaan yang serupa.

Analisis Kasus Galat. Kegagalan model secara sistematis bersumber dari dua faktor utama. **Pertama**, kelas *fake_unknown* menunjukkan distribusi kesalahan yang tersebar ke berbagai kelas, mencerminkan sifatnya yang tidak memiliki definisi artefak yang konsisten sehingga representasi latennya sulit dipisahkan secara tegas. **Kedua**, serangan berkualitas tinggi menghasilkan spektrum frekuensi yang mendekati wajah asli, menempatkan batas atas kinerja sistem pada kualitas fisik media serangan, bukan semata-mata pada kapasitas model.

V. KESIMPULAN

Penelitian ini telah berhasil mengembangkan sebuah kerangka kerja *Face Anti-Spoofing (FAS)* yang tangguh dengan memformulasikan deteksi serangan sebagai masalah klasifikasi tekstur *fine-grained* tingkat *patch*. Integrasi pra-pemrosesan **YOLOv8-Face** dengan strategi *patch-based sampling* terbukti efektif dalam mengekstraksi artefak mikroskopis, seperti pola Moiré dan pikselasi layar, sembari meminimalisasi ketergantungan model terhadap fitur anatomi wajah global yang mudah direplikasi. Penggunaan *backbone DINOv2* yang dilengkapi dengan *Register Tokens* secara krusial berhasil menghilangkan artefak pada *attention map*, sehingga memastikan mekanisme *Multi-Head Attention Pooling* berfokus sepenuhnya pada area diskriminatif serangan.

Optimasi ruang laten melalui sinergi fungsi kerugian komposit, yang menggabungkan *Asymmetric Angular Margin Softmax (AAMS)* dan *Supervised Contrastive Learning (SupCon)*, terbukti mampu menciptakan batas keputusan yang absolut. Strategi ini berhasil mempertahankan kohesi fitur intra-kelas yang tinggi serta pemisahan inter-kelas yang tegas, bahkan dalam kondisi dataset yang tidak seimbang. Hasil evaluasi melalui *5-Fold Cross-Validation* pada dataset yang digunakan mengonfirmasi bahwa model yang diusulkan memiliki performa yang stabil dan secara signifikan mengungguli arsitektur *baseline* konvensional.

Saran Pengembangan. Arah pengembangan yang paling krusial adalah perancangan model **FAS** yang ringan dan dapat digunakan pada perangkat dengan sumber daya terbatas (*edge deployment*). **TREX** dalam konfigurasi saat ini, dengan *backbone DINOv2-Base* dan inferensi berbasis *5-fold ensemble*, memiliki kompleksitas komputasi yang terlalu besar untuk diterapkan secara *real-time* pada perangkat *mobile* atau *embedded system*. Penelitian lanjutan dapat mengeksplorasi teknik distilasi pengetahuan (*knowledge distillation*) [24] untuk mentransfer representasi diskriminatif **TREX** ke arsitektur yang lebih ringkas seperti **DINOv2-Small** atau varian *lightweight ViT*, serta penerapan kuantisasi dan pemangkasan jaringan (*pruning*) untuk mereduksi jejak memori tanpa degradasi kinerja yang signifikan. Pendekatan ini berpotensi menjembatani kesenjangan antara kinerja tinggi sistem berbasis *foundation model* dan kebutuhan praktis deployment **FAS** pada infrastruktur komputasi terbatas di dunia nyata.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada penyelenggara kompetisi *Data Analytics Competition (DAC) FindIT 2026* oleh DTETI FT UGM atas penyediaan dataset dan platform kompetisi yang menjadi landasan penelitian ini. Apresiasi juga disampaikan kepada Bapak Alfian Farizki Wicaksono, S.T., M.Sc., Ph.D. atas dukungan teknis dan diskusi yang konstruktif selama proses pengerjaan.

REFERENSI

- [1] M. Feng, P. Gallin-Martel, K. Ito, dan T. Aoki, "Optimizing DINOv2 with registers for face anti-spoofing," *arXiv preprint arXiv:2510.17201*, 2025.
- [2] Z. Yu, C. Zhao, Z. Wang, Y. Qin, Z. Su, X. Li, F. Zhou, dan G. Zhao, "Searching central difference convolutional networks for face anti-spoofing," dalam *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recog. (CVPR)*, 2020, hlm. 5295–5305.
- [3] Z. Yu, J. Wan, Y. Qin, X. Li, S. Z. Li, dan G. Zhao, "NAS-FAS: Static-dynamic central difference network search for face anti-spoofing," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 9, hlm. 3005–3023, 2020.
- [4] M. Oquab *et al.*, "DINOv2: Learning robust visual features without supervision," *Trans. Mach. Learn. Res.*, 2024.
- [5] T. Darcet, M. Oquab, J. Mairal, dan P. Bojanowski, "Vision transformers need registers," dalam *Proc. Int'l Conf. Learn. Represent. (ICLR)*, 2024.
- [6] A. Vaswani *et al.*, "Attention is all you need," dalam *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2017, hlm. 5998–6008.
- [7] C. Wang, Y. Lu, S. Yang, dan S. Lai, "PatchNet: A simple face anti-spoofing framework via fine-grained patch recognition," dalam *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recog. (CVPR)*, 2022, hlm. 20281–20290.
- [8] J. Deng, J. Guo, N. Xue, dan S. Zafeiriou, "ArcFace: Additive angular margin loss for deep face recognition," dalam *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recog. (CVPR)*, 2019, hlm. 4690–4699.
- [9] P. Khosla *et al.*, "Supervised contrastive learning," dalam *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2020, hlm. 18661–18673.
- [10] G. Jocher, A. Chaurasia, dan J. Qiu, "Ultralytics YOLOv8," 2023. [Daring]. Tersedia: <https://github.com/ultralytics/ultralytics>
- [11] L. N. Smith, "Super-convergence: Very fast training of neural networks using large learning rates," dalam *Proc. SPIE Def. Commer. Sens.*, vol. 11006, 2019.
- [12] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, dan A. A. Kalinin, "Albumentations: Fast and flexible image augmentations," *Information*, vol. 11, no. 2, hlm. 125, 2020.
- [13] I. Loshchilov dan F. Hutter, "Decoupled weight decay regularization," dalam *Proc. Int'l Conf. Learn. Represent. (ICLR)*, 2019.
- [14] A. Dosovitskiy *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," dalam *Proc. Int'l Conf. Learn. Represent. (ICLR)*, 2021.
- [15] M. Caron *et al.*, "Emerging properties in self-supervised vision transformers," dalam *Proc. IEEE/CVF Int'l Conf. Comput. Vis. (ICCV)*, 2021, hlm. 9650–9660.
- [16] K. He, X. Chen, S. Xie, Y. Li, P. Dollár, dan R. Girshick, "Masked autoencoders are scalable vision learners," dalam *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recog. (CVPR)*, 2022, hlm. 16000–16009.
- [17] T. Chen, S. Kornblith, M. Norouzi, dan G. Hinton, "A simple framework for contrastive learning of visual representations," dalam *Proc. Int'l Conf. Mach. Learn. (ICML)*, 2020, hlm. 1597–1607.
- [18] J. L. Ba, J. R. Kiros, dan G. E. Hinton, "Layer normalization," *arXiv preprint arXiv:1607.06450*, 2016.
- [19] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, dan Z. Wojna, "Rethinking the inception architecture for computer vision," dalam *Proc. IEEE Conf. Comput. Vis. Pattern Recog. (CVPR)*, 2016, hlm. 2818–2826.
- [20] Y. Liu, A. Jourabloo, dan X. Liu, "Learning deep models for face anti-spoofing: Binary or auxiliary supervision," dalam *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recog. (CVPR)*, 2018, hlm. 389–398.
- [21] Z. Wang, Q. Wang, W. Deng, dan G. Guo, "Face anti-spoofing using transformers with relation-aware mechanism," *IEEE Trans. Biometrics, Behavior, Identity Sci.*, vol. 4, no. 3, hlm. 439–450, 2022.
- [22] K. He, X. Zhang, S. Ren, dan J. Sun, "Deep residual learning for image recognition," dalam *Proc. IEEE Conf. Comput. Vis. Pattern Recog. (CVPR)*, 2016, hlm. 770–778.
- [23] M. Tan dan Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," dalam *Proc. Int'l Conf. Mach. Learn. (ICML)*, 2019, hlm. 6105–6114.
- [24] J. Marrie, M. Arbel, J. Mairal, dan D. Larlus, "On Good Practices for Task-Specific Distillation of Large Pretrained Visual Models," *Transactions on Machine Learning Research*, 2024.
- [25] J. Kirkpatrick *et al.*, "Overcoming catastrophic forgetting in neural networks," *Proc. Nat. Acad. Sci. (PNAS)*, vol. 114, no. 13, hlm. 3521–3526, 2017.
- [26] T. Saito dan M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLOS ONE*, vol. 10, no. 3, hlm. e0118432, 2015.